

# 第一章 数值分析基础

## 数值分析

南京理工大学数统学院

## 1.1 数值分析课程简介

## 1.2 误差分析基础

## 1.3 数值分析基础知识

### 1 线性空间与基的表达

### 2 内积及其应用

### 3 范数及其应用

- 向量范数及其性质
- 矩阵范数及其性质
- 范数的应用（谱半径，条件数）

## 1.1 数值分析课程简介

问题1: 考虑线性方程组求解问题

$$Ax = b, \quad A \in \mathbb{R}^{n \times n}$$

## 1.1 数值分析课程简介

问题1: 考虑线性方程组求解问题

$$Ax = b, \quad A \in \mathbb{R}^{n \times n}$$

理论上可依据 Grammer 法则求解, 计算量为  $O(n \cdot n!)$ 。用美国Summit超级计算机, 每秒20亿亿( $2 \times 10^{17}$ )次运算,

$n = 20$  时, 需要243.29秒, 约4分钟。

$n = 25$  时, 需要538583.68小时, 约61.5年!

Grammer 法则理论上很完美, 但实际工程问题中根本无法使用!

## 1.1 数值分析课程简介

**问题1:** 考虑线性方程组求解问题

$$Ax = b, \quad A \in \mathbb{R}^{n \times n}$$

理论上可依据 Grammer 法则求解, 计算量为  $O(n \cdot n!)$ 。用美国Summit超级计算机, 每秒20亿亿( $2 \times 10^{17}$ )次运算,

$n = 20$  时, 需要243.29秒, 约4分钟。

$n = 25$  时, 需要538583.68小时, 约61.5年!

Grammer 法则理论上很完美, 但实际工程问题中根本无法使用!

**问题:** 如何计算可节约计算量, 设计实际工程可用的计算方法?

事实上，对于同一个问题，可设计具有不同计算量的算法。

例：计算  $P(x) = 2x^4 + 3x^3 - 3x^2 + 5x + 1$

事实上，对于同一个问题，可设计具有不同计算量的算法。

例：计算  $P(x) = 2x^4 + 3x^3 - 3x^2 + 5x + 1$

- ① 直接从左到右依次计算，需要 10 次乘法，4 次加法，共 14 次运算；

事实上，对于同一个问题，可设计具有不同计算量的算法。

例：计算  $P(x) = 2x^4 + 3x^3 - 3x^2 + 5x + 1$

- ① 直接从左到右依次计算，需要 10 次乘法，4 次加法，共 14 次运算；
- ② 先算  $x^2$ ，再算  $x^3 = x^2 * x$ ,  $x^4 = x^3 * x$ ，需要 7 次乘法，4 次加法，共 11 次运算；



事实上，对于同一个问题，可设计具有不同计算量的算法。

例：计算  $P(x) = 2x^4 + 3x^3 - 3x^2 + 5x + 1$

- ① 直接从左到右依次计算，需要 10 次乘法，4 次加法，共 14 次运算；
- ② 先算  $x^2$ ，再算  $x^3 = x^2 * x$ ， $x^4 = x^3 * x$ ，需要 7 次乘法，4 次加法，共 11 次运算；
- ③  $P(x) = 1 + x * (5 + x * (-3 + x * (3 + 2 * x)))$ ，只需要 4 次乘法，4 次加法，共只需 8 次运算。

启发：合理地设计计算方法，可以简化计算，节省计算量！

问题2: 考虑函数  $f(x) = \sin x$ ,  $x \in [0, \pi]$  的计算。

已知,  $f(0) = 0, f(\frac{\pi}{6}) = \frac{1}{2}, f(\frac{\pi}{4}) = \frac{\sqrt{2}}{2}, \dots$ , 问题:  $f(\frac{\pi}{5}) = ?$

**问题2:** 考虑函数  $f(x) = \sin x$ ,  $x \in [0, \pi]$  的计算。

已知,  $f(0) = 0, f(\frac{\pi}{6}) = \frac{1}{2}, f(\frac{\pi}{4}) = \frac{\sqrt{2}}{2}, \dots$ , 问题:  $f(\frac{\pi}{5}) = ?$

可能的方法:

- 利用 Taylor 展开式  $\sin x = x - \frac{x^3}{3!} + \frac{x^5}{5!} + \dots$ , 截取前  $n$  项近似计算。

**问题2:** 考虑函数  $f(x) = \sin x$ ,  $x \in [0, \pi]$  的计算。

已知,  $f(0) = 0, f(\frac{\pi}{6}) = \frac{1}{2}, f(\frac{\pi}{4}) = \frac{\sqrt{2}}{2}, \dots$ , 问题:  $f(\frac{\pi}{5}) = ?$

可能的方法:

- 利用 Taylor 展开式  $\sin x = x - \frac{x^3}{3!} + \frac{x^5}{5!} + \dots$ , 截取前  $n$  项近似计算。
- 构造函数

$$P(x) = \frac{1}{2} \cdot \frac{(x-0)(x-\frac{\pi}{4})}{(\frac{\pi}{6}-0)(\frac{\pi}{6}-\frac{\pi}{4})} + \frac{\sqrt{2}}{2} \cdot \frac{(x-0)(x-\frac{\pi}{6})}{(\frac{\pi}{4}-0)(\frac{\pi}{4}-\frac{\pi}{6})}$$

则有  $f(0) = P(0), f(\frac{\pi}{6}) = P(\frac{\pi}{6}), f(\frac{\pi}{4}) = P(\frac{\pi}{4})$ , 由于在  $x = \frac{\pi}{5}$  附近的已知节点上的函数值都正确, 因此有理由相信  $f(\frac{\pi}{5}) \approx P(\frac{\pi}{5})$ 。

**问题:** 哪种近似方法更好? **更方便**的计算, **更小**的误差...

更多的问题.....

- 如何求方程  $x^3 - x + e^x = 0$  的根? (非线性方程 (组) 求根)
- 如何计算  $\int_1^2 \frac{\sin x}{x} dx$ ? (数值积分)
- 如何求解描述大气运动的 Lorenz 微分方程? (常微分方程数值方法)

$$\begin{cases} \dot{x} = P(y - x) \\ \dot{y} = Rx - y - xz \\ \dot{z} = xy - bz \end{cases}$$




Figure: Lorenz方程吸引子

- 天气预测、石油开采、地下水污染等的数学模型求解 (偏微分方程数值方法)

**数值分析：**分析和研究数值计算方法的课程，数值计算也叫**科学计算**，已经和理论研究、实验研究一起，并列成为现代科学研究的三大研究手段之一。




Figure: 实际工程问题的解决途径

**Top ten algorithms of the century:** “We tried to assemble the 10 algorithms with the greatest influence on the development and practice of science and engineering in the 20th century” —Editors of [IEEE Computational Science and Engineering](#), Jan. 2000 (后被 SIAM 转载)

1. 1946, Monte Carlo方法的 Metropolis 算法（机器学习重要基础之一）
2. 1947, 解线性规划问题的单纯形算法（simplex method）
3. 1950, Krylov子空间迭代法（Lanczos过程、CG算法等，现代大规模科学计算的基础算法之一）
4. 1950' s, A. Householder形式化的矩阵分解方法（表示为矩阵分解）

## Top ten algorithms of the century(Cont...)

5. 1957, Fortran 最优编译器（科学计算性能优于C/C++）
6. 1959-1961, 能稳定计算矩阵特征值的 QR 算法（现代大规模科学计算的基础算法之一）
7. 1962, 快速排序算法（Quicksort）
8. 1965, 快速 Fourier 变换（FFT 及 IFFT 算法，现代信号分析核心基础算法之一）
9. 1977, 整数关系侦察算法（Integer Relation Detection）
10. 1987, 快速多极算法（fast multipole algorithm）

大多数算法都与数值计算直接相关！部分算法也属于本课程内容。

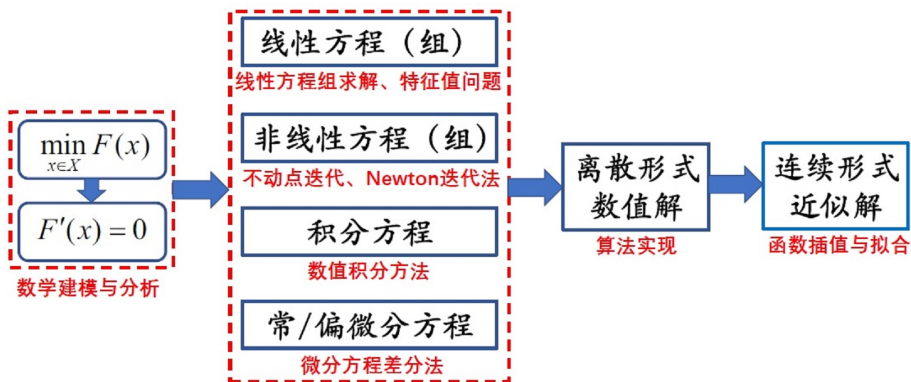


针对实际问题的**数学模型**求解，数值分析主要**研究能够在计算机上进行实现的算法**，其主要内容有：

- ① **直接求解**：如何方便计算？减少计算量，甚至变不可能为可能
- ② **近似求解**，要解决的问题：
  - (1) 用什么来近似？（近似的**基本原理**，研究算法设计原理）
  - (2) 如何进行近似？（近似的**具体方法**，研究算法具体设计）
  - (3) 如何度量近似的好坏？（近似的**误差分析**，研究算法优缺点）
  - (4) 如何在计算机上实现？（近似的**具体实现**，上机实现具体算法）

**最重要的概念**：**基**的表示（逼近方法建模），算法设计，算法稳定性和收敛性（误差分析），算法复杂度

## 数学建模与数值分析主要内容：



## 1.2 误差分析基础

在实际问题中，误差几乎是不可避免的。误差根据其来源，可分为：

- **观测误差**：由观测产生的误差（物理因素造成）
- **模型误差**：由实际问题转化为数学模型时产生的误差（数学简化时的误差）；
- **截断误差**：也被称为方法误差，是数值近似解与模型精确解之间的误差（构造数值算法时产生）；
- **舍入误差**：实际计算中，计算机在计算过程中只能对有限位数的数字进行运算，对于超过位数的数字便自动四舍五入，产生舍入误差；

## 1.误差的度量

**定义:** 设  $x^*$  为精确值,  $x_a$  为  $x^*$  的一个近似值, 称  $|x_a - x^*|$  为近似值的**绝对误差** (简称误差)。

一般称

$$\frac{|x_a - x^*|}{|x^*|} \quad (x^* \neq 0)$$

为**相对误差**, 但实际中由于  $x^*$  是未知的, 所以也可用

$$\frac{|x_a - x^*|}{|x_a|} \quad (x_a \neq 0)$$

作为相对误差。

**定义:** 设  $x_a$  为精确值  $x^*$  的一个近似值, 如果存在  $\varepsilon_a > 0$ , 使得

$$|x_a - x^*| \leq \varepsilon_a$$

则称  $\varepsilon_a$  为近似值的一个**绝对误差界**, 若  $x^* \neq 0$ , 称  $\frac{\varepsilon_a}{|x^*|}$  为**相对误差界**。

**定义:** 设  $x_a = \pm 10^k \times 0.d_1 d_2 d_3 \cdots d_m \cdots$  为精确值  $x^*$  的一个近似值, 其中  $d_1 \neq 0$ ,  $x_a$  有可能为有限或者无限小数形式, 如果  $n$  是满足

$$|x_a - x^*| \leq 0.5 \times 10^{k-n}$$

的最大非负整数, 则称  $x_a$  为  $x^*$  的具有  $n$  位十进制**有效数字**的近似值。

例：对于圆周率  $\pi$  的近似 ( $\pi : 3.14159265358979323846 \dots$ )

- (1)  $\pi_a = 3.14$ , 则 0.002 和 0.0006 分别为近似值的一个绝对误差界和一个相对误差界。
- (2)  $\pi_a = 3.14 = 10^1 \times 0.314$ , 由于  $|\pi - \pi_a| \leq 0.5 \times 10^{-2} = 0.5 \times 10^{1-3}$ , 因此 3.14 近似  $\pi$  时有三位有效数字。
- (3)  $\pi_a = \frac{22}{7} = 10^1 \times 0.3142857 \dots$ , 由于  $|\pi - \pi_a| \leq 0.5 \times 10^{-2} = 0.5 \times 10^{1-3}$ , 因此  $\frac{22}{7}$  近似  $\pi$  时有三位有效数字。(祖冲之“约率”)
- (4)  $\pi_a = \frac{355}{113} = 10^1 \times 0.31415929 \dots$ , 由于  $|\pi - \pi_a| \leq 0.5 \times 10^{-6} = 0.5 \times 10^{1-7}$ , 因此  $\frac{355}{113}$  近似  $\pi$  时有七位有效数字。(祖冲之“密率”)

## 2. 求函数值的误差估计

- (1) 假设一元函数 $f$ 具有二阶连续导数, 自变量 $x$ 的一个近似值为 $x_A$ , 由Taylor公式可以估计 $f(x_A)$ 对 $f(x)$ 近似的绝对误差:

$$|f(x_A) - f(x)| \leq |f'(x_A)||x - x_A| + \frac{|f''(\xi)||x - x_A|^2}{2},$$

其中 $\xi$ 在 $x$ 与 $x_A$ 之间.

若 $f'(x_A) \neq 0$ ,  $|f''(\xi)|$ 与 $f'(x_A)$ 相比不太大, 则上式右端第二项可忽略, 于是有 $f(x_A)$ 绝对误差的如下近似估计:

$$|f(x_A) - f(x)| \leq |f'(x_A)||x - x_A|.$$

(2) 若 $f$ 是 $n$ 元函数, 自变量 $x_1, \cdots, x_n$ 的近似值分别为 $x_{1A}, \cdots, x_{nA}$ , 则有 $f(\mathbf{x}_A)$ 绝对误差的如下近似估计:

$$|f(x_{1A}, \cdots, x_{nA}) - f(x_1, \cdots, x_n)| \leq \sum_{k=1}^n \left| \left( \frac{\partial f}{\partial x_k} \right)_A \right| |x_k - x_{kA}|.$$



### 3. 病态问题与条件数

若初始数据的微小扰动, 而使解严重失真, 则称该问题是病态的, 反之, 称为良态的.

例:  $f(x)$  的计算:

函数值相对误差:

$$\left| \frac{f(x+h) - f(x)}{f(x)} \right| \approx \left| \frac{hf'(x)}{f(x)} \right| = \left| \frac{xf'(x)}{f(x)} \right| \left| \frac{h}{x} \right|.$$

计算函数值问题的条件数:  $C = \left| \frac{xf'(x)}{f(x)} \right|.$

## 4.数值稳定性

对于一个数值方法(公式), 若初始数据或计算过程中某一步的结果有微小改变, 而由此引起的最后结果的改变也是微小的, 则称该方法是数值稳定的, 否则称为数值不稳定的. (允许误差, 要求误差的传播可控)

如果一种数值方法有初始误差 $\epsilon_0 > 0$ , 由它引起此后运算 $n$ 步的误差是 $\epsilon_n$ (下面 $C$ 是与 $n$ 无关的常数)

- (1) 如果 $|\epsilon_n| \approx Cn\epsilon_0$ , 称误差线性增长;
- (2) 如果 $|\epsilon_n| \approx C^n\epsilon_0$ , 称误差指数增长.

例 建立

$$I_n = \int_0^1 \frac{x^n}{x+25} dx$$

的递推公式, 计算 $I_1, I_2, I_3, I_4$ .

## 例 建立

$$I_n = \int_0^1 \frac{x^n}{x+25} dx$$

的递推公式, 计算 $I_1, I_2, I_3, I_4$ .

解

$$I_n + 25I_{n-1} = \int_0^1 \frac{x^n + 25x^{n-1}}{x+25} dx = \int_0^1 x^{n-1} dx = \frac{1}{n},$$

$$I_n = \frac{1}{n} - 25I_{n-1}.$$

保留五位小数, 计算得:

$$I_0 = \int_0^1 \frac{1}{x+25} dx = \ln(x+25) \Big|_0^1 \approx 0.03922,$$

$$\begin{aligned} I_1 &= 1 - 25I_0 \approx 0.01950, & I_2 &= \frac{1}{2} - 25I_1 \approx 0.01250, \\ I_3 &= \frac{1}{3} - 25I_2 \approx 0.02083, & I_4 &= \frac{1}{4} - 25I_3 \approx -0.27075. \end{aligned}$$

$$I_1 = 1 - 25I_0 \approx 0.01950, \quad I_2 = \frac{1}{2} - 25I_1 \approx 0.01250,$$
$$I_3 = \frac{1}{3} - 25I_2 \approx 0.02083, \quad I_4 = \frac{1}{4} - 25I_3 \approx -0.27075.$$

⇒上述解法是有问题的!

分析原因: 计算 $I_0$ 时只保留了小数点后五位,

$$I_1 = 1 - 25I_0 \approx 0.01950, \quad I_2 = \frac{1}{2} - 25I_1 \approx 0.01250,$$
$$I_3 = \frac{1}{3} - 25I_2 \approx 0.02083, \quad I_4 = \frac{1}{4} - 25I_3 \approx -0.27075.$$

⇒上述解法是有问题的!

分析原因: 计算 $I_0$ 时只保留了小数点后五位,

上述解法每计算一步, 将前一步误差放大25倍!

解 将递推公式写为:

$$I_{n-1} = \frac{1}{25} \left( \frac{1}{n} - I_n \right),$$
$$\left| I_{n-1} - \tilde{I}_{n-1} \right| = \frac{1}{25} \left| I_n - \tilde{I}_n \right|.$$

另一方面, 注意到:

$$0 < \int_0^1 \frac{x^n}{x+25} dx < \int_0^1 \frac{x^n}{25} dx = \frac{1}{25} \frac{1}{n+1} \rightarrow 0 (n \rightarrow \infty),$$

因此,  $I_n \rightarrow 0 (n \rightarrow \infty)$ , 可取  $\tilde{I}_7 = 0$ , 由递推公式计算得:

$$\tilde{I}_4 = 0.00774, \tilde{I}_3 = \dots\dots$$



## 5.误差的危害及处理

**危害一：损失有效数字**（很接近的数做减法时出现）

**例：**求解  $x^2 - 16x + 1 = 0$ ，很容易得到解

$$x_1 = 8 + \sqrt{63} \approx 15.9372539332 \cdots, \quad x_2 = 8 - \sqrt{63} \approx 0.0627460668 \cdots$$

计算机只能对有限数字进行运算，对于无理数只能采用近似值计算。采用**三位十进制**数计算，取  $\sqrt{63} \approx 7.94$ ，有三位有效数字。

## 5.误差的危害及处理

**危害一：损失有效数字**（很接近的数做减法时出现）

**例：**求解  $x^2 - 16x + 1 = 0$ ，很容易得到解

$$x_1 = 8 + \sqrt{63} \approx 15.9372539332 \cdots, \quad x_2 = 8 - \sqrt{63} \approx 0.0627460668 \cdots$$

计算机只能对有限数字进行运算，对于无理数只能采用近似值计算。采用**三位十进制**数计算，取  $\sqrt{63} \approx 7.94$ ，有三位有效数字。

(1) 若直接计算，则  $x_1 = 8 + \sqrt{63} \approx 15.9$ ， $x_2 = 8 - \sqrt{63} \approx 0.06$ ， $x_1$  有三位有效数字，而  $x_2$  只有一位有效数字。

## 5.误差的危害及处理

**危害一：损失有效数字**（很接近的数做减法时出现）

**例：**求解  $x^2 - 16x + 1 = 0$ ，很容易得到解

$$x_1 = 8 + \sqrt{63} \approx 15.9372539332 \cdots, \quad x_2 = 8 - \sqrt{63} \approx 0.0627460668 \cdots$$

计算机只能对有限数字进行运算，对于无理数只能采用近似值计算。采用**三位十进制**数计算，取  $\sqrt{63} \approx 7.94$ ，有三位有效数字。

(1) 若直接计算，则  $x_1 = 8 + \sqrt{63} \approx 15.9$ ， $x_2 = 8 - \sqrt{63} \approx 0.06$ ， $x_1$  有三位有效数字，而  $x_2$  只有一位有效数字。

(2) 若用  $x_2 = \frac{1}{x_1}$ ，则  $x_2 \approx 0.0629$ ，具有两位有效数字。

**计算原则：避免很接近的数字作减法运算**

## 危害二：大数“吃”小数（相差很大的数作加法时出现）

例：求用三位十进制有效数字计算

$$x = 101 + \delta_1 + \delta_2 + \cdots + \delta_{100}$$

其中  $\delta_i \in [0.1, 0.4]$ ,  $i = 1, 2, \cdots, 100$ 。

## 危害二：大数“吃”小数（相差很大的数作加法时出现）

例：求用三位十进制有效数字计算

$$x = 101 + \delta_1 + \delta_2 + \cdots + \delta_{100}$$

其中  $\delta_i \in [0.1, 0.4]$ ,  $i = 1, 2, \cdots, 100$ 。

(1) 若直接从左到右计算，则每次计算由于有效位数的限制，小数部分全部丢失（大数“吃”小数），最后得到  $x \approx 101$ 。

## 危害二：大数“吃”小数（相差很大的数作加法时出现）

例：求用三位十进制有效数字计算

$$x = 101 + \delta_1 + \delta_2 + \cdots + \delta_{100}$$

其中  $\delta_i \in [0.1, 0.4]$ ,  $i = 1, 2, \cdots, 100$ 。

(1) 若直接从左到右计算，则每次计算由于有效位数的限制，小数部分全部丢失（大数“吃”小数），最后得到  $x \approx 101$ 。

(2) 若先把小数部分全部加起来（此时小数部分之和在 $[10, 40]$ 之间），最后再加101，则可得到  $x \in [111, 141]$ ，相对要准确得多。

计算原则：避免相差很大的数字作加法运算

### 危害三：误差的放大（问题病态或采用不稳定方法时出现）

例：对于方程组

$$\begin{pmatrix} 1 & 0 \\ 0 & 10^{-16} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

此时得到精确解：  $x_1 = x_2 = 0$ 。

若方程的右端有了很小的扰动

$$\begin{pmatrix} 1 & 0 \\ 0 & 10^{-16} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 10^{-10} \\ 10^{-10} \end{pmatrix}$$

此时得到解：  $x_1 = 10^{-10}/1 \approx 0$ ,  $x_2 = 10^{-10}/10^{-16} = 10^6$ ！

计算原则：避免很小的数做分母（避免系统病态/ill-posed）

## 1.3 数值分析基础知识

### 1、线性空间与基的表达

**定义：**（线性空间）设  $X$  为一非空集合， $K$  为一数域（实数域  $\mathbb{R}$  或复数域  $\mathbb{C}$ ），若对于任意元素  $x, y \in X$  和数  $k, l \in K$ ，都有  $kx + ly \in X$ ，则称  $X$  为数域  $K$  上的线性空间。（对于加法和数乘封闭）

- (1)  $C^n[a, b] = \{f \mid f \text{ 为定义在 } [a, b] \text{ 上的具有 } n \text{ 阶连续导数的实值函数}\};$
- (2)  $P_n[a, b] = \{f \mid f \text{ 为定义在 } [a, b] \text{ 上的所有次数不超过 } n \text{ 的代数多项式}\};$
- (3)  $L^p[a, b] = \left\{ f(x) \mid \left[ \int_a^b |f(x)|^p dx \right]^{1/p} < +\infty, x \in [a, b] \right\};$
- (4)  $\mathbb{R}^n / \mathbb{C}^n = \left\{ x \mid x = (x_1, x_2, \dots, x_n)^T, x_i \in \mathbb{R} / \mathbb{C}, i = 1, 2, \dots, n \right\};$
- (5)  $\mathbb{R}^{n \times m} / \mathbb{C}^{n \times m} = \{A \mid A = (a_{ij})_{n \times m}, a_{ij} \in \mathbb{R} / \mathbb{C}, i = 1, 2, \dots, n, j = 1, 2, \dots, m\}$



设  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  为线性空间  $X$  的一组基，则对于任意  $\alpha \in X$ ，有

基的表示：
$$\alpha = k_1\varphi_1 + k_2\varphi_2 + \dots + k_d\varphi_d$$

其中  $k_1, k_2, \dots, k_d$  为表示系数，此时称  $X$  是由  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  张成的，记为

$$X = \text{span}\{\varphi_1, \varphi_2, \dots, \varphi_d\}$$

设  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  为线性空间  $X$  的一组基，则对于任意  $\alpha \in X$ ，有

基的表示：
$$\alpha = k_1\varphi_1 + k_2\varphi_2 + \dots + k_d\varphi_d$$

其中  $k_1, k_2, \dots, k_d$  为表示系数，此时称  $X$  是由  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  张成的，记为

$$X = \text{span}\{\varphi_1, \varphi_2, \dots, \varphi_d\}$$

例如， $P_n[a, b] = \text{span}\{1, x, x^2, \dots, x^n\}$ ，对任意  $p_n(x) \in P_n[a, b]$ ，有

$$p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0, \quad \forall x \in [a, b]$$

设  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  为线性空间  $X$  的一组基，则对于任意  $\alpha \in X$ ，有

基的表示：
$$\alpha = k_1\varphi_1 + k_2\varphi_2 + \dots + k_d\varphi_d$$

其中  $k_1, k_2, \dots, k_d$  为表示系数，此时称  $X$  是由  $\{\varphi_1, \varphi_2, \dots, \varphi_d\}$  张成的，记为

$$X = \text{span}\{\varphi_1, \varphi_2, \dots, \varphi_d\}$$

例如， $P_n[a, b] = \text{span}\{1, x, x^2, \dots, x^n\}$ ，对任意  $p_n(x) \in P_n[a, b]$ ，有

$$p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0, \quad \forall x \in [a, b]$$

注意：一个空间的基是不唯一的。

对于  $C_{m \times n} = A_{m \times l} B_{l \times n}$  (矩阵的分解, 对矩阵  $C$  进行分解),

$$[\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_n] = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l] \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & & \vdots \\ b_{l1} & b_{l2} & \cdots & b_{ln} \end{bmatrix}$$

因此,  $c_j = b_{1,j} \mathbf{a}_1 + b_{2,j} \mathbf{a}_2 + \cdots + b_{l,j} \mathbf{a}_l, \quad j = 1, 2, \dots, n$ 。

将  $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l\}$  看作子空间的“基”, 则  $c_j \in \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l\}$ 。

对于  $C_{m \times n} = A_{m \times l} B_{l \times n}$  (矩阵的分解, 对矩阵  $C$  进行分解),

$$[\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_n] = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l] \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & & \vdots \\ b_{l1} & b_{l2} & \cdots & b_{ln} \end{bmatrix}$$

因此,  $c_j = b_{1,j}\mathbf{a}_1 + b_{2,j}\mathbf{a}_2 + \cdots + b_{l,j}\mathbf{a}_l, \quad j = 1, 2, \dots, n$ 。

将  $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l\}$  看作子空间的“基”, 则  $c_j \in \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_l\}$ 。

需要指出的是, 在严格数学定义上, 构成“基”的向量组必须是线性无关的。但在实际工程问题中, 即使向量组中有部分向量线性相关, 由于不影响对元素的线性表示, 往往还是被称为基 (冗余基或冗余字典)。

如果矩阵  $A$  可以正交对角化, 即存在正交矩阵  $P$ , 使得

$$\begin{aligned} A &= P \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) P^T \\ &= [p_1, p_2, \cdots, p_n] \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) [p_1, p_2, \cdots, p_n]^T \\ &= \lambda_1 \cdot p_1 p_1^T + \lambda_2 \cdot p_2 p_2^T + \cdots + \lambda_n \cdot p_n p_n^T \end{aligned}$$

这里  $p_i p_i^T, i = 1, 2, \cdots, n$  都是由  $A$  的特征向量生成的秩 1 矩阵, 则  $A$  可看作是矩阵子空间  $\operatorname{span}\{p_1 p_1^T, p_2 p_2^T, \cdots, p_n p_n^T\}$  中的一个元素, 而表示系数则是对应的特征值。

如果矩阵  $A$  可以正交对角化, 即存在正交矩阵  $P$ , 使得

$$\begin{aligned} A &= P \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) P^T \\ &= [p_1, p_2, \cdots, p_n] \operatorname{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n) [p_1, p_2, \cdots, p_n]^T \\ &= \lambda_1 \cdot p_1 p_1^T + \lambda_2 \cdot p_2 p_2^T + \cdots + \lambda_n \cdot p_n p_n^T \end{aligned}$$

这里  $p_i p_i^T, i = 1, 2, \cdots, n$  都是由  $A$  的特征向量生成的秩 1 矩阵, 则  $A$  可看作是矩阵子空间  $\operatorname{span}\{p_1 p_1^T, p_2 p_2^T, \cdots, p_n p_n^T\}$  中的一个元素, 而表示系数则是对应的特征值。

若  $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ , 且对于  $k > K, K < n$  时  $\lambda_k$  “充分小”, 则

$$A \approx \tilde{A} = \lambda_1 \cdot p_1 p_1^T + \lambda_2 \cdot p_2 p_2^T + \cdots + \lambda_K \cdot p_K p_K^T$$

这种近似在当前的大数据降维中经常使用 ( $K \ll n$ )。

## 2、内积及其应用

**定义：（内积）** 设  $X$  是数域  $K$  上的线性空间，若存在映射  $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$  满足如下条件：

- (1) 对任意  $x \in X$ ，有  $(x, x) \geq 0$ ，当且仅当  $x = 0$  时等号成立；
- (2) 对任意  $x, y \in X$ ，有  $(x, y) = \overline{(y, x)}$ ；
- (3) 对任意  $x, y, z \in X$  和  $k, l \in K$ ，有  $(kx + ly, z) = k(x, z) + l(y, z)$ ；

则称映射  $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$  为线性空间  $X$  上的内积，定义了内积运算后的线性空间  $X$  称为内积空间。



## 内积的性质

$$(1) \quad (x, y) = \overline{(y, x)};$$

$$(2) \quad (\lambda x, y) = \lambda(x, y);$$

$$(3) \quad (x + y, z) = (x, z) + (y, z);$$

$$(4) \quad (x, x) \geq 0, \text{ 仅当 } x = 0 \text{ 时才有 } (x, x) = 0;$$

$$(5) \quad (x, y)(y, x) \leq (x, x)(y, y) \quad (\text{Cauchy-Schwarz 不等式}).$$

## 内积的性质

$$(1) (x, y) = \overline{(y, x)};$$

$$(2) (\lambda x, y) = \lambda(x, y);$$

$$(3) (x + y, z) = (x, z) + (y, z);$$

$$(4) (x, x) \geq 0, \text{ 仅当 } x = 0 \text{ 时才有 } (x, x) = 0;$$

$$(5) (x, y)(y, x) \leq (x, x)(y, y) \quad (\text{Cauchy-Schwarz 不等式}).$$

**注：**内积可以认为是线性空间中两个元素之间的“相关性”（方向的一致性）的一种度量（以  $x, y \in \mathbb{R}^n$  为例， $(x, y) = |x| \cdot |y| \cdot \cos(x, y)$ ）。

例如，利用内积最大可以对图像处理中的梯度场匹配问题建模。

➤ 数字图像可以表示为以**像素**为元素的**矩阵**

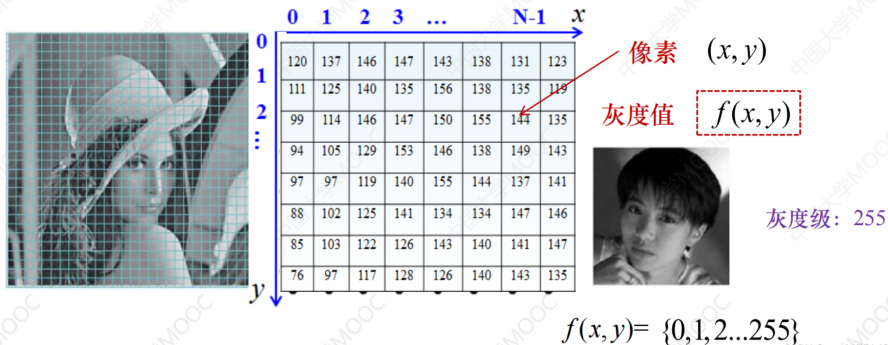


Figure: 图像在计算机中的表示，数字图像

常用的内积:

(1) 当  $X = \mathbb{C}^n$ , 则对任意  $x = (x_1, x_2, \dots, x_n)^T, y = (y_1, y_2, \dots, y_n)^T \in \mathbb{C}^n$

$$(x, y) = y^H x = \sum_{i=1}^n x_i \bar{y}_i, \quad (x, y)_w = \sum_{i=1}^n w_i \cdot x_i \bar{y}_i$$

其中  $w_i > 0, i = 1, 2, \dots, n$  为加权系数。

(2) 当  $X = L^2[a, b]$ , 则对于任意  $f, g \in L^2[a, b]$ , 有

$$(f, g) = \int_a^b f \cdot \bar{g} dx, \quad (f, g)_\rho = \int_a^b \rho(x) f(x) \bar{g}(x) dx,$$

其中  $\rho(x) \geq 0, x \in [a, b]$ , 且在任意子区间上  $\rho(x)$  不恒为零, 称  $\rho(x)$  为权函数。

**定义:** 设  $x \in \mathbb{C}^n$ , 非负实数  $\sqrt{(x, x)}$  称为向量  $x$  的长度, 通常称为**模**或者**范数**, 记为  $\|x\|$  或  $|x|$ 。若  $\|x\| = 1$ , 则称  $x$  为单位向量。

**定义:** 设  $x, y \in \mathbb{C}^n$ , 则

- (1) 若  $(x, y) = 0$ , 则称  $x$  与  $y$  **正交**, 记作  $x \perp y$ .
- (2) 若非零向量组  $x_1, \dots, x_m$  两两正交, 即当  $i \neq j$  时,  $(x_i, x_j) = 0$ , 当  $i = j$  时,  $(x_i, x_i) = c_i > 0$ , 则称该向量组为**正交向量组**。
- (3) 若正交向量组  $x_1, \dots, x_m$  还满足  $\|x_i\| = 1, i = 1, 2, \dots, m$ , 则称其为**标准正交向量组**。

**定义：** 设  $A \in \mathbb{C}^{n \times n}$ ，若有  $A^H A = A A^H = I$  或  $A^{-1} = A^H$ ，称  $A$  为酉矩阵（在实数意义下，就是正交矩阵）。

酉矩阵的性质：

- (1) 若  $A$  是酉矩阵，则  $A^{-1}, \bar{A}, A^T, A^H, A^k (k = 1, 2, \dots)$  也是酉矩阵。(定义验证)
- (2) 若  $A, B$  是酉矩阵，则  $AB$  也是酉矩阵。(定义验证)
- (3) 若  $A$  是酉矩阵，则  $|\det A| = 1$ 。
- (4)  $A$  是酉矩阵的充要条件是它的  $n$  个列（行）向量是标准正交向量组。
- (5)  $A$  是酉矩阵的充要条件是对任意  $x, y \in \mathbb{C}^n$ ，有  $(Ax, Ay) = (x, y)$ 。
- (6) 若  $A$  是酉矩阵， $\lambda$  为  $A$  的特征值，则  $|\lambda| = 1$ 。

### 3.范数及其应用

**定义：** 设  $X$  是数域  $K$  上的线性空间，若映射  $\|\cdot\| : X \rightarrow \mathbb{R}$  同时满足下列条件：

- (1) (**非负性**) 对任意  $x \in X$ ，有  $\|x\| \geq 0$ ，当且仅当  $x = 0$  时等号成立；
- (2) (**齐次性**) 对任意  $x \in X$  和任意  $\lambda \in K$ ，有  $\|\lambda x\| = |\lambda| \cdot \|x\|$ ；
- (3) (**三角不等式**) 对任意  $x, y \in X$ ，有  $\|x + y\| \leq \|x\| + \|y\|$ ；

则称  $\|\cdot\| : X \rightarrow \mathbb{R}$  为线性空间  $X$  上的一个**范数**，此时称  $(X, \|\cdot\|)$  为**赋范线性空间**（简称  $X$  为赋范线性空间）。

### 3.范数及其应用

**定义：** 设  $X$  是数域  $K$  上的线性空间，若映射  $\|\cdot\|: X \rightarrow \mathbb{R}$  同时满足下列条件：

- (1) (**非负性**) 对任意  $x \in X$ ，有  $\|x\| \geq 0$ ，当且仅当  $x = 0$  时等号成立；
- (2) (**齐次性**) 对任意  $x \in X$  和任意  $\lambda \in K$ ，有  $\|\lambda x\| = |\lambda| \cdot \|x\|$ ；
- (3) (**三角不等式**) 对任意  $x, y \in X$ ，有  $\|x + y\| \leq \|x\| + \|y\|$ ；

则称  $\|\cdot\|: X \rightarrow \mathbb{R}$  为线性空间  $X$  上的一个**范数**，此时称  $(X, \|\cdot\|)$  为**赋范线性空间**（简称  $X$  为赋范线性空间）。

**注：** 范数可以**度量元素的大小**，是一种**距离**的定义，事实上  $\|x\| = \|x - 0\|$ ，即  $x$  到  $0$  的距离。因此前面误差的概念都可以在范数意义下重新定义，可以对  $x, y \in X$  之间的误差进行度量。



设  $(X, \|\cdot\|)$  是一个赋范线性空间, 如果对于  $X$  中的任一 Cauchy 序列  $\{x_n\}$  (即满足  $\|x_m - x_n\| \rightarrow 0$  ( $m, n \rightarrow +\infty$ ) 的序列), 必存在  $x \in X$ , 使得  $\|x_n - x\| \rightarrow 0$ , 则称  $(X, \|\cdot\|)$  为完备的赋范线性空间, 通常称为 Banach 空间。

设  $(X, \|\cdot\|)$  是一个赋范线性空间, 如果对于  $X$  中的任一 Cauchy 序列  $\{x_n\}$  (即满足  $\|x_m - x_n\| \rightarrow 0$  ( $m, n \rightarrow +\infty$ ) 的序列), 必存在  $x \in X$ , 使得  $\|x_n - x\| \rightarrow 0$ , 则称  $(X, \|\cdot\|)$  为完备的赋范线性空间, 通常称为 Banach 空间。

**注1:** 设  $X$  是一个内积空间, 则  $\|x\| = \sqrt{(x, x)}$  定义了  $X$  上的一种范数, 因此内积空间一定是赋范线性空间, 但反之未必;

设  $(X, \|\cdot\|)$  是一个赋范线性空间, 如果对于  $X$  中的任一 Cauchy 序列  $\{x_n\}$  (即满足  $\|x_m - x_n\| \rightarrow 0$  ( $m, n \rightarrow +\infty$ ) 的序列), 必存在  $x \in X$ , 使得  $\|x_n - x\| \rightarrow 0$ , 则称  $(X, \|\cdot\|)$  为**完备的赋范线性空间**, 通常称为 **Banach 空间**。

**注1:** 设  $X$  是一个内积空间, 则  $\|x\| = \sqrt{(x, x)}$  定义了  $X$  上的一种范数, 因此内积空间一定是赋范线性空间, 但反之未必;

**注2:** 若内积空间  $X$  在范数  $\|x\| = \sqrt{(x, x)}$  意义下是 Banach 空间, 则称  $X$  是一个**完备的内积空间**, 通常称为 **Hilbert 空间**;

设  $(X, \|\cdot\|)$  是一个赋范线性空间, 如果对于  $X$  中的任一 Cauchy 序列  $\{x_n\}$  (即满足  $\|x_m - x_n\| \rightarrow 0$  ( $m, n \rightarrow +\infty$ ) 的序列), 必存在  $x \in X$ , 使得  $\|x_n - x\| \rightarrow 0$ , 则称  $(X, \|\cdot\|)$  为**完备的赋范线性空间**, 通常称为 **Banach 空间**。

**注1:** 设  $X$  是一个内积空间, 则  $\|x\| = \sqrt{(x, x)}$  定义了  $X$  上的一种范数, 因此内积空间一定是赋范线性空间, 但反之未必;

**注2:** 若内积空间  $X$  在范数  $\|x\| = \sqrt{(x, x)}$  意义下是 Banach 空间, 则称  $X$  是一个**完备的内积空间**, 通常称为 **Hilbert 空间**;

**注3:** 对于  $L^p$  空间, 仅当  $p = 2$  时,  $L^p$  是 Hilbert 空间, 其余情况均为 Banach 空间。

常用的范数：

当  $X = C[a, b]$ ，对于任意  $f \in C[a, b]$ ，可定义连续意义下的范数：

$$(1) \|f\|_1 = \int_a^b |f(x)| dx \quad (1\text{范数})$$

$$(2) \|f\|_2 = \left( \int_a^b |f(x)|^2 dx \right)^{1/2} \quad (2\text{范数})$$

$$(3) \|f\|_\infty = \max_{x \in [a, b]} |f(x)| \quad (\infty\text{范数})$$

$$(4) \|f\|_p = \left( \int_a^b |f(x)|^p dx \right)^{1/p} \quad (1 \leq p < \infty) \quad (p\text{范数})$$

(可以证明:  $\lim_{p \rightarrow +\infty} \|f\|_p = \|f\|_\infty$ )

## 向量范数

当  $X = \mathbb{C}^n$ , 设  $x = (\xi_1, \xi_2, \dots, \xi_n)^T \in \mathbb{C}^n$ , 规定

$$(1) \|x\|_1 = \sum_{k=1}^n |\xi_k| \quad (1\text{范数})$$

$$(2) \|x\|_2 = \sqrt{\sum_{k=1}^n |\xi_k|^2} = \sqrt{x^H x} \quad (2\text{范数})$$

$$(3) \|x\|_\infty = \max_k |\xi_k| \quad (\infty\text{范数})$$

$$(4) \|x\|_p = \left( \sum_{k=1}^n |\xi_k|^p \right)^{1/p} \quad (1 \leq p < \infty)$$

( $p$ 范数)

(可以证明  $\lim_{p \rightarrow +\infty} \|x\|_p = \|x\|_\infty$ )

## 向量范数

当  $X = \mathbb{C}^n$ , 设  $x = (\xi_1, \xi_2, \dots, \xi_n)^T \in \mathbb{C}^n$ , 规定

$$(1) \|x\|_1 = \sum_{k=1}^n |\xi_k| \quad (1\text{范数})$$

$$(2) \|x\|_2 = \sqrt{\sum_{k=1}^n |\xi_k|^2} = \sqrt{x^H x} \quad (2\text{范数})$$

$$(3) \|x\|_\infty = \max_k |\xi_k| \quad (\infty\text{范数})$$

$$(4) \|x\|_p = \left( \sum_{k=1}^n |\xi_k|^p \right)^{1/p} \quad (1 \leq p < \infty)$$

( $p$ 范数)

(可以证明  $\lim_{p \rightarrow +\infty} \|x\|_p = \|x\|_\infty$ )




Figure:  $\|x\|_p$  意义下的单位圆

向量范数的基本性质:

(1) 任何向量范数都是  $\mathbb{C}^n$  上的连续函数  $\left( \lim_{\|\Delta x\| \rightarrow 0} \|x + \Delta x\| = \|x\| \right)$ 。

(2) 设  $\|\cdot\|_\alpha$  与  $\|\cdot\|_\beta$  是  $\mathbb{C}^n$  上的两个向量范数, 如存在  $a, b > 0$  使得

$$a\|x\|_\beta \leq \|x\|_\alpha \leq b\|x\|_\beta, \quad (\forall x \in \mathbb{C}^n)$$

则称向量范数  $\|\cdot\|_\alpha$  与  $\|\cdot\|_\beta$  等价。 $\mathbb{C}^n$  上的所有向量范数等价。

(3) 设  $A \in \mathbb{C}_n^{n \times n}$ ,  $\|\cdot\|_\alpha$  是  $\mathbb{C}^n$  上一个向量范数, 则  $\|x\|_\beta = \|Ax\|_\alpha$  也是  $\mathbb{C}^n$  上向量范数。

(4) 设  $A$  是  $n$  阶 Hermite 正定矩阵, 对任意  $x \in \mathbb{C}^n$ , 规定  $\|x\|_A = \sqrt{x^H A x}$ , 则  $\|x\|_A$  是一个向量范数 (椭圆范数)。



给定  $\mathbb{C}^n$  中的向量序列  $\{x^{(k)}\}$ , 其中  $x^{(k)} = (\xi_1^{(k)}, \dots, \xi_n^{(k)})^T$  ( $k = 1, 2, \dots$ ), 如果

$$\lim_{k \rightarrow \infty} \xi_j^{(k)} = \xi_j \quad (j = 1, 2, \dots, n)$$

则称向量序列  $\{x^{(k)}\}$  收敛于  $x = (\xi_1, \dots, \xi_n)^T$ , 简称  $\{x^{(k)}\}$  收敛, 记为

$$\lim_{k \rightarrow \infty} x^{(k)} = x \quad \text{或} \quad x^{(k)} \rightarrow x \quad (k \rightarrow +\infty)$$

不收敛的向量序列称为是发散的。

如果当  $k \rightarrow \infty$  时, 有  $\|x^{(k)} - x\| \rightarrow 0$ , 则称  $\{x^{(k)}\}$  依范数  $\|\cdot\|$  收敛于向量  $x \in \mathbb{C}^n$ 。简记为

$$x^{(k)} \xrightarrow{\|\cdot\|} x \quad (k \rightarrow \infty) \quad \text{或} \quad \lim_{k \rightarrow \infty} x^{(k)} = x \quad (\text{依范数 } \|\cdot\|)。$$

## 矩阵范数

**定义：** 如果  $\mathbb{C}^{n \times n}$  上的一个实函数  $\|\cdot\| : \mathbb{C}^{n \times n} \rightarrow \mathbb{R}$  满足以下条件：

- (1) (非负性)  $\|A\| \geq 0$ , 当且仅当  $A = \mathbf{0}$  时,  $\|A\| = 0$
- (2) (齐次性) 对  $\lambda \in \mathbb{C}$ ,  $\|\lambda A\| = |\lambda| \|A\|$
- (3) (三角不等式)  $\|A + B\| \leq \|A\| + \|B\|$
- (4) (相容性)  $\|AB\| \leq \|A\| \|B\|$

则称  $\|\cdot\|$  为是  $\mathbb{C}^{n \times n}$  上的一个矩阵范数, 而  $\|A\|$  为  $\mathbb{C}^{n \times n}$  上  $A$  的范数 (矩阵范数)。

常用的矩阵范数：设  $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$ ，规定

$$\|A\|_{m_1} = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| \quad (m_1 \text{ 范数})$$

$$\|A\|_{m_\infty} = \max_{i,j} |a_{ij}| \quad (m_\infty \text{ 范数})$$

$$\|A\|_F = \left( \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = \sqrt{\text{tr}(A^H A)} \quad (\text{Frobenius 范数, } F \text{ 范数})$$

F 范数的酉不变性：对酉矩阵  $U, V$ ，有

$$\|UA\|_F = \|AV\|_F = \|UAV\|_F = \|A\|_F$$

单位矩阵在矩阵乘法中的作用类似于 1 在数的乘法中的作用，但对于  $m_1$ -范数，F-范数和  $m_\infty$ -范数，有  $\|I_n\|_{m_1} = n$ ,  $\|I_n\|_F = \sqrt{n}$ ,  $\|I_n\|_{m_\infty} = n$ ，能否构造出使  $\|I_n\| = 1$  的范数呢？

单位矩阵在矩阵乘法中的作用类似于 1 在数的乘法中的作用，但对于  $m_1$ -范数，F-范数和  $m_\infty$ -范数，有  $\|I_n\|_{m_1} = n$ ,  $\|I_n\|_F = \sqrt{n}$ ,  $\|I_n\|_{m_\infty} = n$ ，能否构造出使  $\|I_n\| = 1$  的范数呢？

**定义：** 已知  $\mathbb{C}^n$  上的一个向量范数  $\|\cdot\|_v$ ，对  $A \in \mathbb{C}^{n \times n}$ ，规定

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v} \quad \left( = \max_{\|x\|_v=1} \|Ax\|_v \right)$$

则  $\|\cdot\|$  是  $\mathbb{C}^{n \times n}$  上与向量范数  $\|\cdot\|_v$  相容的矩阵范数，且满足  $\|I_n\| = 1$ ，称之为由向量范数  $\|\cdot\|_v$  诱导出的矩阵范数或从属于向量范数  $\|\cdot\|_v$  的矩阵范数，简称诱导范数、从属范数或算子范数。

由向量 1, 2,  $\infty$  范数导出的矩阵范数

$$(1) \|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|, \quad (\text{极大列和范数})$$

$$(2) \|A\|_2 = \sqrt{\lambda_1}, \quad \lambda_1 \text{ 为 } A^H A \text{ 或 } A A^H \text{ 的最大特征值 (谱范数, 2-范数)}$$

$$(3) \|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|, \quad (\text{极大行和范数})$$

矩阵2-范数的性质

- ① 酉不变性: 设  $U, V$  为酉矩阵, 则  $\|UA\|_2 = \|AV\|_2 = \|UAV\|_2 = \|A\|_2$
- ② 若  $A^H A = A A^H$ , 则称  $A$  为**正规矩阵**。

若  $A$  是正规矩阵, 且  $\lambda_1, \lambda_2, \dots, \lambda_n$  是  $A$  的  $n$  个特征值, 则

$$\|A\|_2 = \max_k |\lambda_k|$$

例：设  $U$  是酉矩阵， $A = \begin{pmatrix} -1 & i & 0 \\ -i & 0 & -i \\ 0 & i & -1 \end{pmatrix}$ ，试计算  $\max_{\|x\|_1=4} \|Ax\|_1$   
 $\max_{\|Ux\|_2=3} \|Ax\|_2$ .

例：设  $U$  是酉矩阵， $A = \begin{pmatrix} -1 & i & 0 \\ -i & 0 & -i \\ 0 & i & -1 \end{pmatrix}$ ，试计算  $\max_{\|x\|_1=4} \|Ax\|_1$   
 $\max_{\|Ux\|_2=3} \|Ax\|_2$ .

解：(1) 首先设  $x = 4y$ ，则

$$\max_{\|x\|_1=4} \|Ax\|_1 = 4 \cdot \max_{\|y\|_1=1} \|Ay\|_1 = 4\|A\|_1 = 8$$

(2) 设  $x = 3U^H y$ ，则

$$\max_{\|Ux\|_2=3} \|Ax\|_2 = \max_{\|y\|_2=1} 3\|AU^H y\|_2 = 3\|AU^H\|_2 = 3\|A\|_2.$$

而  $A$  是 Hermite 矩阵，其特征值为  $\lambda_1 = -2$ ， $\lambda_1 = -1$ ， $\lambda_1 = 1$ 。所以

$$\max_{\|Ux\|_2=3} \|Ax\|_2 = 3\|A\|_2 = 3|\lambda_1| = 6.$$



## 矩阵范数与向量范数的关系

**定义：（相容）** 对于  $\mathbb{C}^n$  上给定的一种向量范数  $\|x\|_v$  和  $\mathbb{C}^{n \times n}$  上给定的一种矩阵范数  $\|A\|_m$ ，如果

$$\|Ax\|_v \leq \|A\|_m \|x\|_v,$$

则称上述矩阵范数和向量范数是相容的。

**定理：**任何向量范数都存在与之相容的矩阵范数（算子范数），反之设  $\|\cdot\|_m$  是一个矩阵范数，则必存在与之相容的向量范数。

**证明：**对  $x \in \mathbb{C}^n$ ，记  $X = (x, x, \dots, x) \in \mathbb{C}^{n \times n}$ 。定义  $\mathbb{C}^n$  上函数  $\|x\|_v = \|X\|_m$ 。易证  $\|x\|_v$  是  $\mathbb{C}^n$  上的范数，并且对任意  $A \in \mathbb{C}^{n \times n}$ ，有

$$\|Ax\|_v = \|(Ax, Ax, \dots, Ax)\|_m = \|AX\|_m \leq \|A\|_m \|X\|_m = \|A\|_m \|x\|_v$$

例： 向量 1 范数与矩阵  $m_1$  范数相容。

例： 向量 1 范数与矩阵  $m_1$  范数相容。

证明： 设  $A = (a_{ij})_{n \times n}$ ,  $x = (\xi_1, \dots, \xi_n)^T$ , 则

$$\begin{aligned}\|Ax\|_1 &= \sum_{i=1}^n \left| \sum_{k=1}^n a_{ik} \xi_k \right| \leq \sum_{i=1}^n \left( \sum_{k=1}^n |a_{ik}| |\xi_k| \right) \\ &\leq \sum_{i=1}^n \left[ \left( \sum_{k=1}^n |a_{ik}| \right) \left( \sum_{k=1}^n |\xi_k| \right) \right] \\ &= \left( \sum_{i=1}^n \sum_{k=1}^n |a_{ik}| \right) \left( \sum_{k=1}^n |\xi_k| \right) \\ &= \|A\|_{m_1} \|x\|_1\end{aligned}$$

例： 向量2 范数与矩阵 $F$  范数相容。

例：向量2 范数与矩阵 $F$  范数相容。

$$\begin{aligned}\|Ax\|_2 &= \sqrt{\sum_{i=1}^n \left| \sum_{k=1}^n a_{ik} \xi_k \right|^2} \\ &\leq \sqrt{\sum_{i=1}^n \left( \sum_{k=1}^n |a_{ik}| |\xi_k| \right)^2} \\ &\leq \sqrt{\sum_{i=1}^n \left[ \left( \sum_{k=1}^n |a_{ik}|^2 \right) \left( \sum_{k=1}^n |\xi_k|^2 \right) \right]} \\ &= \|A\|_F \|x\|_2\end{aligned}$$

可证明：向量 1, 2,  $\infty$  范数均与矩阵  $m_\infty$  范数相容。

## 矩阵的谱半径

**定义：** 设  $A \in \mathbb{C}^{n \times n}$ ,  $\lambda_1, \lambda_2, \dots, \lambda_n$  为  $A$  的  $n$  个特征值, 称

$$\rho(A) = \max_j |\lambda_j|$$

为  $A$  的谱半径。

## 矩阵的谱半径

**定义：** 设  $A \in \mathbb{C}^{n \times n}$ ,  $\lambda_1, \lambda_2, \dots, \lambda_n$  为  $A$  的  $n$  个特征值, 称

$$\rho(A) = \max_j |\lambda_j|$$

为  $A$  的谱半径。

**注：**  $\rho(A)$  是  $\mathbb{C}^{n \times n}$  上的一个函数, 但它不是矩阵范数。

**例：** 设

$$A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}, E = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, F = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix},$$

则  $A \neq 0$ , 但  $\rho(A) = 0$ ; (不满足非负性条件)

$\rho(A + B) = 1 > 0 = \rho(A) + \rho(B)$ ; (不满足三角不等式)

$\rho(EF) = (1 + \sqrt{5})/2 > 1 = \rho(E)\rho(F)$ 。(不满足相容性)

**定理：** 设  $A \in \mathbb{C}^{n \times n}$ ，则  $\rho(A) \leq \|A\|$ .

**证明：** 设  $\lambda$  是  $A$  的特征值， $\|\cdot\|_v$  为  $\mathbb{C}^n$  上与  $\|\cdot\|$  相容的向量范数。

由  $Ax = \lambda x$  得

$$|\lambda| \|x\|_v = \|\lambda x\|_v = \|Ax\|_v \leq \|A\| \|x\|_v$$

由于  $\|x\|_v \neq 0$ ，从而  $|\lambda| \leq \|A\|$ ，故  $\rho(A) \leq \|A\|$

**注：** 设  $A \in \mathbb{C}^{n \times n}$ ，则

$$(1) \|A\|_2 \leq \max\{\|A\|_\infty, \|A\|_1\}$$

(2) 当  $A$  是正规矩阵时， $\rho(A) = \|A\|_2$ 。



**定理：** 设  $A \in \mathbb{C}^{n \times n}$ ，对任意  $\varepsilon > 0$ ，存在矩阵范数  $\|\cdot\|_m$  使

$$\|A\|_m \leq \rho(A) + \varepsilon$$

**定理：** 设  $A \in \mathbb{C}^{n \times n}$ ，对任意  $\varepsilon > 0$ ，存在矩阵范数  $\|\cdot\|_m$  使

$$\|A\|_m \leq \rho(A) + \varepsilon$$

**证明：** 设  $P \in \mathbb{C}_n^{n \times n}$  使得

$$P^{-1}AP = J = \begin{pmatrix} \lambda_1 & \delta_1 & & \\ & \lambda_2 & \ddots & \\ & & \ddots & \delta_{n-1} \\ & & & \lambda_n \end{pmatrix}, \quad \delta_i = 0 \text{ 或 } 1$$

令  $D = \text{diag}(1, \varepsilon, \varepsilon^2, \dots, \varepsilon^{n-1})$ ，则有

$$D^{-1}P^{-1}APD = D^{-1}JD = \begin{pmatrix} \lambda_1 & \varepsilon\delta_1 & & \\ & \lambda_2 & \ddots & \\ & & \ddots & \varepsilon\delta_{n-1} \\ & & & \lambda_n \end{pmatrix}$$

于是有  $\|D^{-1}P^{-1}APD\|_{\infty} \leq \max_j (|\lambda_j| + \varepsilon) = \rho(A) + \varepsilon$ .

规定

$$\|B\|_m = \|D^{-1}P^{-1}BPD\|_{\infty}, \quad B \in C^{n \times n}$$

则  $\|\cdot\|_m$  是  $C^{n \times n}$  上的一种矩阵范数且有

$$\|A\|_m = \|D^{-1}P^{-1}APD\|_{\infty} \leq \rho(A) + \varepsilon$$

## 扰动方程与矩阵的条件数

实际工程问题很多都归结于求解线性方程

$$Ax = b$$

而实际中，误差往往是不可避免的，因此需要研究下面的扰动方程组

$$(A + \delta A)(x + \delta x) = b + \delta b$$

其中  $\delta x$  是由系数矩阵的扰动  $\delta A$  和右端扰动  $\delta b$  引起的解的误差。

我们需要在有误差  $\delta A$  和  $\delta b$  的情况下，研究解的误差。

**引理：** 设  $P \in \mathbb{C}^{n \times n}$ ，若对  $\mathbb{C}^{n \times n}$  上的某一矩阵范数  $\|\cdot\|$  有  $\|P\| < 1$ ，则  $I - P$  可逆。

**证明：** 若  $(I - P)$  不可逆，则  $(I - P)x = 0$  有非零解  $x^{(0)}$ ，即有

$$(I - P)x^{(0)} = 0, \text{ 或 } x^{(0)} = Px^{(0)}.$$

设  $\|\cdot\|_v$  是  $C^n$  上与矩阵范数  $\|\cdot\|$  相容的向量范数，则

$$\|x^{(0)}\|_v = \|Px^{(0)}\|_v \leq \|P\| \|x^{(0)}\|_v$$

即有  $\|P\| \geq 1$ ，与条件矛盾。

**定理：** 设  $A \in \mathbb{C}_n^{n \times n}$ ,  $\delta A \in \mathbb{C}_n^{n \times n}$ ,  $b, \delta b \in \mathbb{C}^n$ 。若对  $\mathbb{C}_n^{n \times n}$  上某矩阵范数  $\|\cdot\|$  有  $\|A^{-1}\| \|\delta A\| < 1$ , 则

$$Ax = b \quad \text{与} \quad (A + \delta A)(x + \delta x) = b + \delta b$$

的解满足（相对误差）

$$\frac{\|\delta x\|_v}{\|x\|_v} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|_v}{\|b\|_v} \right)$$

其中  $\|\cdot\|_v$  是  $\mathbb{C}^n$  上与矩阵范数  $\|\cdot\|$  相容的向量范数。

**证明：** 首先， $A + \delta A = A(I + A^{-1}\delta A)$ ，根据引理  $A + \delta A$  可逆。

将  $(A + \delta A)(x + \delta x) = b + \delta b$  展开，得

$$A\delta x + (\delta A)x + (\delta A)\delta x = \delta b$$

$$\delta x = -A^{-1}(\delta A)x - A^{-1}(\delta A)\delta x + A^{-1}\delta b$$

$$\|\delta x\|_v \leq \|A^{-1}\| \|\delta A\| \|x\|_v + \|A^{-1}\| \|\delta A\| \|\delta x\|_v$$

$$+ \|A^{-1}\| \|\delta b\|_v$$

又  $\|b\|_v = \|Ax\|_v \leq \|A\| \|x\|_v$ ，得

$$\frac{\|\delta x\|_v}{\|x\|_v} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|_v}{\|b\|_v} \right)$$

**定义：** 设  $A \in \mathbb{C}_n^{n \times n}$ ,  $\|\cdot\|$  是  $\mathbb{C}^{n \times n}$  上的矩阵范数, 称

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

为矩阵  $A$  的条件数。

如果方程组系数矩阵条件数大, 称该方程组是病态的。

常用的矩阵条件数:

- (a)  $\text{cond}_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty$ ;
- (b)  $\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\mu_1}{\mu_n}}$ , 其中  $\mu_1, \mu_n$  分别为  $A^H A$  的最大与最小特征值;
- (c) 当  $A$  为正规矩阵时,  $\text{cond}_2(A) = \left| \frac{\lambda_1}{\lambda_n} \right|$ , 其中  $\lambda_1, \lambda_n$  分别是  $A$  的按模最大和最小特征值。



例： 设

$$A = \begin{pmatrix} -1 & i & 0 \\ -i & 0 & -i \\ 0 & i & -1 \end{pmatrix}, \delta(A) \in \mathbb{C}^{3 \times 3}, 0 \neq b \in \mathbb{C}^3.$$

为使  $Ax = b$  的解  $x$  与  $(A + \delta(A))x = b$  的解  $\hat{x}$  的相对误差  $\frac{\|\hat{x} - x\|_2}{\|x\|_2} \leq 10^{-4}$ , 问  $\frac{\|\delta(A)\|_2}{\|A\|_2}$  应满足什么条件 (不超过何值) ?

解： 因为  $|\lambda I - A| = (\lambda + 1)(\lambda - 1)(\lambda + 2)$ ，所以

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = 2$$

从而

$$\frac{\|\hat{x} - x\|_2}{\|x\|_2} \leq \frac{\text{cond}_2(A)}{1 - \text{cond}_2(A) \frac{\|\delta A\|_2}{\|A\|_2}} \frac{\|\delta A\|_2}{\|A\|_2} \leq 10^{-4},$$

$$\frac{2}{1 - 2 \frac{\|\delta A\|_2}{\|A\|_2}} \frac{\|\delta A\|_2}{\|A\|_2} \leq 10^{-4},$$

从而得到

$$\frac{\|\delta A\|_2}{\|A\|_2} \leq \frac{1}{2.0002} \times 10^{-4} \leq \frac{1}{2} \times 10^{-4} = 5 \times 10^{-5}.$$