

## 第三章 线性方程组的迭代解法

### 数值分析

南京理工大学数统学院

### 3.1 迭代法的基本概念

### 3.2 Jacobi 迭代法和Gauss-Seidel 迭代法

### 3.3 超松驰迭代法(SOR)

### 3.4 求解线性方程组的极小化方法

#### 3.4.1 变分原理与最速下降法

#### 3.4.2 共轭梯度法

#### 3.4.3 预处理共轭梯度法

### 3.1 迭代法的基本概念

设  $A \in \mathbb{R}^{n \times n}$ ,  $b \in \mathbb{R}^n$ , 考虑线性方程组  $Ax = b$ ,

设  $A$  非奇异, 将  $A$  分裂为  $A = M - N$ , 其中  $M$  为非奇异矩阵, 则有

$$x = M^{-1}Nx + M^{-1}b.$$

令  $B = M^{-1}N = I - M^{-1}A$ ,  $f = M^{-1}b$ ,

得到与  $Ax = b$  等价(同解)的方程组

$$x = Bx + f. \quad (1.1)$$

由此可以构造方程组的单步定常迭代法:

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, \dots, \quad (1.2)$$

其中 $B$ 为迭代矩阵, 给定初始向量 $x^{(0)} \in \mathbb{R}^n$ , 按(1.2) 可产生向量序列 $\{x^{(k)}\}$ .

其中 $B$ 为迭代矩阵, 给定初始向量 $x^{(0)} \in \mathbb{R}^n$ , 按(1.2) 可产生向量序列 $\{x^{(k)}\}$ .

**定义:** 若存在向量 $x^* \in \mathbb{R}^n$ , 对任意 $x^{(0)} \in \mathbb{R}^n$ , 由迭代法(1.2)产生的向量序列 $\{x^{(k)}\}$  满足

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*,$$

则称迭代法(1.2)是收敛的.

若迭代法收敛, 则 $x^*$ 是方程组(1.1)的解, 从而是方程组 $Ax = b$ 的解.

记第 $k$ 次迭代的误差向量为

$$\boldsymbol{e}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^*, \quad k = 0, 1, 2, \dots, \quad (1.3)$$

于是有

$$\boldsymbol{e}^{(k)} = \boldsymbol{B}\boldsymbol{e}^{(k-1)} = \dots = \boldsymbol{B}^k\boldsymbol{e}^{(0)}, \quad \boldsymbol{e}^{(0)} = \boldsymbol{x}^{(0)} - \boldsymbol{x}^*.$$

记第 $k$ 次迭代的误差向量为

$$\boldsymbol{e}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^*, \quad k = 0, 1, 2, \dots, \quad (1.3)$$

于是有

$$\boldsymbol{e}^{(k)} = \boldsymbol{B}\boldsymbol{e}^{(k-1)} = \dots = \boldsymbol{B}^k\boldsymbol{e}^{(0)}, \quad \boldsymbol{e}^{(0)} = \boldsymbol{x}^{(0)} - \boldsymbol{x}^*.$$

**定理:** 迭代法 $\boldsymbol{x}^{(k+1)} = \boldsymbol{B}\boldsymbol{x}^{(k)} + \boldsymbol{f}$ ,  $k = 0, 1, \dots$ , 收敛的充要条件:

(i)  $\lim_{k \rightarrow \infty} \boldsymbol{B}^k = \mathbf{0}$ ,

(ii)  $\rho(\boldsymbol{B}) < 1$ ,

(iii) 至少存在一种矩阵从属范数 $\|\cdot\|$ , 使 $\|\boldsymbol{B}\| < 1$ .

**定理(迭代法误差估计):** 设  $x^*$  是方程  $x = Bx + f$  的唯一解,  $\|B\| < 1$ , 则由 (1.2) 产生的向量序列  $x^{(k)}$  满足

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|; \quad (1.4)$$

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|^k}{1 - \|B\|} (\|f\| + 2\|x^{(0)}\|). \quad (1.5)$$

**注:** 利用(1.5) 可估计迭代法需要的迭代次数, 若要  $\|x^{(k)} - x^*\| \leq \varepsilon$ , 只要

$$\frac{\|B\|^k}{1 - \|B\|} (\|f\| + 2\|x^{(0)}\|) \leq \varepsilon, \text{ 即 } k \geq \ln \left( \frac{\varepsilon(1 - \|B\|)}{\|f\| + 2\|x^{(0)}\|} \right) / \ln \|B\|.$$



## 迭代法收敛速度:

设迭代法(1.2)收敛, 即 $\rho(B) < 1$ , 第 $k$ 次迭代的误差向量 $e^{(k)}$ 满足( $e^{(0)} \neq 0$ )

$$\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \leq \|B^k\|,$$

根据矩阵算子范数定义

$$\|B^k\| = \max_{e^{(0)} \neq 0} \frac{\|B^k e^{(0)}\|}{\|e^{(0)}\|} = \max_{e^{(0)} \neq 0} \frac{\|e^{(k)}\|}{\|e^{(0)}\|}.$$

因此, 迭代 $k$ 次后, 平均每次迭代误差向量范数的压缩率可以看成 $\|B^k\|^{\frac{1}{k}}$ .

若要求迭代 $k$ 次后有 $\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \leq \epsilon$ ,  $\epsilon \leq 10^{-s} \ll 1$ ,

只要满足 $\|B^k\| \leq \epsilon$ 即可, 即 $\|B^k\|^{\frac{1}{k}} \leq \epsilon^{\frac{1}{k}}$ ,

取对数得 $\ln \|B^k\|^{\frac{1}{k}} \leq \frac{1}{k} \ln \epsilon$ , 即  $k \geq \frac{-\ln \epsilon}{-\ln \|B^k\|^{\frac{1}{k}}}$ .

定义(平均收敛率):  $R_k(B) = -\ln \|B^k\|^{\frac{1}{k}}$ 为迭代法(1.2)的平均收敛率.

定义(渐近收敛率):  $R(B) = -\ln \rho(B)$ 称为迭代法(1.2)的渐近收敛率或渐近收敛速度.

可用 $k \geq \frac{-\ln \epsilon}{R(B)}$ 作为所需迭代次数的估计.

## 3.2 Jacobi 迭代法和 Gauss-Seidel 迭代法

考虑非奇异线性方程组  $Ax = b$ ,  $a_{ii} \neq 0$ , 将  $A$  分裂为

$$A = D - L - U,$$

其中  $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$  可逆,

$$L = - \begin{pmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & \ddots & \ddots & \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & 0 \end{pmatrix}, \quad U = - \begin{pmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n-1,n} \\ & & & & 0 \end{pmatrix}$$

在迭代矩阵  $B = I - M^{-1}A$  中取  $M = D$ , 得迭代格式:

$$\begin{aligned} \boldsymbol{x}^{(k+1)} &= (\boldsymbol{I} - \boldsymbol{D}^{-1}\boldsymbol{A}) \boldsymbol{x}^{(k)} + \boldsymbol{D}^{-1}\boldsymbol{b}, \\ &= \boldsymbol{D}^{-1}(\boldsymbol{L} + \boldsymbol{U}) \boldsymbol{x}^{(k)} + \boldsymbol{D}^{-1}\boldsymbol{b}. \end{aligned}$$

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{B}_J \boldsymbol{x}^{(k)} + \boldsymbol{f}_J, \quad \boldsymbol{B}_J = \boldsymbol{D}^{-1}(\boldsymbol{L} + \boldsymbol{U}), \quad \boldsymbol{f}_J = \boldsymbol{D}^{-1}\boldsymbol{b}. \quad (2.1)$$

称为Jacobi迭代法, 简称J法.

在迭代矩阵  $B = I - M^{-1}A$  中取  $M = D$ , 得迭代格式:

$$\begin{aligned} \boldsymbol{x}^{(k+1)} &= (\boldsymbol{I} - \boldsymbol{D}^{-1}\boldsymbol{A}) \boldsymbol{x}^{(k)} + \boldsymbol{D}^{-1}\boldsymbol{b}, \\ &= \boldsymbol{D}^{-1}(\boldsymbol{L} + \boldsymbol{U}) \boldsymbol{x}^{(k)} + \boldsymbol{D}^{-1}\boldsymbol{b}. \end{aligned}$$

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{B}_J \boldsymbol{x}^{(k)} + \boldsymbol{f}_J, \quad \boldsymbol{B}_J = \boldsymbol{D}^{-1}(\boldsymbol{L} + \boldsymbol{U}), \quad \boldsymbol{f}_J = \boldsymbol{D}^{-1}\boldsymbol{b}. \quad (2.1)$$

称为Jacobi迭代法, 简称J法.

Jacobi迭代的分量形式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right), \quad (2.2)$$

将(2.2)中右端 $x_j^{(k)}, j = 1, \dots, i-1$  用 $x_j^{(k+1)}$ 替换, 可构造迭代格式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad (2.3)$$

将(2.2)中右端 $x_j^{(k)}, j = 1, \dots, i-1$  用 $x_j^{(k+1)}$ 替换, 可构造迭代格式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad (2.3)$$

其矩阵形式:

$$\begin{aligned} (\mathbf{D} - \mathbf{L}) \mathbf{x}^{(k+1)} &= \mathbf{b} + \mathbf{U} \mathbf{x}^{(k)}, \\ \mathbf{x}^{(k+1)} &= \mathbf{B}_G \mathbf{x}^{(k)} + \mathbf{f}_G, \quad \mathbf{B}_G = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{U}, \quad \mathbf{f}_G = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{b}. \end{aligned} \quad (2.4)$$

称为Gauss-Seidel迭代法, 简称GS法.

例: 设初始向量  $\mathbf{x}^{(0)} = (0, 0, 0)^T$ , 用 Jacobi 迭代法求解方程组

$$\begin{cases} x_1 + 2x_2 - 2x_3 = 1 \\ x_1 + x_2 + x_3 = 3 \\ 2x_1 + 2x_2 + x_3 = 5 \end{cases}$$

解: Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = 1 - 2x_2^{(k)} + 2x_3^{(k)}, \\ x_2^{(k+1)} = 3 - x_1^{(k)} - x_3^{(k)}, \\ x_3^{(k+1)} = 5 - 2x_1^{(k)} - 2x_2^{(k)}, \end{cases}$$

可得  $\mathbf{x}^{(1)} = (1, 3, 5)^T$ ,  $\mathbf{x}^{(2)} = (5, -3, -3)^T$ ,  $\mathbf{x}^{(3)} = (1, 1, 1)^T$ ,  $\mathbf{x}^{(4)} = (1, 1, 1)^T$ , 所以方程组的解为  $\mathbf{x} = (1, 1, 1)^T$ .



例: 设初始向量  $\mathbf{x}^{(0)} = (0, 0, 0)^T$ , 用 Gauss-Seidel 迭代法求解方程组

$$\begin{cases} 9x_1 - x_2 - x_3 = 7 \\ -x_1 + 8x_2 = 7 \\ -x_1 + 9x_3 = 8 \end{cases}$$

解: Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = \frac{1}{9}(7 + x_2^{(k)} + x_3^{(k)}) \\ x_2^{(k+1)} = \frac{1}{8}(7 + x_1^{(k+1)}) \\ x_3^{(k+1)} = \frac{1}{9}(8 + x_1^{(k+1)}) \end{cases}$$

可得,  $\mathbf{x}^{(1)} = (0.7778, 0.9722, 0.9753)^T$ ,  $\mathbf{x}^{(2)} = (0.9942, 0.9993, 0.9994)^T$ ,

$\mathbf{x}^{(3)} = (0.9999, 0.9999, 0.9999)^T$ ,  $\mathbf{x}^{(4)} = (1, 1, 1)^T$ ,  $\mathbf{x}^{(5)} = (1, 1, 1)^T$ 。

所以方程组的解为  $\mathbf{x} = (1, 1, 1)^T$ 。

无论是 J 迭代法还是 G-S 迭代法, 它们收敛的充要条件都是迭代矩阵谱半径小于 1.

例: 分析求解  $Ax = b$  的 J 迭代法和 G-S 迭代法收敛性, 其中

$$A = \begin{pmatrix} 1 & -2 & 2 \\ -1 & 1 & -1 \\ -2 & -2 & 1 \end{pmatrix}.$$

解: 由  $B_J = D^{-1}(L + U)$ , 所以  $B_J$  的特征方程为

$$\begin{aligned}\det(\lambda \mathbf{I} - \mathbf{B}_J) &= \det[\lambda \mathbf{I} - \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})] \\ &= \det(\mathbf{D}^{-1}) \det[\lambda \mathbf{D} - (\mathbf{L} + \mathbf{U})] = 0,\end{aligned}$$

等价于  $\det[\lambda \mathbf{D} - (\mathbf{L} + \mathbf{U})] = 0$ , 即

$$\begin{vmatrix} \lambda & -2 & 2 \\ -1 & \lambda & -1 \\ -2 & -2 & \lambda \end{vmatrix} = 0.$$

求解得到  $\lambda_1 = \lambda_2 = \lambda_3 = 0$ , 因此  $\rho(\mathbf{B}_J) = 0 < 1$ , 因此 J 迭代法收敛。

由  $B_G = (D - L)^{-1}U$ , 所以  $B_G$  的特征方程为

$$\begin{aligned}\det(\lambda I - B_G) &= \det[\lambda I - (D - L)^{-1}U] \\ &= \det[(D - L)^{-1}] \det[\lambda(D - L) - U] = 0,\end{aligned}$$

等价于  $\det[\lambda(D - L) - U] = 0$ , 即

$$\begin{vmatrix} \lambda & -2 & 2 \\ -\lambda & \lambda & -1 \\ -2\lambda & -2\lambda & \lambda \end{vmatrix} = 0.$$

解得特征值为  $\lambda_1 = 0$ ,  $\lambda_2 = 2(\sqrt{2} - 1)$ ,  $\lambda_3 = 2(\sqrt{2} + 1)$ , 因此谱半径  $\rho(B_G) = 2(\sqrt{2} + 1) > 1$ , 因此 G-S 迭代法发散.

需要注意的是, J 迭代法和 G-S 迭代法之间并无包含关系.

如设方程组的系数矩阵分别为

$$\mathbf{A}_1 = \begin{pmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{pmatrix}, \quad \mathbf{A}_2 = \begin{pmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix},$$

可验证:  $\mathbf{A}_1$  对 J 迭代法是收敛的, 但 G-S 迭代法不收敛; 而  $\mathbf{A}_2$  对 J 迭代法不收敛, 但 G-S 迭代法收敛.

**定义:** 设  $A = (a_{ij}) \in R^{n \times n}$ , 若**不存在**置换矩阵  $P$ , 使得

$$P^T A P = \begin{pmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{pmatrix} \quad (2.5)$$

其中  $\tilde{A}_{11}$  与  $\tilde{A}_{22}$  均为方阵, 则称  $A$  为**不可约矩阵**.

**定理:** 若  $A = (a_{ij})$  严格对角占优或不可约弱对角占优, 则对  $i = 1, 2, \dots, n$ , 有  $a_{ii} \neq 0$ , 且  $A$  非奇异.

**定理:** 若系数矩阵  $A$  严格对角占优或不可约弱对角占优矩阵, 则 Jacobi 迭代法和 G-S 迭代法收敛.

**证明:** 若  $A$  严格对角占优, 则  $|a_{ii}| > 0$ , 因此  $D$  可逆. 现假设 Jacobi 迭代矩阵  $B_J$  的某个特征值  $|\lambda| \geq 1$ , 那么矩阵  $\lambda D - L - U$  也是严格对角占优的, 因此  $\lambda D - L - U$  非奇异.

再由

$$\lambda I - B_J = \lambda I - D^{-1}(L + U) = D^{-1}(\lambda D - L - U)$$

可知  $\lambda I - B_J$  非奇异, 这与  $\lambda$  是  $B_J$  的特征值矛盾.

故  $B_J$  的特征值的模均小于 1, 即 Jacobi 迭代法收敛.

**定理:** 设  $A$  具有正对角元且为对称矩阵, 则 Jacobi 方法收敛的充分必要条件是  $A$  和  $2D - A$  同为正定矩阵.

**定理:** 若系数矩阵  $A$  是对称正定阵, 则 G-S 迭代法收敛.

**定理:** 设系数矩阵  $A$  对称、非奇异, 且对角元素  $a_{ii} > 0$ , 若方程组  $Ax = b$  的 G-S 迭代法收敛, 则  $A$  正定.



**定理:** 设  $A$  具有正对角元且为对称矩阵, 则 Jacobi 方法收敛的充分必要条件是  $A$  和  $2D - A$  同为正定矩阵.

**定理:** 若系数矩阵  $A$  是对称正定阵, 则 G-S 迭代法收敛.

**定理:** 设系数矩阵  $A$  对称、非奇异, 且对角元素  $a_{ii} > 0$ , 若方程组  $Ax = b$  的 G-S 迭代法收敛, 则  $A$  正定.

**例:** 分析方程组  $Ax = b$  的 J 迭代法和 G-S 迭代法收敛性, 其中

$$A = \begin{pmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{pmatrix}.$$

### 3.3 超松弛迭代(SOR)法

在 G-S 迭代格式中

$$\tilde{x}^{(k+1)} = D^{-1}Lx^{(k+1)} + D^{-1}Ux^{(k)} + D^{-1}b,$$

取

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega\tilde{x}^{(k+1)},$$

便得到逐次超松弛迭代法，简记为 SOR 法，其计算式

$$x^{(k+1)} = x^{(k)} + \omega D^{-1}[Lx^{(k+1)} + (U - D)x^{(k)} + b],$$

SOR法也是线性迭代（ $\omega$ 称为松弛因子）

$$x^{(k+1)} = B_{\omega}x^{(k)} + f_{\omega},$$

$$B_{\omega} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U], \quad f_{\omega} = \omega(D - \omega L)^{-1}b.$$

## SOR法的分量形式

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right).$$

**定理:** 在矩阵  $A$  是实对称正定矩阵的条件下, SOR 法收敛的充要条件是  $0 < \omega < 2$ .

**定理:** 若矩阵  $A$  为严格对角占优或不可约弱对角占优矩阵, 则当  $0 < \omega \leq 1$  时, SOR 法收敛.

例: 用SOR 法求解方程组

$$\begin{cases} 4x_1 - x_2 = 1 \\ -x_1 + 4x_2 - x_3 = 4 \\ -x_2 + 4x_3 = -3 \end{cases}$$

分别取  $\omega = 1.03$ ,  $\omega = 1$ ,  $\omega = 1.1$ , 并对每个  $\omega$  确定迭代次数, 要求当  $\|\mathbf{x}^* - \mathbf{x}^{(k)}\|_{\infty} \leq 5 \times 10^{-6}$  时迭代终止, 其中精确解  $\mathbf{x}^* = (\frac{1}{2}, 1, -\frac{1}{2})^T$ .

解: SOR 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 - \omega)x_1^{(k)} + \frac{\omega}{4}(1 + x_2^{(k)}) \\ x_2^{(k+1)} = (1 - \omega)x_2^{(k)} + \frac{\omega}{4}(4 + x_1^{(k+1)} + x_3^{(k)}) \\ x_3^{(k+1)} = (1 - \omega)x_3^{(k)} + \frac{\omega}{4}(-3 + x_2^{(k+1)}) \end{cases}$$

取初始向量  $\mathbf{x}^{(0)} = (0, 0, 0)^T$ , 当  $\omega = 1.03$  时, 迭代 5 次达到要求,

$$\mathbf{x}^{(5)} = (0.50000043, 1.0000001, -0.499999)^T,$$

当  $\omega = 1$  时, 迭代 6 次达到要求,

$$\mathbf{x}^{(6)} = (0.50000038, 1.0000002, -0.4999995)^T,$$

当  $\omega = 1.1$  时, 迭代 6 次达到要求,

$$\mathbf{x}^{(6)} = (0.50000035, 0.9999989, -0.5000003)^T.$$

## 3.4 求解线性方程组的极小化方法

### 3.4.1 变分原理与最速下降法

考虑方程组  $Ax = b$ ,

其中  $A$  为  $n$  阶对称正定阵,  $b \in R^n$  为一给定向量.

定义二次函数:  $\varphi(x): R^n \rightarrow R$  如下

$$\begin{aligned}\varphi(x) &= \frac{1}{2}(Ax, x) - (b, x) \\ &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{j=1}^n b_j x_j.\end{aligned}$$

## 1. $\varphi(\mathbf{x})$ 的性质

(1).  $\forall \mathbf{x} \in R^n, \nabla \varphi(\mathbf{x}) = \text{grad} \varphi(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}.$

(2).  $\forall \mathbf{x}, \mathbf{y} \in R^n, \lambda \in R,$  有:

$$\begin{aligned}\varphi(\mathbf{x} + \lambda \mathbf{y}) &= \frac{1}{2} (\mathbf{A}(\mathbf{x} + \lambda \mathbf{y}), \mathbf{x} + \lambda \mathbf{y}) - (\mathbf{b}, \mathbf{x} + \lambda \mathbf{y}) \\ &= \frac{1}{2} (\mathbf{Ax}, \mathbf{x}) + \lambda (\mathbf{Ax}, \mathbf{y}) + \frac{\lambda^2}{2} (\mathbf{Ay}, \mathbf{y}) - (\mathbf{b}, \mathbf{x}) - \lambda (\mathbf{b}, \mathbf{y}) \\ &= \frac{\lambda^2}{2} (\mathbf{Ay}, \mathbf{y}) + \lambda (\mathbf{Ax} - \mathbf{b}, \mathbf{y}) + \frac{1}{2} (\mathbf{Ax}, \mathbf{x}) - (\mathbf{b}, \mathbf{x}) \\ &= \frac{\lambda^2}{2} (\mathbf{Ay}, \mathbf{y}) + \lambda (\mathbf{Ax} - \mathbf{b}, \mathbf{y}) + \varphi(\mathbf{x}).\end{aligned}$$

(3). 设  $Ax^* = b$ , 则  $\varphi(x^*) = \frac{1}{2}(Ax^*, x^*) - (b, x^*) = -\frac{1}{2}(Ax^*, x^*)$ ,

因此:

$$\begin{aligned}\varphi(x) - \varphi(x^*) &= \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}(Ax^*, x^*) \\ &= \frac{1}{2}(Ax, x) - (Ax^*, x) + \frac{1}{2}(Ax^*, x^*) \\ &= \frac{1}{2}(A(x - x^*), x - x^*).\end{aligned}$$



## 2. 求解线性方程组的变分原理

**定理:** 设  $A \in R^n$ ,  $A$  对称正定, 则:

$$Ax^* = b \Leftrightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x).$$

## 2. 求解线性方程组的变分原理

**定理:** 设  $A \in R^n$ ,  $A$  对称正定, 则:

$$Ax^* = b \Leftrightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x).$$

**证明:**  $\forall \lambda \in R, x, y \in R^n$ , 有:

$$\varphi(x + \lambda y) = \frac{\lambda^2}{2}(Ay, y) + \lambda(Ax - b, y) + \varphi(x)$$

$(\Rightarrow)$  若  $Ax^* = b$ , 则

$$\begin{aligned}\varphi(x) &= \varphi(x^* + (x - x^*)) \\ &= \frac{1}{2}(A(x - x^*), (x - x^*)) + \varphi(x^*),\end{aligned}$$

由  $A$  的正定性和  $x$  的任意性知,  $\varphi(x^*) = \min_{x \in R^n} \varphi(x)$ .

( $\Leftarrow$ ) 若  $\varphi(\mathbf{x}^*) = \min_{\mathbf{x} \in R^n} \varphi(\mathbf{x})$ , 则对任意  $\mathbf{y} \in R^n$ ,  $\left. \frac{d\varphi(\mathbf{x}^* + \lambda \mathbf{y})}{d\lambda} \right|_{\lambda=0} = 0$ ,

即  $(A\mathbf{x}^* - \mathbf{b}, \mathbf{y}) = 0$ , 由  $\mathbf{y}$  的任意性, 知  $A\mathbf{x}^* = \mathbf{b}$ .

### 3. 求解 $\varphi(x)$ 的极小值 $\varphi(x^*)$

“盲人下山”:

首先, 任意给定一个初始向量 $x^{(0)}$ , 确定一个下山方向 $p^{(0)}$ , 沿着经过点 $x^{(0)}$  而方向为 $p^{(0)}$  的直线 $x = x^{(0)} + \alpha p^{(0)}$ , 找一个点 $x^{(1)} = x^{(0)} + \alpha_0 p^{(0)}$ , 使得:

$$\varphi(x^{(1)}) = \min_{\alpha \in R} \varphi(x^{(0)} + \alpha p^{(0)}).$$

然后, 从 $x^{(1)}$  出发, 再确定一个下山方向 $p^{(1)}$ , 沿直线 $x = x^{(1)} + \alpha p^{(1)}$  找一个点 $x^{(2)} = x^{(1)} + \alpha_1 p^{(1)}$ , 使得:

$$\varphi(x^{(2)}) = \min_{\alpha \in R} \varphi(x^{(1)} + \alpha p^{(1)}).$$

如此继续下去, 得到一串:

$$\alpha_0, \alpha_1, \cdots, \alpha_k, \cdots \text{ 和 } \boldsymbol{p}^{(0)}, \boldsymbol{p}^{(1)}, \cdots, \boldsymbol{p}^{(k)}, \cdots,$$

称 $\boldsymbol{p}^{(k)}$ 为搜索方向,  $\alpha_k$ 为步长.

一般做法: 在 $\boldsymbol{x}^{(k)}$ 点, 先找下山方向 $\boldsymbol{p}^{(k)}$ , 再确定步长 $\alpha_k$ , 使得:

$$\varphi(\boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{p}^{(k)}) = \min_{\alpha \in R} \varphi(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{p}^{(k)}).$$

对于不同的选择下山(搜索)方向的方法, 就形成不同的算法.

# (1). 如何确定步长 $\alpha_k$

设从 $x^{(k)}$  出发, 已选定下山方向 $p^{(k)}$ , 要在直线 $x = x^{(k)} + \alpha p^{(k)}$  上确定最小值点.

# (1). 如何确定步长 $\alpha_k$

设从 $\mathbf{x}^{(k)}$  出发, 已选定下山方向 $\mathbf{p}^{(k)}$ , 要在直线 $\mathbf{x} = \mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}$  上确定最小值点.

令:  $f(\alpha) = \varphi(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$ , 于是:

$$\begin{aligned} f(\alpha) &= \frac{1}{2} (\mathbf{A}(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}), (\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})) - (\mathbf{b}, \mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}) \\ &= \frac{1}{2} \alpha^2 \mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)} - \alpha (\mathbf{b} - \mathbf{A} \mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + \varphi(\mathbf{x}^{(k)}) \\ &= \frac{1}{2} \alpha^2 \mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)} - \alpha \mathbf{r}^{(k)T} \mathbf{p}^{(k)} + \varphi(\mathbf{x}^{(k)}). \end{aligned}$$

其中  $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k)}$  为残量.

由极值必要条件:  $\frac{df}{d\alpha} = \alpha \mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)} - \mathbf{r}^{(k)T} \mathbf{p}^{(k)} = 0,$

得到:  $\alpha_k = \frac{\mathbf{r}^{(k)T} \mathbf{p}^{(k)}}{\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)}},$

又  $\frac{d^2 f}{d\alpha^2} = \mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)} > 0 \ (\mathbf{p}^{(k)} \neq 0),$

故  $\alpha_k$  为  $f(\alpha)$  的极小值点, 于是  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}.$

$$\varphi(\mathbf{x}^{(k+1)}) - \varphi(\mathbf{x}^{(k)}) = -\frac{(\mathbf{r}^{(k)T} \mathbf{p}^{(k)})^2}{2\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)}}.$$

$$\varphi(\mathbf{x}^{(k+1)}) < \varphi(\mathbf{x}^{(k)}), (\mathbf{r}_k^T \mathbf{p}^{(k)} \neq 0).$$



## (2). 确定下山方向 $p^{(k)}$

若选取  $p^{(k)}$  为负梯度方向, 即  $p^{(k)} = -(Ax^{(k)} - b) = r^{(k)}$ , 就得到最速下降法(梯度下降法, GD 法)

算法1:

选取初值  $x^{(0)}$ ,

对  $k = 0, 1, 2, \dots$ ,  $r^{(k)} = b - Ax^{(k)}$ ,

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})},$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}.$$

## 梯度下降法的性质:

◇  $(\mathbf{r}^{(k+1)}, \mathbf{r}^{(k)}) = 0$ , 即  $\mathbf{r}^{(k+1)}$  与  $\mathbf{r}^{(k)}$  正交.

◇  $\{\varphi(\mathbf{x}^{(k)})\}$  是一个单调下降序列, 且  $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$  ( $A\mathbf{x}^* = \mathbf{b}$ ). 并且有估计:

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|_A \leq \left( \frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_A,$$

其中:  $\|\mathbf{x}\|_A = \sqrt{\mathbf{x}^T A \mathbf{x}}$ ,  $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n > 0$  为  $A$  的特征值.

## 梯度下降法的优缺点:

- ◇ 简单易用, 又可充分利用  $A$  的稀疏性
- ◇ 当  $\lambda_1 \gg \lambda_n$  时收敛非常慢; 当  $\|r^{(k)}\|$  很小时, 由于舍入误差, 计算不稳定.

例：用梯度下降法求解  $Ax = b$ , 其中  $A = \begin{pmatrix} 1/18 & 0 \\ 0 & 2 \end{pmatrix}$ ,  $b = (0, 0)^T$ ,  $x^{(0)} = (0.625, 0.1)^T$ .




Figure: GD法迭代点图, 迭代60次, 误差  $O(10^{-9})$ .

### 3.4.2 共轭梯度法(CG法)

#### 1. 计算过程:

给定初始向量 $\boldsymbol{x}^{(0)}$ , 第一步仍选负梯度方向为下山方向, 即 $\boldsymbol{p}^{(0)} = \boldsymbol{r}^{(0)}$ ,

于是有:  $\alpha_0 = \frac{\boldsymbol{r}^{(0)T} \boldsymbol{r}^{(0)}}{\boldsymbol{r}^{(0)T} \boldsymbol{A} \boldsymbol{r}^{(0)}}$ ,  $\boldsymbol{x}^{(1)} = \boldsymbol{x}^{(0)} + \alpha_0 \boldsymbol{r}^{(0)}$ ,  $\boldsymbol{r}^{(1)} = \boldsymbol{b} - \boldsymbol{A} \boldsymbol{x}^{(1)}$ .

对于第 $k+1$  ( $k \geq 1$ )步, 下山方向不再取负梯度方向 $\boldsymbol{r}^{(k)}$ , 而是取为经过点 $\boldsymbol{x}^{(k)}$  由向量 $\boldsymbol{r}^{(k)}$ 和 $\boldsymbol{p}^{(k-1)}$  所张成的二维平面

$$\pi_2 = \{ \boldsymbol{x} = \boldsymbol{x}^{(k)} + \xi \boldsymbol{r}^{(k)} + \eta \boldsymbol{p}^{(k-1)}; \xi, \eta \in R \}.$$

内, 找出使函数 $\varphi$ 下降最快的方向作为新的下山方向 $\boldsymbol{p}^{(k)}$ .

考虑 $\varphi$ 在 $\pi_2$ 上的限制:

$$\begin{aligned}\varphi(\xi, \eta) &= \varphi(\mathbf{x}^{(k)} + \xi \mathbf{r}^{(k)} + \eta \mathbf{p}^{(k-1)}) \\ &= \frac{1}{2}(\mathbf{x}^{(k)} + \xi \mathbf{r}^{(k)} + \eta \mathbf{p}^{(k-1)})^T \mathbf{A}(\mathbf{x}^{(k)} + \xi \mathbf{r}^{(k)} + \eta \mathbf{p}^{(k-1)}) \\ &\quad - \mathbf{b}^T(\mathbf{x}^{(k)} + \xi \mathbf{r}^{(k)} + \eta \mathbf{p}^{(k-1)}),\end{aligned}$$

根据函数取极值必要条件:

$$\begin{aligned}\frac{\partial \varphi}{\partial \xi} &= \xi \mathbf{r}^{(k)T} \mathbf{A} \mathbf{r}^{(k)} + \eta \mathbf{r}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)} - \mathbf{r}^{(k)T} \mathbf{r}^{(k)} = 0, \\ \frac{\partial \varphi}{\partial \eta} &= \xi \mathbf{r}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)} + \eta \mathbf{p}^{(k-1)T} \mathbf{A} \mathbf{p}^{(k-1)} = 0,\end{aligned}$$

这里用到了 $\mathbf{r}^{(k)T} \mathbf{p}^{(k-1)} = 0$ .

可得 $\varphi$ 在 $\pi_2$ 内有唯一极小点:

$$\tilde{\mathbf{x}} = \mathbf{x}^{(k)} + \xi_0 \mathbf{r}^{(k)} + \eta_0 \mathbf{p}^{(k-1)},$$

其中 $\xi_0, \eta_0$ 满足:

$$\begin{cases} \xi_0 \mathbf{r}^{(k)T} \mathbf{A} \mathbf{r}^{(k)} + \eta_0 \mathbf{r}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)} = \mathbf{r}^{(k)T} \mathbf{r}^{(k)}, \\ \xi_0 \mathbf{r}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)} + \eta_0 \mathbf{p}^{(k-1)T} \mathbf{A} \mathbf{p}^{(k-1)} = 0. \end{cases}$$

于是, 可取  $\mathbf{p}^{(k)} = \frac{1}{\xi_0}(\tilde{\mathbf{x}} - \mathbf{x}^{(k)}) = \mathbf{r}^{(k)} + \frac{\eta_0}{\xi_0} \mathbf{p}^{(k-1)}$  作为新的下山方向.

显然, 这是在平面 $\pi_2$ 内找到的最佳下山方向.

$$\text{令 } \beta_{k-1} = \frac{\eta_0}{\xi_0}, \text{ 则 } \beta_{k-1} = -\frac{\mathbf{r}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)}}{\mathbf{p}^{(k-1)T} \mathbf{A} \mathbf{p}^{(k-1)}}.$$

注意到, 这样确定的  $\mathbf{p}^{(k)}$  满足:  $\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k-1)} = 0$ .

**定义:**  $\mathbf{A}$  对称正定, 如果  $R^n$  中向量组  $\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(l)}\}$  满足

$$(\mathbf{A} \mathbf{p}^{(i)}, \mathbf{p}^{(j)}) = 0, \quad i \neq j.$$

则称它为  $R^n$  中的一个  **$\mathbf{A}$ -共轭向量组**.

即:  $\mathbf{p}^{(k)}$  与  $\mathbf{p}^{(k-1)}$  是  $\mathbf{A}$  共轭的.

$\mathbf{p}^{(k)}$ ,  $\mathbf{p}^{(k-1)}$ ,  $\mathbf{r}^{(k)}$  的几何意义?



确定了 $p^{(k)}$ 后, 可确定 $\alpha_k$ , 于是第 $k+1$ 步的迭代计算过程如下:

计算搜索方向 $p^{(k)}$ :

$$\begin{aligned} r^{(k)} &= b - Ax^{(k)}, \quad \beta_{k-1} = -\frac{r^{(k)T} A p^{(k-1)}}{p^{(k-1)T} A p^{(k-1)}}, \\ p^{(k)} &= r^{(k)} + \beta_{k-1} p^{(k-1)}. \end{aligned}$$

计算步长 $\alpha_k$ :

$$\alpha_k = \frac{r^{(k)T} p^{(k)}}{p^{(k)T} A p^{(k)}},$$

计算新的迭代点 $x^{(k+1)}$ :  $x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$ :

## 简化计算公式:

(1). 简化 $\mathbf{r}^{(k)}$  的计算公式:

$$\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k)} = \mathbf{b} - \mathbf{A}(\mathbf{x}^{(k-1)} + \alpha_{k-1}\mathbf{p}^{(k-1)}) = \mathbf{r}^{(k-1)} - \alpha_{k-1}\mathbf{A}\mathbf{p}^{(k-1)}.$$

(2). 简化 $\alpha_k, \beta_{k-1}$  的计算公式:

注意到:  $\mathbf{r}^{(k)T}\mathbf{r}^{(k-1)} = \mathbf{r}^{(k)T}\mathbf{p}^{(k-1)} = \mathbf{r}^{(k+1)T}\mathbf{p}^{(k)} = 0, k = 1, 2, \dots$

于是:  $(\mathbf{r}^{(k)}, \mathbf{p}^{(k)}) = (\mathbf{r}^{(k)}, \mathbf{r}^{(k)} + \beta_{k-1}\mathbf{p}^{(k-1)}) = (\mathbf{r}^{(k)}, \mathbf{r}^{(k)}),$

$$\mathbf{r}^{(k)T}\mathbf{A}\mathbf{p}^{(k-1)} = \frac{1}{\alpha_{k-1}}\mathbf{r}^{(k)T}(\mathbf{r}^{(k-1)} - \mathbf{r}^{(k)}) = -\frac{1}{\alpha_{k-1}}\mathbf{r}^{(k)T}\mathbf{r}^{(k)},$$

$$\mathbf{p}^{(k)T}\mathbf{A}\mathbf{p}^{(k)} = \frac{1}{\alpha_k}\mathbf{p}^{(k)T}(\mathbf{r}^{(k)} - \mathbf{r}^{(k+1)}) = \frac{1}{\alpha_k}\mathbf{p}^{(k)T}\mathbf{r}^{(k)} = \frac{1}{\alpha_k}\mathbf{r}^{(k)T}\mathbf{r}^{(k)}.$$

于是:

$$\alpha_k = \frac{\mathbf{r}^{(k)T} \mathbf{r}^{(k)}}{\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)}}, \quad \beta_{k-1} = \frac{\mathbf{r}^{(k)T} \mathbf{r}^{(k)}}{\mathbf{r}^{(k-1)T} \mathbf{r}^{(k-1)}}.$$

算法2(共轭梯度法):

$$\begin{aligned} &\text{选取初始向量 } \mathbf{x}^{(0)}, \quad \mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(0)}, \quad \alpha_0 = \frac{\mathbf{r}^{(0)T} \mathbf{r}^{(0)}}{\mathbf{r}^{(0)T} \mathbf{A} \mathbf{r}^{(0)}}, \\ &\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{r}^{(0)}; \end{aligned}$$

$$\text{对于 } k = 1, 2, \dots, \quad \mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - \alpha_{k-1} \mathbf{A} \mathbf{p}^{(k-1)},$$

$$\beta_{k-1} = \frac{\mathbf{r}^{(k)T} \mathbf{r}^{(k)}}{\mathbf{r}^{(k-1)T} \mathbf{r}^{(k-1)}}, \quad \mathbf{p}^{(k)} = \mathbf{r}^{(k)} + \beta_{k-1} \mathbf{p}^{(k-1)},$$

$$\alpha_k = \frac{\mathbf{r}^{(k)T} \mathbf{r}^{(k)}}{\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)}}, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}.$$

## 例：应用共轭梯度法求解方程组

$$\begin{pmatrix} 2 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \\ 3 \end{pmatrix}$$

解：

(1) 当  $k = 1$  时，取  $\mathbf{x}_0 = (0, 0, 0)^T$ ，则

$$\mathbf{p}^{(0)} = \mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)} = (3, 1, 3)^T$$

计算得  $\mathbf{A}\mathbf{p}^{(0)} = (9, 1, 9)^T$ ， $\mathbf{p}^{(0)T}\mathbf{A}\mathbf{p}^{(0)} = 55$ ，因此

$$\alpha_0 = \frac{(\mathbf{r}^{(0)}, \mathbf{p}^{(0)})}{(\mathbf{p}^{(0)}, \mathbf{A}\mathbf{p}^{(0)})} = \frac{19}{55}, \quad \mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{p}^{(0)} = \frac{19}{55}(3, 1, 3)^T,$$

(2) 当  $k = 2$  时,  $\mathbf{r}^{(1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(1)} = \mathbf{r}^{(0)} - \alpha_0 \mathbf{A}\mathbf{p}^{(0)} = \frac{6}{55}(-1, 6, -1)^T$ ,

$$\beta_0 = -\frac{(\mathbf{r}^{(1)}, \mathbf{r}^{(1)})}{(\mathbf{r}^{(0)}, \mathbf{r}^{(0)})} = \frac{72}{55^2}, \quad \mathbf{p}^{(1)} = \mathbf{r}^{(1)} + \beta_0 \mathbf{p}^{(0)} = \frac{6 \times 19}{55^2}(-1, 18, -1)^T$$

计算得  $\mathbf{A}\mathbf{p}^{(1)} = \frac{6 \times 3 \times 19}{55^2}(-1, 6, -1)^T$ ,  $\mathbf{p}^{(1)T} \mathbf{A}\mathbf{p}^{(1)} = \frac{6^3 \times 19^2}{55^2}$

$$\mathbf{r}^{(1)T} \mathbf{r}^{(1)} = \frac{6^2 \times 19 \times 2}{55^2}, \quad \alpha_1 = \frac{(\mathbf{r}^{(1)}, \mathbf{r}^{(1)})}{(\mathbf{p}^{(1)}, \mathbf{A}\mathbf{p}^{(1)})} = \frac{55}{3 \times 19}$$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \alpha_1 \mathbf{p}^{(1)} = (1, 1, 1)^T, \quad \mathbf{r}^{(2)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(2)} = \mathbf{0}$$

故方程组的解为  $\mathbf{x}^{(2)} = (1, 1, 1)^T$ 。

## 2. CG法的相关概念及性质

### (1). 共轭梯度法的基本性质:

**定理:** 由共轭梯度法得到的向量组 $\{\mathbf{r}^{(i)}\}$ 和 $\{\mathbf{p}^{(i)}\}$ 具有如下性质:

- (i)  $\mathbf{p}^{(i)T} \mathbf{r}^{(j)} = 0, 0 \leq i < j \leq k$
- (ii)  $\mathbf{r}^{(i)T} \mathbf{r}^{(j)} = 0, i \neq j, 0 \leq i, j \leq k$
- (iii)  $\mathbf{p}^{(i)T} \mathbf{A} \mathbf{p}^{(j)} = 0, i \neq j, 0 \leq i, j \leq k$
- (iv)  $\text{span}\{\mathbf{r}^{(0)}, \mathbf{r}^{(1)}, \dots, \mathbf{r}^{(k)}\} = \text{span}\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k)}\} = \mathcal{K}(\mathbf{A}, \mathbf{r}^{(0)}, k+1)$ , 其中:

$$\mathcal{K}(\mathbf{A}, \mathbf{r}^{(0)}, k+1) = \text{span}\{\mathbf{r}^{(0)}, \mathbf{A} \mathbf{r}^{(0)}, \dots, \mathbf{A}^k \mathbf{r}^{(0)}\}.$$

通常称为Krylov子空间.

**定理:** 共轭梯度法最多 $n$ 步便可得到方程组的解 $\mathbf{x}^*$ .

(2). 定理: 用CG法计算得到的近似解 $\boldsymbol{x}^{(k)}$ 满足:

$$\varphi(\boldsymbol{x}^{(k)}) = \min\{\varphi(\boldsymbol{x}) : \boldsymbol{x} \in \boldsymbol{x}^{(0)} + \mathcal{K}(\boldsymbol{A}, \boldsymbol{r}_0, k)\}.$$

$$\text{或 } \|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_{\boldsymbol{A}} = \min\{\|\boldsymbol{x} - \boldsymbol{x}^*\|_{\boldsymbol{A}} : \boldsymbol{x} \in \boldsymbol{x}^{(0)} + \mathcal{K}(\boldsymbol{A}, \boldsymbol{r}^{(0)}, k)\},$$

其中:  $\|\boldsymbol{x}\|_{\boldsymbol{A}} = \sqrt{\boldsymbol{x}^T \boldsymbol{A} \boldsymbol{x}}$ ,  $\boldsymbol{x}^*$ 是方程组 $\boldsymbol{A} \boldsymbol{x} = \boldsymbol{b}$ 的解,  $\mathcal{K}(\boldsymbol{A}, \boldsymbol{r}_0, k)$ 是由前面定理定义的Krylov子空间.

注: CG法第 $k$ 步迭代得到的解实质就是由 $\boldsymbol{x}^{(0)}$ 出发(经过 $\boldsymbol{x}^{(0)}$ ), 由前面各步的搜索方向张成的子空间中的最优解.

### (3). $A$ -共轭向量组:

**定理:**  $A$ -共轭向量组是线性无关的.

**推论:** 若  $R^n$  中一组  $A$ -共轭向量组中向量个数为  $n$ , 则构成  $R^n$  的一组基(称为  $A$ -共轭基)



#### (4). 向量组的正交化与 $A$ -共轭化

##### Schmidt正交化

##### $A$ -共轭化:

设  $\alpha^{(1)}, \dots, \alpha^{(k-1)}$  线性无关, 令  $p^{(1)} = \alpha^{(1)}$ , 且由  $\alpha^{(1)}, \dots, \alpha^{(k-1)}$  的组合已产生  $A$ -共轭向量组  $p^{(1)}, p^{(2)}, \dots, p^{(k-1)}$ , 令

$$p^{(k)} = \alpha^{(k)} + l_{k,1}p^{(1)} + \dots + l_{k,k-1}p^{(k-1)},$$

由  $(p^{(k)}, Ap^{(j)}) = (\alpha^{(k)}, Ap^{(j)}) + l_{k,j}(p^{(j)}, Ap^{(j)}) = 0, \quad j = 1, 2, \dots, k-1.$

于是: 
$$l_{k,j} = -\frac{(\alpha^{(k)}, Ap^{(j)})}{(Ap^{(j)}, p^{(j)})}.$$

从而有:

$$\left\{ \begin{array}{l} \mathbf{p}^{(1)} = \boldsymbol{\alpha}^{(1)}, \\ \mathbf{p}^{(k)} = \boldsymbol{\alpha}^{(k)} - \sum_{j=1}^{k-1} \frac{(\boldsymbol{\alpha}^{(k)}, A\mathbf{p}^{(j)})}{(A\mathbf{p}^{(j)}, \mathbf{p}^{(j)})} \mathbf{p}^{(j)} \\ \quad = \boldsymbol{\alpha}^{(k)} - \sum_{j=1}^{k-1} \frac{(A\boldsymbol{\alpha}^{(k)}, \mathbf{p}^{(j)})}{(A\mathbf{p}^{(j)}, \mathbf{p}^{(j)})} \mathbf{p}^{(j)} \end{array} \right.$$

### 3. 实用CG法

#### 应用CG法存在的问题:

- ◇ 理论上CG法至多经 $n$ 步便得到方程组的精确解, 然而实际使用时, 由于舍入误差, 使得 $\mathbf{r}^{(k)}$ 之间的正交性很快损失, 以致于其有限步终止性不再成立.
- ◇ 实际问题中, 由于 $n$ 一般很大, 以致于迭代 $O(n)$ 次耗时巨大, 因此实际上将CG法作为一种迭代算法使用. 迭代终止准则一般为:  $\|\mathbf{r}^{(k)}\|$ 已经很小或迭代次数已达最大容许次数.

## 算法3(实用CG法):

设置 $\epsilon$ ,  $k_{\max}$ :

(1) 取初值 $\mathbf{x}^{(0)} \in R^n$ , 计算 $\mathbf{r}^{(0)} = \mathbf{p}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$ ,

对 $k = 0, 1, 2, \dots$

(2) 计算 $\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{A}\mathbf{p}^{(k)}, \mathbf{p}^{(k)})}$ ,

(3) 计算 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$ ,

(4) 计算 $\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{p}^{(k)}$ ,

(5) 若 $\|\mathbf{r}^{(k+1)}\|_2 < \epsilon$ 或 $k > k_{\max}$ , 输出 $\mathbf{x}^{(k+1)}$ , 迭代停止, 否则转下一步,

(6) 计算 $\beta_k = \frac{(\mathbf{r}^{(k+1)}, \mathbf{r}^{(k+1)})}{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}$ ,

(7) 计算 $\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} + \beta_k \mathbf{p}^{(k)}$ ,  $k = k + 1$ , 转(2).

## 4. CG法的收敛性

**定理:** 用CG法求得的 $\boldsymbol{x}^{(k)}$ 有如下误差估计:

$$\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^*\|_A \leq 2 \left( \frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^*\|_A,$$

其中  $\kappa_2 = \text{cond}_2(\boldsymbol{A}) = \|\boldsymbol{A}\|_2 \|\boldsymbol{A}^{-1}\|_2 = \frac{\lambda_1}{\lambda_n}$ ,  
 $\lambda_1, \lambda_n$  分别为 $\boldsymbol{A}$ 的最大特征值和最小特征值.

**注:** 只要线性方程组的系数矩阵是十分良态的( $\text{cond}_2(\boldsymbol{A}) \approx 1$ ), 则CG法收敛很快.

## 5. CG法的优点:

- ◇ 算法中, 系数矩阵 $A$ 的作用仅仅用来由已知向量 $p$ 产生向量 $w = AP$ , 可以充分利用 $A$ 的稀疏性, 且对某些提供 $A$ 较困难但由 $p$ 产生 $Ap$ 十分方便的应用问题非常有益.
- ◇ 不需要预先估计任何参数.
- ◇ 每次迭代所需的计算, 主要是向量之间的运算, 便于并行化.

### 3.4.3 预处理共轭梯度法

#### 1. 基本思想:

CG法在系数矩阵仅有少数几个互不相同的特征值或者非常良态时, 收敛非常快, 因此, 在应用CG法时, 首先应设法将原方程等价转化为一个系数矩阵仅有少数几个互不相同的特征值或非常良态的方程组, 然后再用CG 法求解转化后的方程组.

## 2. 算法:

设 $S$ 为一可逆阵,

$$Ax = b \Leftrightarrow S^{-1}AS^{-T}S^Tx = S^{-1}b \Leftrightarrow Hu = g,$$

其中:  $H = S^{-1}AS^{-T}$ ,  $u = S^Tx$ ,  $g = S^{-1}b$ .

对 $Hu = g$ 应用CG法, 记 $M = SS^T$ , 整理得算法4(PCG 算法):

设置 $\epsilon$ ,  $k_{\max}$ :

(1) 取初值 $x^{(0)} \in R^n$ , 计算 $r^{(0)} = b - Ax^{(0)}$ ,  $z^{(0)} = M^{-1}r^{(0)}$ ,  $p^{(0)} = z^{(0)}$ ,

对 $k = 0, 1, 2, \dots$

(2) 计算 $\alpha_k = \frac{(z^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$ ,



- (3) 计算  $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{p}^{(k)}$ ,
- (4) 计算  $\boldsymbol{r}^{(k+1)} = \boldsymbol{r}^{(k)} - \alpha_k \boldsymbol{A} \boldsymbol{p}^{(k)}$ ,
- (5) 若  $\|\boldsymbol{r}^{(k+1)}\|_2 < \epsilon$  或  $k > k_{\max}$ , 输出  $\boldsymbol{x}^{(k+1)}$ , 迭代停止, 否则转下一步,
- (6) 计算  $\boldsymbol{z}^{(k+1)} = \boldsymbol{M}^{-1} \boldsymbol{r}^{(k+1)}$ , (或求解  $\boldsymbol{M} \boldsymbol{z}^{(k+1)} = \boldsymbol{r}^{(k+1)}$ ),
- (7) 计算  $\beta_k = \frac{(\boldsymbol{z}^{(k+1)}, \boldsymbol{r}^{(k+1)})}{(\boldsymbol{z}^{(k)}, \boldsymbol{r}^{(k)})}$ ,
- (8) 计算  $\boldsymbol{p}^{(k+1)} = \boldsymbol{z}^{(k+1)} + \beta_k \boldsymbol{p}^{(k)}$ ,  $k = k + 1$ , 转(2).

### 3. PCG方法的性质和误差估计:

(1). 由 $(\tilde{\mathbf{r}}^{(i)}, \tilde{\mathbf{r}}^{(j)}) = 0$ , 有:  $(\mathbf{M}^{-1}\mathbf{r}^{(i)}, \mathbf{r}^{(j)}) = 0, i \neq j$ ;

由 $(\mathbf{H}\tilde{\mathbf{p}}^{(i)}, \tilde{\mathbf{p}}^{(j)}) = 0$ , 有:  $(\mathbf{A}\mathbf{p}^{(i)}, \mathbf{p}^{(j)}) = 0, i \neq j$ .

即 $\{\mathbf{r}^{(k)}\}$ 是内积 $(\cdot, \cdot)_{\mathbf{M}^{-1}}$ 意义下的正交组,  $\{\mathbf{p}^{(k)}\}$ 是 $\mathbf{A}$ -共轭向量组.

$$(2). \|\mathbf{x}^{(k)} - \mathbf{x}^*\|_{\mathbf{A}} \leq 2 \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_{\mathbf{A}},$$

其中 $\kappa$  是 $\mathbf{M}^{-1}\mathbf{A}$ 的最大特征值和最小特征值之比.

#### 4. 预处理矩阵 $M$ 的选取

(1).  $M$ 应满足的条件:

- a.  $M$ 对称正定
- b.  $M$ 是稀疏的
- c.  $M^{-1}A$ 的特征值分布“集中”，即条件数小
- d. 形如 $Mz = r$ 的方程容易求解( $M$ 具有分块或三角阵乘积等较好的性质)

## 5. 常用的预处理矩阵 $M$ 的选取技巧

### (1). 对角预处理阵:

若线性方程组的系数矩阵 $A$ 的对角元素相差较大, 则可取

$M = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ 作为预处理阵, 常会使收敛速度大大提高.

推广: 若

$$A = \begin{pmatrix} A_{11} & \cdots & A_{1k} \\ \vdots & \vdots & \vdots \\ A_{k1} & \cdots & A_{kk} \end{pmatrix}, \text{ 其中 } A_{ii} \text{ 是易于求逆的方阵,}$$

则可取 $M = \text{diag}(A_{11}, \dots, A_{kk})$ .

## (2). 不完全Cholesky分解法:

先求系数矩阵 $A$ 的不完全Cholesky分解:

$$A = LL^T + R,$$

其中 $L$ 为单位下三角阵. 选取 $M = LL^T$ 作为预处理阵, 由于有 $R$ 可选择, 可调整 $L$ 具有与 $A$ 一样的稀疏性, 当然 $LL^T$ 越接近 $A$ 越好.

缺点: 求 $Mz = r$ 时需要求解两个三角方程组, 并行效率低.