

第五章 矩阵特征值问题的数值方法

数值分析

南京理工大学数统学院

5.1 特征值的估计与扰动

5.1.1 特征值的估计

5.1.2 特征值的扰动

5.2 幂迭代法和逆幂迭代法

5.2.1 幂迭代法

5.2.2 幂法的加速

5.2.3 逆幂迭代法

5.3 QR 算法

5.3.1 矩阵的 QR 分解

5.3.2 特征值求解的 QR 算法

5.4 矩阵的奇异值分解

5.1 特征值的估计与扰动

5.1.1 特征值的估计

1. **定理5.1:** (盖尔圆定理) 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, 则 A 的特征值有

$$\lambda \in \bigcup_{i=1}^n D_i$$

其中

$$D_i = \{z : |z - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}|\} \quad (i = 1, 2, \dots, n)$$

为复平面上的圆盘, D_i 也称为矩阵 A 的第 i 个盖尔圆, $R_i = \sum_{j=1, j \neq i}^n |a_{ij}|$ 为盖尔圆 D_i 的半径。

证明： 设 λ 是 A 的任意特征值， x 为 A 对应于 λ 的特征向量，设 x_i 是特征向量 x 中按模最大的分量，由于 $(Ax)_i = \lambda x_i$,

即 $\lambda x_i = \sum_{j=1}^n a_{ij} x_j$ ，则有 $(\lambda - a_{ii})x_i = \sum_{j=1, j \neq i}^n a_{ij} x_j$ 。

注意到 $|x_j| \leq |x_i| (j \neq i)$ ，则由上式得

$$|\lambda - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{j=1, j \neq i}^n |a_{ij}|.$$

于是 $\lambda \in D_i$ 。证毕■

注： A 的全体特征值也都在 A^T 的 n 个盖尔圆构成的并集中，称 A^T 的盖尔圆为 A 的**列盖尔圆**。

注：定理5.1说明 **A 的 n 个特征值均落在 n 个圆盘的并集中**，但未说明特征值的具体分布情况，**并不是指每个圆盘内都有特征值**。

注： A 的全体特征值也都在 A^T 的 n 个盖尔圆构成的并集中，称 A^T 的盖尔圆为 A 的**列盖尔圆**。

注：定理5.1说明 **A 的 n 个特征值均落在 n 个圆盘的并集中**，但未说明特征值的具体分布情况，**并不是指每个圆盘内都有特征值**。

定理5.2: 设矩阵的 n 个盖尔圆圆盘中，有 m 个圆盘相交构成一个连通域 S ，且 S 与其余 $n - m$ 个圆盘严格分离，则 S 中恰有 A 的 m 个特征值，其中重根特征值的个数按其重数计算。

例： 估计下面矩阵的特征值范围

$$A = \begin{pmatrix} -3+i & 0 & 2 \\ -1 & 3 & i \\ 0 & -1 & 2 \end{pmatrix}$$

解： 矩阵 A 的 3 个盖尔圆为


$$G_1 : |z + 3 - i| \leq 2$$

$$G_2 : |z - 3| \leq 2$$

$$G_3 : |z - 2| \leq 1,$$

矩阵 A 的特征值在 G_1 中有一个，

在 $G_2 \cup G_3$ 中有两个；




矩阵 A 的 3 个列盖尔圆为

$$G'_1 : |z + 3 - i| \leq 1,$$

$$G'_2 : |z - 3| \leq 1,$$

$$G'_3 : |z - 2| \leq 3,$$

故 A 的 3 个特征值有一个在 G'_1 中，两个在 $G'_2 \cup G'_3$ 中。



在这里，矩阵 A 的其中一个特征值独占一个盖尔圆，是可以分出来的，而另外两个特征值只能判断是在 $G'_2 \cup G'_3$ 或 $G'_2 \cup G'_3$ 中，无法判断其位置（有可能都在小圆外面，而小圆内一个都没有）。

盖尔圆隔离的基本思想: 如果每个盖尔圆都是独立的, 则每个盖尔圆内有一个特征值。

1. 结合列盖尔圆实现特征值隔离.

例: 应用盖尔圆定理隔离

$$A = \begin{pmatrix} 20 & 3 & 2 \\ 2 & 10 & 4 \\ 4 & 0.5 & 0 \end{pmatrix}$$

的特征值。

解: A 的三个盖尔圆为

$$G_1 : |z - 20| \leq 5, \quad G_2 : |z - 10| \leq 6, \quad G_3 : |z| \leq 4.5$$

显然, G_1, G_2, G_3 相交。

而 A 的三个列盖尔圆为

$$\overline{G}_1 : |z - 20| \leq 6, \quad \overline{G}_2 : |z - 10| \leq 3.5, \quad \overline{G}_3 : |z| \leq 6,$$

它们相互分离。

故在 $\overline{G}_1, \overline{G}_2, \overline{G}_3$ 中各有 A 的一个特征值。

2. 利用相似变换调节盖尔圆半径，实现特征值隔离.

对于 $A = (a_{ij})_{n \times n}$ ，设 $D = \text{diag}(d_1, d_2, \dots, d_n)$ ， $(d_i > 0, i = 1, 2, \dots, n)$ ，则

$$A \sim B = D^{-1}AD,$$

此时 A 和 B 有相同特征值。

注意到： A 和 B 具有相同的对角线元素（即盖尔圆中心不变），但 B 的盖尔圆盘半径为

$$R_i = \sum_{j=1, j \neq i}^n \left| \frac{a_{ij}d_j}{d_i} \right|,$$

发生了改变，其具体大小可通过 D 的对角元素取值来调节。

通过适当选取 D 的元素值, 可以使某个圆盘半径相对减少或增加。

一般地, 要使 A 的第 i 个盖尔圆半径放大, 其余盖尔圆适量缩小 (相对于 A 的同序号盖尔圆), 我们可取 $d_i < 1$, 其它元素值取 1;

相反, 若使 A 的第 i 个盖尔圆半径缩小, 其余盖尔圆适量放大 (相对于 A 的同序号盖尔圆), 我们可取 $d_i > 1$, 其它元素值取 1.

例：应用盖尔圆定理隔离证明

$$A = \begin{pmatrix} 2 & 2 & -1 \\ 1 & 10 & -1 \\ 8 & 2 & 20 \end{pmatrix}$$

有三个互异的实数特征值。

例： 应用盖尔圆定理隔离证明

$$A = \begin{pmatrix} 2 & 2 & -1 \\ 1 & 10 & -1 \\ 8 & 2 & 20 \end{pmatrix}$$

有三个互异的实数特征值。

解： A 的三个盖尔圆为

$$G_1 : |z - 2| \leq 3, \quad G_2 : |z - 10| \leq 2, \quad G_3 : |z - 20| \leq 10.$$

G_2 与 G_3 相交。

取 $D = \text{diag}(\frac{1}{2}, 1, 1)$, 则

$$B = D^{-1}AD = \begin{pmatrix} 2 & 4 & -2 \\ 0.5 & 10 & -1 \\ 4 & 2 & 20 \end{pmatrix}.$$

则 B 的三个盖尔圆为

$$\overline{G}_1: |z - 2| \leq 6, \quad \overline{G}_2: |z - 10| \leq 1.5, \quad \overline{G}_3: |z - 20| \leq 6,$$

它们相互分离。

若实矩阵 A 的特征值 λ 为复数, 则 $\bar{\lambda}$ 也为特征值, 但 $\overline{G}_1, \overline{G}_2, \overline{G}_3$ 关于实轴对称, 则 A 特征值必皆为实数, 故在区间 $[-4, 8], [8.5, 11.5], [14, 26]$ 中各有 A 的一个实特征值。

5.1.2 特征值的扰动

定理5.3: 设 E 为矩阵 A 的扰动矩阵, μ 是矩阵 $A + E \in \mathbb{C}^{n \times n}$ 的一个特征值, 且存在 $X \in \mathbb{C}^{n \times n}$, $X^{-1}AX = D = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, 则

$$\min_{\lambda \in \sigma(A)} |\lambda - \mu| \leq \|X^{-1}\|_p \|X\|_p \|E\|_p,$$

其中 $\|\cdot\|_p$ 为矩阵的 p -范数, $p = 1, 2, \infty$.

证明: 若 $\mu \in \sigma(A)$, 结论显然成立. 今设 $\mu \notin \sigma(A)$, 由 A 可对角化

$$A + E - \mu I = X[D - \mu I + X^{-1}EX]X^{-1},$$

μ 为 $A + E$ 的特征值, 所以 $D - \mu I + X^{-1}EX$ 奇异, 存在非零向量 $y \in \mathbb{C}^n$, 使

$$(D - \mu I)y = -(X^{-1}EX)y,$$

由此得

$$y = -(D - \mu I)^{-1}(X^{-1}EX)y,$$

两边取 p -范数有

$$\|(D - \mu I)^{-1}\|_p \|X^{-1}\|_p \|E\|_p \|X\|_p \geq 1,$$

由 $\|(D - \mu I)^{-1}\|_p = \frac{1}{\min_{\lambda \in \sigma(A)} |\lambda - \mu|}$, 定理得证.

$\|X^{-1}\|_p \|X\|_p$ 称为矩阵 A 关于特征值问题的条件数.

5.2 幂迭代法与逆幂迭代法

5.2.1 幂迭代法

假设矩阵 A 可对角化, 其特征值满足

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$$

且 x_1, x_2, \cdots, x_n 为相应线性无关的特征向量, 其中 A 按模最大的特征值 λ_1 称为**主特征值**, 对应 x_1 称为**主特征向量**。

幂迭代法目的: 求出主特征值及对应的主特征向量。

算法思想： 由于特征向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 构成 \mathbb{R}^n 的一组基，因此对于 \mathbb{R}^n 中的任意元素 $\mathbf{v}^{(0)}$ ，有

$$\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n.$$

从而得到

$$\mathbf{A}^k \mathbf{v}^{(0)} = \lambda_1^k \left[\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right].$$

若记 $\mathbf{v}^{(k)} = \mathbf{A}^k \mathbf{v}^{(0)}$ ，则有 $\mathbf{v}^{(k+1)} = \mathbf{A} \mathbf{v}^{(k)}$ 。

当 $k \rightarrow \infty$ ， $|\frac{\lambda_i}{\lambda_1}|^k \rightarrow 0$ 。且当 $\alpha_1 \neq 0$ 时， $\mathbf{v}^{(k)} \approx \lambda_1^k \alpha_1 \mathbf{x}_1$ 。

但注意到,

当 $|\lambda_1| > 1$ 时, $\mathbf{v}^{(k)} \approx \lambda_1^k \alpha_1 \mathbf{x}_1$ 的分量都趋向于无穷;

当 $|\lambda_1| < 1$ 时, $\mathbf{v}^{(k)} \approx \lambda_1^k \alpha_1 \mathbf{x}_1$ 的分量都趋向于 0。

为避免这种情况, 通常在迭代过程中加上规范化步骤, 即在每一次计算中都要求 $\mathbf{v}^{(k)}$ 的按模最大分量为 1, 这样 $\|\mathbf{v}^{(k)}\|_\infty = 1$ 。

幂迭代格式: 选取初始向量 $\mathbf{v}^{(0)} \neq 0$, 对 $k = 0, 1, 2, \dots$, 按照如下迭代格式计算

$$\begin{cases} \mathbf{u}^{(k+1)} = \mathbf{A}\mathbf{v}^{(k)}, \\ m_{k+1} = \max(\mathbf{u}^{(k+1)}), \\ \mathbf{v}^{(k+1)} = \frac{\mathbf{u}^{(k+1)}}{m_{k+1}}. \end{cases}$$

定理5.4: 设 $A \in \mathbb{R}^{n \times n}$, A 存在 n 个线性无关的特征向量 $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_n$, 对应的特征值满足

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|,$$

且初始向量 $\boldsymbol{v}^{(0)}$ 在 \boldsymbol{x}_1 方向上的投影非零, 则有

$$\lim_{k \rightarrow \infty} \boldsymbol{v}^{(k)} = \frac{\boldsymbol{x}_1}{\max\{\boldsymbol{x}_1\}}, \quad \lim_{k \rightarrow \infty} m_k = \lambda_1.$$

证明: 特征向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 构成 \mathbb{R}^n 的一组基, 因此对于 \mathbb{R}^n 中的任意元素 $\mathbf{v}^{(0)}$, 有 $\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n$, 从而得到

$$\mathbf{A}^k \mathbf{v}^{(0)} = \lambda_1^k \left[\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right]. \quad (\lambda_1 \text{ 为按模最大特征值})$$

当 $\mathbf{v}^{(0)}$ 在 \mathbf{x}_1 方向上的投影非零, 即 $\alpha_1 \neq 0$, 则有

$$\mathbf{v}^{(k)} = \frac{\mathbf{A} \mathbf{v}^{(k-1)}}{m_k} = \frac{\mathbf{A}}{m_k} \frac{\mathbf{A} \mathbf{v}^{(k-2)}}{m_{k-1}} = \dots = \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{m_k \cdots m_1} = \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^k \mathbf{v}^{(0)})} \rightarrow \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}$$

$$\begin{aligned} m_k &= \max(\mathbf{A} \mathbf{v}^{(k-1)}) = \frac{\max(\mathbf{A}^k \mathbf{v}^{(0)})}{\max(\mathbf{A}^{k-1} \mathbf{v}^{(0)})} \\ &= \lambda_1 \left[\max \left(\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right) / \max \left(\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^{k-1} \mathbf{x}_i \right) \right] \rightarrow \lambda_1. \end{aligned}$$

注1: 幂法收敛速度取决于 $\left| \frac{\lambda_2}{\lambda_1} \right|$, 当 $|\lambda_2| \ll |\lambda_1|$ 时, 收敛较快, 而当 $|\lambda_2| \approx |\lambda_1|$ 时, 收敛速度很慢.

注2: 实际计算中, 可设置 $\|v^{(k)} - v^{(k+1)}\| \leq \epsilon$ 作为迭代终止准则.

注3: 对于不满足 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ 的情形, 如按模最大特征值为 r 重根的情形 ($r \geq 2$), 但 A 仍满足可对角化条件, 那么 $m_k = \max(\mathbf{u}_k) \rightarrow \lambda_1$ 仍成立.

注4: 若选取的 $v^{(0)}$ 满足 $\alpha_1 = 0$, 则在中间计算过程无任何误差的情况下, 幂法计算得到的是次模最大的特征值; 若中间过程有舍入误差, 则很可能某次迭代开始成立 $\alpha_1 \neq 0$, 但 α_1 仍很小, 有可能造成迭代很多次后收敛到 x_1, λ_1 . 通常取 $v^{(0)} = (1, 1, \cdots, 1)^T$, 以尽可能使 $\alpha_1 \neq 0$ 的可能性大些.

例: 计算 $A = \begin{pmatrix} 2 & 4 & 6 \\ 3 & 9 & 15 \\ 4 & 16 & 36 \end{pmatrix}$ 的按模最大特征值及对应特征向量。

解: 取 $v^{(0)} = (1, 1, 1)^T$, 按规范化幂法计算结果见表

k	$u^{(k)T}$			$v^{(k)T}$			m_k
0	—	—	—	1	1	1	
1	12	27	56	0.2143	0.4820	1	56
2	8.357	19.98	55.57	0.1857	0.4483	1	55.57
3	8.168	19.60	43.92	0.1860	0.4463	1	43.92
4	8.157	19.57	43.88	0.1859	0.4460	1	43.88
5	8.156	19.57	43.88	0.1859	0.4460	1	43.88

所以按模最大特征值为 $\lambda_1 = 43.88$, 其对应的特征向量为 $x_1 = (0.1859, 0.4460, 1.0000)^T$ 。

5.2.2 幂法的加速

原点平移法

当 $\left| \frac{\lambda_2}{\lambda_1} \right|$ 接近1时, 幂法收敛可能很慢, 可采用加速收敛的技巧.

引进矩阵 $B = A - pI$, 其中 p 为待定参数, 设 A 特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则 B 特征值为 $\lambda_1 - p, \lambda_2 - p, \dots, \lambda_n - p$, 且 A, B 特征向量相同.

如果计算 A 的主特征值, 需要适当选择 p , 使得

$$\begin{aligned} |\lambda_1 - p| &> |\lambda_2 - p| \geq \dots \geq |\lambda_n - p| \\ \left| \frac{\lambda_2 - p}{\lambda_1 - p} \right| &< \left| \frac{\lambda_2}{\lambda_1} \right|. \end{aligned}$$

问题: 若已知 A 的特征值为实数, 如何选取 p 使幂法得到加速?

注: 设计一个自动选择适当参数 p 的算法是困难的.

瑞利商加速

定义： 设 A 为 n 阶实对称矩阵, 对于任一非零向量 x , 称

$$R(x) = \frac{(Ax, x)}{(x, x)}$$

为对应于向量 x 的瑞利(Rayleigh)商.

定理： 设 $A \in R^{n \times n}$ 为对称矩阵, 特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$, 则

$$(1) \lambda_n \leq \frac{(Ax, x)}{(x, x)} \leq \lambda_1,$$

$$(2) \lambda_1 = \max_{x \in R^n, x \neq 0} \frac{(Ax, x)}{(x, x)},$$

$$(3) \lambda_n = \min_{x \in R^n, x \neq 0} \frac{(Ax, x)}{(x, x)}.$$

定理： 设 $A \in R^{n \times n}$ 为对称矩阵, 特征值满足 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 对应的特征向量满足 $(x_i, x_j) = \delta_{ij}$, 则应用幂法计算 A 的主特征值 λ_1 , 规范化向量 $v^{(k)}$ 的瑞利商满足

$$\frac{(Av^{(k)}, v^{(k)})}{(v^{(k)}, v^{(k)})} = \lambda_1 + O\left(\left(\frac{\lambda_2}{\lambda_1}\right)^{2k}\right).$$

5.2.3 逆幂迭代法

应用 1: 计算非奇异矩阵 A 按模最小特征值及相应特征向量。

设 A 非奇异, 且 $0 < |\lambda_n| < |\lambda_{n-1}| \leq \cdots |\lambda_2| \leq |\lambda_1|$, 则 A 的按模最小特征值 λ_n 的倒数恰好为 A^{-1} 的按模最大特征值。对 A^{-1} 应用幂法即可求得最小特征值及其对应的特征向量。

算法：选取 $\boldsymbol{v}^{(0)} \neq 0$ ，对 $k = 1, 2, \dots$ ，按照如下迭代格式计算

$$\begin{cases} \boldsymbol{u}^{(k+1)} = \boldsymbol{A}^{-1}\boldsymbol{v}^{(k)}, \\ m_{k+1} = \max(\boldsymbol{u}^{(k+1)}), \quad k = 1, 2, \dots \\ \boldsymbol{v}^{(k+1)} = \frac{\boldsymbol{u}^{(k+1)}}{m_{k+1}}. \end{cases}$$

则有 $m_k \rightarrow \frac{1}{\lambda_n}$ ， $\boldsymbol{v}^{(k)} \rightarrow \frac{\boldsymbol{x}_n}{\max(\boldsymbol{x}_n)}$ 。

为了避免计算 \boldsymbol{A}^{-1} ，我们往往将求 $\boldsymbol{u}^{(k+1)} = \boldsymbol{A}^{-1}\boldsymbol{v}^{(k)}$ 变为求解线性方程组 $\boldsymbol{A}\boldsymbol{u}^{(k+1)} = \boldsymbol{v}^{(k)}$ (LU 分解法)。

应用 2: 给定一个常数 p , 求 A 的最接近于 p 的特征值及其特征向量。

若矩阵 $(A - pI)^{-1}$ 存在, 则其特征值为

$$\frac{1}{\lambda_1 - p}, \frac{1}{\lambda_2 - p}, \dots, \frac{1}{\lambda_n - p}$$

对应的特征向量仍为 x_1, x_2, \dots, x_n 。

设 λ_i 为最接近 p 的特征值, 则有

$$|\lambda_i - p| < |\lambda_j - p|, \quad j \neq i$$

即 $(\lambda_i - p)^{-1}$ 为 $(A - pI)^{-1}$ 的按模最大特征值。

★ 对 $A - pI$ 实行逆幂迭代法计算 λ_i :

$$\begin{cases} (A - pI)\mathbf{u}^{(k+1)} = \mathbf{v}^{(k)}, \\ m_{k+1} = \max(\mathbf{u}^{(k+1)}), \\ \mathbf{v}^{(k+1)} = \frac{\mathbf{u}^{(k+1)}}{m_{k+1}}. \end{cases}$$

● 收敛性:

$$\mathbf{v}^{(k)} \rightarrow \frac{\mathbf{x}_i}{\max(\mathbf{x}_i)}, \quad m_k \rightarrow \frac{1}{\lambda_i - p}.$$

得 $k \rightarrow \infty$ 时, $\frac{1}{m_k} + p \rightarrow \lambda_i$ 。

例：用逆幂法求矩阵 $A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 4 \end{pmatrix}$ 在 1 附近的特征值及对应特征向量（准确值 $\lambda = 3 - \sqrt{3}$ ）。

解：计算可得

$$(A - I)^{-1} = \frac{1}{2} \begin{pmatrix} 5 & -3 & 1 \\ -3 & 3 & -1 \\ 1 & -1 & 1 \end{pmatrix}.$$

取 $\mathbf{v}^{(0)} = (1, 1, 1)^T$, 计算结果见表

k	$\mathbf{u}^{(k)T}$			$\mathbf{v}^{(k)T}$			$p + \frac{1}{\max(\mathbf{u}^{(k)})}$
0				1	1	1	
1	1.5	-0.5	0.5	1	-0.3333	0.3333	1.667
2	3.1666	-2.1666	1.6666	1	-0.6842	0.4545	1.2727
3	3.7536	-2.7536	1.0694	1	-0.7336	0.2849	1.2664
4	3.7429	-2.7429	1.0093	1	-.07328	0.2697	1.2671
5	3.7341	-2.7341	1.0013	1	-0.7322	0.2681	1.2678
6	3.7324	-2.7324	1.0001	1	-0.7321	0.2680	1.2679
7	3.7322	-2.7322	1.0001	1	-0.7321	0.2680	1.2679

从而 $\lambda_j \approx 1.2679$, 特征向量 $(1, -0.7321, 0.2680)^T$ 。

5.3 QR 算法

结合对矩阵特征值的估计，理论上可以利用逆幂迭代法计算所有的特征值，但这种方法计算量很大。能否用方便的方法求出所有特征值？

问题1：什么样的矩阵的特征值最好求？

回答1： 对角矩阵，上（下）三角矩阵，特征值就是主对角线元素。

问题2： 如何将一个矩阵化为对角阵或上（下）三角矩阵，而且还保持特征值不变？

回答2： 利用正交相似变换，即使对于矩阵 A ，找一个正交矩阵 Q ，使得 $QAQ^T = B$ ，其中 B 是一个对角阵，或者上(下)三角矩阵，而 B 的对角线元素就是特征值。

如何构造？ QR算法（二十世纪十大算法占2席）

5.3.1 矩阵的 QR 分解

1. 定义(QR分解): 设 $A \in \mathbb{R}^{n \times n}$, 如果存在 n 阶正交矩阵 Q 和 n 阶上三角矩阵 R , 使得

$$A = QR$$

则称该分解为矩阵 A 的 QR 分解。

5.3.1 矩阵的 QR 分解

1. 定义(QR分解): 设 $A \in \mathbb{R}^{n \times n}$, 如果存在 n 阶正交矩阵 Q 和 n 阶上三角矩阵 R , 使得

$$A = QR$$

则称该分解为矩阵 A 的 QR 分解。

写成分量形式, 即

$$(\mathbf{a}_1, \mathbf{a}_2, \cdots, \mathbf{a}_n) = (\mathbf{q}_1, \mathbf{q}_2, \cdots, \mathbf{q}_n) \begin{pmatrix} r_{11} & r_{1,2} & \cdots & r_{1,n} \\ & r_{22} & & r_{2,n} \\ & & \ddots & \vdots \\ & & & r_{n,n} \end{pmatrix},$$

由此可得,

$$\begin{cases} \mathbf{a}_1 = r_{1,1} \cdot \mathbf{q}_1, \\ \vdots \\ \mathbf{a}_k = r_{1,k} \cdot \mathbf{q}_1 + r_{2,k} \cdot \mathbf{q}_2 + \cdots + r_{k,k} \cdot \mathbf{q}_k, \\ \vdots \\ \mathbf{a}_n = r_{1,n} \cdot \mathbf{q}_1 + r_{2,n} \cdot \mathbf{q}_2 + \cdots + r_{n,n} \cdot \mathbf{q}_n. \end{cases}$$

由此可见, 矩阵 A 的 QR 分解, 实际上是要找到一组正交基 $\mathbf{q}_1, \mathbf{q}_2, \cdots, \mathbf{q}_n$ 来对 A 的列向量 $\mathbf{a}_1, \mathbf{a}_2, \cdots, \mathbf{a}_n$ 进行线性表示, 其中 R 的列向量就是对应的表示系数。

2. Schmidt 正交化与 QR 分解

定理5.5: 设 $A \in \mathbb{R}^{n \times n}$ 为非奇异矩阵, 存在 n 阶正交矩阵 Q 和 n 阶上三角矩阵 R , 使得

$$A = QR,$$

且当 R 的对角元素为正时, 该分解是唯一的。

证明: 由于矩阵 $A = (a_1, a_2, \dots, a_n)$ 为非奇异矩阵, 则 a_1, a_2, \dots, a_n 是线性无关的。利用 Schmidt 正交化和向量标准化, 可得到标准正交向量组 q_1, q_2, \dots, q_n 。

首先, 根据 Gram-Schmidt 正交化过程:

$$\begin{cases} b_1 = a_1, & q_1 = \frac{b_1}{\|b_1\|_2}, \\ b_k = a_k - \sum_{j=1}^{k-1} l_{j,k} q_j, & l_{j,k} = (a_k, q_j), \\ q_k = \frac{b_k}{\|b_k\|_2}, & k = 2, 3, \dots, n. \end{cases}$$

于是, 有

$$\begin{cases} a_1 = \|b_1\|_2 q_1, & \|b_1\|_2 = \|a_1\|_2, \\ a_k = \sum_{j=1}^{k-1} l_{j,k} q_j + \|b_k\|_2 q_k, \\ \|b_k\|_2 = \sqrt{\|a_k\|_2^2 - \sum_{j=1}^{k-1} l_{j,k}^2}, & k = 2, 3, \dots, n. \end{cases}$$

上式可用矩阵形式表示为

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n) = \underbrace{(\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n)}_{\mathbf{Q}} \underbrace{\begin{pmatrix} \|\mathbf{b}_1\|_2 & l_{1,2} & \cdots & l_{1,n} \\ 0 & \|\mathbf{b}_2\|_2 & \cdots & l_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \|\mathbf{b}_n\|_2 \end{pmatrix}}_{\mathbf{R}} = \mathbf{QR},$$

这里 \mathbf{Q} 满足 $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$ 为正交矩阵, \mathbf{R} 为对角线元素为正的上三角矩阵。由此, \mathbf{QR} 分解的存在性得以证明。

下面证明 QR 分解的唯一性。

假设存在两个 QR 分解：

$$A = Q_1 R_1 = Q_2 R_2,$$

由于 R_1 和 R_2 的主对角线元素为正，因此 R_1 和 R_2 可逆，由此可得

$$Q_1 R_1 = Q_2 R_2 \Rightarrow Q_1 = Q_2 (R_2 R_1^{-1}) = Q_2 D,$$

其中 $D = R_2 R_1^{-1}$ 也是一个上三角矩阵。

由于

$$D^T D = D^T Q_2^T Q_2 D = (Q_2 D)^T (Q_2 D) = Q_1^T Q_1 = I.$$

因此, D 是一个正交矩阵, 又由于 D 是一个上三角矩阵, 因此 D 是单位矩阵, 从而得到

$$Q_1 = Q_2 D = Q_2, R_2 = D R_1 = R_1,$$

因此, 矩阵 A 的 QR 分解是唯一的。

证毕■

定理的证明不仅证明了 QR 分解的存在性和唯一性, 同时也给出了基于 Schmidt 正交化的 QR 分解实现的方法。

注: 由于舍入误差的影响, Gram-Schmidt正交化方法数值不稳定.

改进: 修正的Gram-Schmidt 正交化方法 (比GS 有改善, 但效果也不太好) .

修正的 Gram-Schmidt 正交化过程:

$$\left\{ \begin{array}{l} b_1 = a_1, \cdots, b_n = a_n, \\ q_1 = \frac{b_1}{\|b_1\|_2}, \textcolor{red}{b}_k = b_k - l_{1,k}q_1, \quad l_{1,k} = (b_k, q_1), \quad k = 2, \cdots, n, \\ q_2 = \frac{\textcolor{red}{b}_2}{\|\textcolor{red}{b}_2\|_2}, \textcolor{blue}{b}_k = \textcolor{red}{b}_k - l_{2,k}q_2, \quad l_{2,k} = (\textcolor{red}{b}_k, q_2), \quad k = 3, \cdots, n, \\ q_3 = \frac{\textcolor{blue}{b}_3}{\|\textcolor{blue}{b}_3\|_2}, \cdots \cdots \cdots \\ \cdots \cdots \cdots \\ q_n = \frac{b_n}{\|b_n\|_2}. \end{array} \right.$$

例：利用 修正的Gram-Schmidt 正交化求矩阵 A 的 QR 分解，其中

$$A = \begin{pmatrix} 0 & 3 & 1 \\ 0 & 4 & -2 \\ 2 & 1 & 1 \end{pmatrix}$$

解：矩阵 A 的列向量

$$\mathbf{a}_1 = (0, 0, 2)^T, \quad \mathbf{a}_2 = (3, 4, 1)^T, \quad \mathbf{a}_3 = (1, -2, 1)^T,$$

修正的Gram-Schmidt 正交化, 首先令

$$\mathbf{b}_1 = \mathbf{a}_1, \quad \mathbf{b}_2 = \mathbf{a}_2, \quad \mathbf{b}_3 = \mathbf{a}_3,$$

第一步, 取向量 $q_1 = \frac{b_1}{\|b_1\|_2} = (0, 0, 1)^T$,

$$b_2 = b_2 - (b_2, q_1)q_1 = (3, 4, 0)^T,$$

$$b_3 = b_3 - (b_3, q_1)q_1 = (1, -2, 0)^T,$$

第二步, 取向量 $q_2 = \frac{b_2}{\|b_2\|_2} = (3/5, 4/5, 0)^T$,

$$b_3 = b_3 - (b_3, q_2)q_2 = (8/5, -6/5, 0)^T, \quad q_3 = \frac{b_3}{\|b_3\|_2} = (4/5, -3/5, 0)^T,$$

由此得到 A 的 QR 分解为:

$$Q = \begin{pmatrix} 0 & 3/5 & 4/5 \\ 0 & 4/5 & -3/5 \\ 1 & 0 & 0 \end{pmatrix}, \quad R = Q^T A = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 5 & -1 \\ 0 & 0 & 2 \end{pmatrix}.$$

3. Householder 变换与 QR 分解

定义： 设向量 $w \in \mathbb{R}^n$ ，且 $\|w\|_2 = 1$ ，称矩阵

$$H(w) = I - 2ww^T$$


为 **Householder 矩阵**，或者 **Householder 变换**。
Householder 变换也称为镜像变换。对任意向量 x ， Hx 是 x 在以 w 为法线“镜面” S 中的像。

记 $S = \{u | w^T u = 0, \forall u \in \mathbb{R}^n\}$,

则 $x = x_1 + x_2$, $x_1 \in S$, $x_2 = \alpha w \in \text{span}\{w\}$.

$Hx = (I - 2ww^T)x = x_1 - x_2$,

其中 $\alpha = (x^T w)$ 。



定理5.6: Householder 矩阵 H 满足下面的性质:

- (1) H 为对称正交矩阵, 即 $H^T = H$, $H^{-1} = H$ 。
- (2) $\begin{pmatrix} I & 0 \\ 0 & H \end{pmatrix}$ 也是 Householder 矩阵。
- (3) 对任意两个长度相等的非零向量 (即 $\|x\|_2 = \|y\|_2$) , 取 $w = \frac{x-y}{\|x-y\|_2}$, 则 $H = I - 2ww^T$ 为一个 Householder 变换, 使得 $Hx = y$ 。
- (4) 设 u 是一个单位向量, 则对于任意 $x \in \mathbb{C}^n$, 存在 Householder 矩阵 H , 使得 $Hx = au$, 其中 $|a| = \|x\|_2$ 且 $ax^H u$ 为实数。
(取 $w = \frac{x-au}{\|x-au\|_2}$ 即可)

对于任意非零向量 $\boldsymbol{x} \in \mathbb{R}^n$, 求 Householder 变换 \boldsymbol{H} , 使得

$$\boldsymbol{H}\boldsymbol{x} = k\boldsymbol{e}_1, \quad \boldsymbol{e}_1 = (1, 0, 0, \dots, 0)^T.$$

根据性质(4), 构造 $\boldsymbol{w} = \frac{\boldsymbol{u}}{\|\boldsymbol{u}\|_2}$, $\boldsymbol{u} = \boldsymbol{x} - k\boldsymbol{e}_1$, 其中 $k = -\text{sgn}(x_1)\|\boldsymbol{x}\|_2$,

$$\text{sgn}(x) = \begin{cases} 1, & x \geq 0 \\ -1 & x < 0 \end{cases}.$$

$$\boldsymbol{u} = \boldsymbol{x} - (-\text{sgn}(x_1)\|\boldsymbol{x}\|_2)\boldsymbol{e}_1 = (x_1 + \text{sgn}(x_1)\|\boldsymbol{x}\|_2, x_2, \dots, x_n)^T,$$

则有 $\|\boldsymbol{u}\|_2^2 = 2\|\boldsymbol{x}\|_2(\|\boldsymbol{x}\|_2 + |x_1|)$ 。

从而, 得到 Householder 变换为

$$\boldsymbol{H} = \boldsymbol{I} - 2\boldsymbol{w}\boldsymbol{w}^T = \boldsymbol{I} - 2\frac{\boldsymbol{u}\boldsymbol{u}^T}{\|\boldsymbol{u}\|_2^2} = \boldsymbol{I} - \beta\boldsymbol{u}\boldsymbol{u}^T, \quad \beta = [\|\boldsymbol{x}\|_2(\|\boldsymbol{x}\|_2 + |x_1|)]^{-1}.$$

基于 Householder 变换的 QR 分解

基本思想：利用 Householder 变换，对矩阵 A 的每一列进行逐列消元，变为一个上三角矩阵。

对 $A = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$ ，记 $A^{(1)} = A$ ，

(1) 对于 $\mathbf{a}_1^{(1)} = (a_{11}^{(1)}, a_{21}^{(1)}, \dots, a_{n1}^{(1)})^T$ ，

构造

$$\begin{cases} r_{11} = -\operatorname{sgn}(a_{11}^{(1)}) \|\mathbf{a}_1^{(1)}\|_2, \\ \mathbf{u}_1 = \mathbf{a}_1^{(1)} - r_{11} \mathbf{e}_1 = (a_{11}^{(1)} + \operatorname{sgn}(a_{11}^{(1)}) \|\mathbf{a}_1^{(1)}\|_2, a_{21}^{(1)}, \dots, a_{n1}^{(1)})^T, \\ \beta_1 = \left[\|\mathbf{a}_1^{(1)}\|_2 (\|\mathbf{a}_1^{(1)}\|_2 + |a_{11}^{(1)}|) \right]^{-1}, \\ \mathbf{H}_1 = \mathbf{I} - \beta_1 \mathbf{u}_1 \mathbf{u}_1^T. \end{cases}$$

则

$$H_1 A^{(1)} = \begin{pmatrix} r_{11} & * & \cdots & * \\ 0 & a_{22}^{(2)} & & a_{2n}^{(2)} \\ 0 & & & \\ 0 & a_{n2}^{(2)} & & a_{nn}^{(2)} \end{pmatrix} = \begin{pmatrix} r_{11} & * \\ \mathbf{0} & A^{(2)} \end{pmatrix},$$

其中 $A^{(2)} = (a_2^{(2)}, a_3^{(2)}, \cdots, a_n^{(2)})$, $a_k^{(2)} = (a_{2k}^{(2)}, a_{3k}^{(2)}, \cdots, a_{nk}^{(2)})^T$, $k = 2, 3, \cdots, n$ 。

然后, 下面再考虑对 $A^{(2)}$ 的第一列向量进行消元。

假设经过 $k - 1$ 次消元后得到:

$$\mathbf{H}_{k-1} \cdots \mathbf{H}_1 \mathbf{A} = \begin{pmatrix} r_{1,1} & * & \cdots & * \\ 0 & \ddots & \ddots & \vdots \\ \vdots & & r_{k-1,k-1} & * \\ 0 & \cdots & 0 & \mathbf{A}^{(k)} \end{pmatrix},$$

$$\mathbf{A}^{(k)} = \left(\mathbf{a}_k^{(k)}, \mathbf{a}_{k+1}^{(k)}, \cdots, \mathbf{a}_n^{(k)} \right),$$

$$\mathbf{a}_j^{(k)} = \left(a_{k,j}^{(k)}, a_{k+1,j}^{(k)}, \cdots, a_{n,j}^{(k)} \right)^T.$$

(2) 对于 $\mathbf{a}_k^{(k)} = (a_{k,k}^{(k)}, a_{k+1,k}^{(k)}, \dots, a_{n,k}^{(k)})^T$, 构造

$$\left\{ \begin{array}{l} r_{k,k} = -\operatorname{sgn}(a_{k,k}^{(k)}) \|\mathbf{a}_k^{(k)}\|_2, \\ \mathbf{u}_k = \mathbf{a}_k^{(k)} - r_{k,k} \mathbf{e}_1^{(k)} = (a_{k,k}^{(k)} + \operatorname{sgn}(a_{k,k}^{(k)}) \|\mathbf{a}_k^{(k)}\|_2, a_{k+1,k}^{(k)}, \dots, a_{n,k}^{(k)})^T, \\ \beta_k = \left[\|\mathbf{a}_k^{(k)}\|_2 (\|\mathbf{a}_k^{(k)}\|_2 + |a_{k,k}^{(k)}|) \right]^{-1}, \\ \mathbf{H}_k = \begin{pmatrix} \mathbf{I}_{(k-1) \times (k-1)} & 0 \\ 0 & \mathbf{I}_{(n-k+1) \times (n-k+1)} - \beta_k \mathbf{u}_k \mathbf{u}_k^T \end{pmatrix}. \end{array} \right.$$

其中 $k = 2, 3, \dots, n$.

根据上述方法, 可以构造出 $n-1$ 个 Householder 矩阵 H_1, H_2, \dots, H_{n-1} , 使得

$$H_{n-1} \cdots H_2 H_1 A = R = \begin{pmatrix} r_{1,1} & * & \cdots & * \\ & r_{2,2} & \ddots & \vdots \\ & & \ddots & * \\ & & & r_{n,n} \end{pmatrix}.$$

由于 H_1, H_2, \dots, H_{n-1} 都是正交矩阵, 因此 $Q = (H_{n-1} \cdots H_1)^T$ 也是正交矩阵, 从而得到矩阵 A 的 QR 分解为

$$A = QR.$$

例： 利用 Householder 变换求矩阵

$$A = \begin{pmatrix} 0 & 3 & 1 \\ 0 & 4 & -2 \\ 2 & 1 & 1 \end{pmatrix}$$

的 QR 分解。

解： (1) 对 $\mathbf{a}_1^{(1)} = (0, 0, 2)^T$, $\|\mathbf{a}_1^{(1)}\|_2 = 2$, 则

$$r_{11} = -2, \quad \mathbf{u}_1 = (2, 0, 2)^T, \quad \beta_1 = \frac{1}{4}$$

$$H_1 = I - \frac{1}{4} \begin{pmatrix} 2 \\ 0 \\ 2 \end{pmatrix} (2, 0, 2) = \begin{pmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ -1 & 0 & 0 \end{pmatrix},$$

从而得到:

$$\mathbf{H}_1 \mathbf{A} = \begin{pmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ -1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 3 & 1 \\ 0 & 4 & -2 \\ 2 & 1 & 1 \end{pmatrix} = \begin{pmatrix} -2 & -1 & -1 \\ 0 & 4 & -2 \\ 0 & -3 & -1 \end{pmatrix}.$$

(2) 对 $\mathbf{a}_2^{(2)} = (4, -3)^T$, $\|\mathbf{a}_2^{(2)}\|_2 = 5$, 则 $r_{22} = -5$, $\mathbf{u}_2 = (9, -3)^T$, $\beta_2 = \frac{1}{45}$

$$\tilde{\mathbf{H}}_2 = \mathbf{I} - \frac{1}{45} \begin{pmatrix} 9 \\ -3 \end{pmatrix} \begin{pmatrix} 9 & -3 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} -4 & 3 \\ 3 & 4 \end{pmatrix},$$

$$\mathbf{H}_2 = \begin{pmatrix} \mathbf{I} & \\ & \tilde{\mathbf{H}}_2 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} 5 & 0 & 0 \\ 0 & -4 & 3 \\ 0 & 3 & 4 \end{pmatrix},$$

从而得到

$$\tilde{H}_2 A^{(2)} = \frac{1}{5} \begin{pmatrix} -4 & 3 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 4 & -2 \\ -3 & -1 \end{pmatrix} = \begin{pmatrix} -5 & 1 \\ 0 & -2 \end{pmatrix},$$

$$\begin{aligned} H_2(H_1 A) &= \begin{pmatrix} I & 0 \\ 0 & \tilde{H}_2 \end{pmatrix} \left(\begin{array}{c|cc} -2 & -1 & -1 \\ \hline 0 & & \\ 0 & & A^{(2)} \end{array} \right) = \begin{pmatrix} -2 & -1 & -1 \\ \hline 0 & & \\ 0 & & \tilde{H}_2 A^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} -2 & -1 & -1 \\ & -5 & 1 \\ & & -2 \end{pmatrix}. \end{aligned}$$

H_2H_1A 已经是一个上三角阵, 若要得到对角元全为正的上三角阵, 令 $D = \text{diag}(-1, -1, -1)$, 则

$$R = DH_2H_1A = \begin{pmatrix} 2 & -1 & -1 \\ & 5 & -1 \\ & & 2 \end{pmatrix},$$

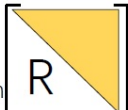
于是

$$Q = H_1H_2D^{-1} = \begin{pmatrix} 0 & 0.6 & 0.8 \\ 0 & 0.8 & -0.6 \\ 1 & 0 & 0 \end{pmatrix}.$$

关于 Householder 变换几点说明:

注1 对矩阵进行QR分解时, Householder 变换与 Schmidt 正交化方法计算量相当 $O(n^3)$, 但Householder 变换数值稳定性良好;

注2 由于 Householder 变换是按列逐列操作的, 因此实际上可以处理不是方阵的情况: 如对于 $A \in \mathbb{R}^{m \times n}, m > n$, 也存在正交矩阵 Q , 使得

$$\begin{bmatrix} A \\ m \times n \end{bmatrix} = Q_{m \times m} \begin{bmatrix} R \\ m \times n \end{bmatrix}$$


从基的表示角度看, $A = QR$ 实际上是找到一组正交基 (即 Q 的列向量) 来对 A 中的列向量进行表示, 表示系数则是对应的 R 中的列。

4. Givens 变换与 QR 分解

我们知道, 在平面 \mathbb{R}^2 上, 将一个向量 x 绕原点顺时针旋转 θ 角度得到向量 y , 该旋转变换可表示为

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = T x = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

这里, $T = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix}$ 被称为**旋转变换**。

将二维空间中的旋转变换推广到 n 维空间, 就得到 Givens 变换。

定义(Givens变换): 称下面的 n 阶正交矩阵为 Givens 矩阵 (变换)

$$J(i, k, \theta) = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & \cos \theta & & \sin \theta \\ & & & & 1 & \\ & & & & & \ddots \\ & & & & & & 1 \\ & & & -\sin \theta & & \cos \theta & \\ & & & & & & & 1 \\ & & & & & & & & \ddots \\ & & & & & & & & & 1 \end{pmatrix}$$

第 i 行

第 k 行

对于任意向量 $x \in \mathbb{R}^n$ ，对其进行 Givens 变换 $y = J(i, k, \theta)x$ ，可得

$$\begin{cases} y_i = x_i \cos \theta + x_k \sin \theta, \\ y_k = x_k \cos \theta - x_i \sin \theta, \\ y_j = x_j, \end{cases} \quad j \neq i, j \neq k$$

若要使得 $y_k = 0$ ，只需要取 $\theta = \theta_{i,k}$ ，其中

$$\cos \theta_{i,k} = \frac{x_i}{\sqrt{x_i^2 + x_k^2}}, \quad \sin \theta_{i,k} = \frac{x_k}{\sqrt{x_i^2 + x_k^2}},$$

此时 $y_k = 0, y_i = \sqrt{x_i^2 + x_k^2}$ ，而其他的分量都不变。

说明： Givens 变换可以利用向量中的某一个分量，把另外一个分量变为0，而保持其他分量都不变，这意味着可以用正交变换**逐分量消元**！

利用 Givens 变换进行 QR 分解

类似于高斯消去法, 在第 k 步, 利用 $A^{(k)}$ 的当前第 k 列的对角线元素 $a_{k,k}^{(k)}$, 利用相应的 Givens 变换 $J^{(k)}(k, j, \theta_{k,j})$ 将当前的 $a_{j,k}^{(k)}, j > k$ 依次变为零。需要注意的是, $J^{(k)}(k, j, \theta_{k,j})A^{(k)}$ 在把 $a_{j,k}^{(k)}$ 变为 0 的同时, 还会改变第 j 行 ($j > k$) 的其他元素。

第1列消元:

$$\underbrace{J^{(1)}(1, n, \theta_{1,n}) \cdots J^{(1)}(1, 3, \theta_{1,3}) J^{(1)}(1, 2, \theta_{1,2})}_{P_1} A^{(1)} = P_1 A,$$

第2列消元:

$$\underbrace{J^{(2)}(2, n, \theta_{2,n}) \cdots J^{(2)}(2, 4, \theta_{2,4}) J^{(2)}(2, 3, \theta_{2,3})}_{P_2} (P_1 A) = P_2 P_1 A,$$

第 k 列消元:

$$\underbrace{J^{(k)}(k, n, \theta_{k,n}) \cdots J^{(k)}(k, k+2, \theta_{k,k+2}) J^{(k)}(k, k+1, \theta_{k,k+1})}_{P_k} (P_{k-1} \cdots P_1 A)$$

$$= P_k \cdots P_1 A,$$

由此得到

$$(P_{n-1} \cdots P_1) A = R,$$

其中 R 是一个上三角矩阵。

由于所有的 Givens 变换都是正交的, 因此所有的 P_k 也都是正交矩阵, 记 $Q = P_1^T P_2^T \cdots P_{n-1}^T$, 则 Q 是一个正交矩阵, 使得

$$A = QR.$$

例：利用 Givens 变换求矩阵

$$A = \begin{pmatrix} 4 & 4 & 0 \\ 3 & 3 & -1 \\ 0 & 1 & 1 \end{pmatrix}$$

的 QR 分解, 使 R 的对角元素为正数。

Givens 变换比较适合于稀疏矩阵的分解，而且有利于并行计算，实际计算中最常采用的还是 Householder 变换，Householder 形式化的矩阵分解方法也被认为是二十世纪十大算法之一。

对于线性方程组 $Ax = b$ ，如果得到系数矩阵 A 的 QR 分解，则可以将方程组求解转化为

$$Rx = Q^T b,$$

然后采用“回代”过程就可以得到方程组的解。

另外， QR 分解在计算特征值的问题中扮演着重要角色，能稳定计算矩阵特征值的 QR 算法也是二十世纪十大算法之一。

5.3.2 特征值求解的 QR 算法

1. 基本QR算法

假设矩阵 A 有 QR 分解

$$A = QR,$$

其中 Q 为正交矩阵, R 为上三角矩阵。若记 $B = RQ$, 则可得到

$$B = Q^T A Q,$$

即 A 与 B 是相似矩阵, 其特征值相同。继续对 B 进行 QR 分解, 重复以上步骤, 则可得到**基本 QR 算法**:

给定初值 $A_1 = A$, 对 $k = 1, 2, \dots$

$$\begin{cases} A_k = Q_k R_k, \\ A_{k+1} = R_k Q_k. \end{cases}$$

定理5.7: 由基本 QR 算法产生的迭代序列 $\{A_k\}$ 满足:

$$(1) A_{k+1} = Q_k^T A_k Q_k ;$$

$$(2) A_{k+1} = \tilde{Q}_k^T A \tilde{Q}_k ;$$

$$(3) A^k = \tilde{Q}_k \tilde{R}_k ;$$

其中 $\tilde{Q}_k = Q_1 Q_2 \cdots Q_k$, $\tilde{R}_k = R_k R_{k-1} \cdots R_1$ 。

定义: 矩阵序列 $\{A_k\}$, 当 $k \rightarrow \infty$ 时, 对角线元素均收敛, 严格下三角部分收敛到零, 则称 $\{A_k\}$ **基本收敛到上三角矩阵**。(严格上三角部分不一定收敛)

定理5.8(QR方法的收敛性): 已知 $A \in \mathbb{R}^{n \times n}$, 设 A 的 n 个特征值满足

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| > 0,$$

方阵 $X = [x_1, x_2, \cdots, x_n]$ 由 λ_i 对应的特征向量 x_i 构成 ($i = 1, 2, \cdots, n$)。设 X^{-1} 可分解为 $X^{-1} = LU$, 其中 L 为单位下三角矩阵, U 为上三角矩阵, 则基本 QR 算法产生的序列 $\{A_k\}$ 基本收敛到上三角矩阵, 其对角线元素极限为

$$\lim_{k \rightarrow \infty} a_{i,i}^{(k)} = \lambda_i, \quad i = 1, 2, \cdots, n$$

定理5.9: 若 A 为对称矩阵且满足上述定理条件, 则基本 QR 算法产生的迭代序列 $\{A_k\}$ 收敛于 $D = \text{diag}(\lambda_1, \lambda_2, \cdots, \lambda_n)$.

如果矩阵 A 具有重实根或者多重复特征值, 则由 QR 算法产生的迭代序列 $\{A_k\}$ 基本收敛于分块上三角矩阵(对角块为一阶和二阶子块), 且对角块中的每个二阶子块给出 A 的一对共轭复特征值, 每一个一阶子块给出 A 的实特征值:

$$A_k \rightarrow \begin{pmatrix} \lambda_1 & \cdots & * & * & \cdots & * \\ & \ddots & \vdots & \vdots & & \vdots \\ & & \lambda_m & * & & * \\ & & & B_1 & \cdots & * \\ & & & & \ddots & \vdots \\ & & & & & B_l \end{pmatrix}, \quad m + 2l = n,$$

其中 $B_i = \begin{pmatrix} b_{11}^{(i)} & b_{12}^{(i)} \\ b_{21}^{(i)} & b_{22}^{(i)} \end{pmatrix}$ 的特征值为 A 的一对共轭复特征值。

2. Hessenberg矩阵的QR算法

定义: 若 $B = [b_{ij}] \in \mathbb{R}^{n \times n}$, 当 $i > j + 1$ 时有 $b_{ij} = 0$, 称 B 为上Hessenberg矩阵, 如果还有 $b_{i,i-1} \neq 0$, ($i = 2, \dots, n$), 则称 B 为不可约上Hessenberg阵.

上Hessenberg阵的QR算法:

对上Hessenberg矩阵 $H_1 = H$, 对 $k = 1, 2, \dots$

$$\begin{cases} H_k = Q_k R_k, \\ H_{k+1} = R_k Q_k. \end{cases}$$

注1: $\{H_k\}$ 均为上Hessenberg阵;

注2: 每步计算量可降低为 $O(n^2)$ 。

$$\begin{pmatrix} * & * & \cdots & * & * \\ * & * & \cdots & * & * \\ & * & \cdots & * & * \\ & & \ddots & \vdots & \vdots \\ & & & * & * \end{pmatrix} \rightarrow \begin{pmatrix} \times & * & \cdots & * & * \\ 0 & * & \cdots & * & * \\ & * & \cdots & * & * \\ & & \ddots & \vdots & \vdots \\ & & & * & * \end{pmatrix} \rightarrow \begin{pmatrix} \times & * & \cdots & * & * \\ 0 & \times & \cdots & * & * \\ & 0 & \cdots & * & * \\ & & \ddots & \vdots & \vdots \\ & & & * & * \end{pmatrix}$$

定理5.12: 对任意矩阵 $A \in \mathbb{R}^{n \times n}$, 存在正交矩阵 Q , 使

$$B = Q^T A Q$$

为一个上Hessenberg阵.(可通过Householder相似变换实现.)

$$(H_1 \cdots H_{n-3} H_{n-2})^T A (H_1 H_2 \cdots H_{n-2}) \rightarrow B = \begin{pmatrix} * & * & \cdots & * & * \\ * & * & \cdots & * & * \\ & * & \cdots & * & * \\ & & \ddots & \vdots & \vdots \\ & & & * & * \end{pmatrix}.$$

一般矩阵的 QR 算法:

- (1) 利用 Householder 变换, 将 A 作相似转化为上 Hessenberg 矩阵 B :
- (2) 对上 Hessenberg 矩阵 B 执行 QR 算法, 其中 QR 分解可用 Givens 变换或者 Householder 变换实现 (此时, 每一列只需要消除一个元素即可)。

一般矩阵的 QR 算法:

- (1) 利用 Householder 变换, 将 A 作相似转化为上 Hessenberg 矩阵 B :
- (2) 对上 Hessenberg 矩阵 B 执行 QR 算法, 其中 QR 分解可用 Givens 变换或者 Householder 变换实现 (此时, 每一列只需要消除一个元素即可)。

QR 算法的计算量? 如何提高收敛速度?

设 A 的 n 个特征值满足

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| > 0,$$

且 H 为 A 经正交相似变换转化成的上 Hessenberg 阵, 对 H 的 QR 算法, 收敛快慢取决于 $\max \left| \frac{\lambda_{j+1}}{\lambda_j} \right|$, 若能找到 μ , 使得 $\left| \frac{\lambda_{j+1}-\mu}{\lambda_j-\mu} \right| < \left| \frac{\lambda_{j+1}}{\lambda_j} \right|$, 则可以提高收敛速度.

设 A 的 n 个特征值满足

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n| > 0,$$

且 H 为 A 经正交相似变换转化成的上 Hessenberg 阵, 对 H 的 QR 算法, 收敛快慢取决于 $\max \left| \frac{\lambda_{j+1}}{\lambda_j} \right|$, 若能找到 μ , 使得 $\left| \frac{\lambda_{j+1}-\mu}{\lambda_j-\mu} \right| < \left| \frac{\lambda_{j+1}}{\lambda_j} \right|$, 则可以提高收敛速度.

带原点位移的 QR 算法:

设上 Hessenberg 矩阵 $H_1 = H$, 对 $k = 1, 2, \cdots$

$$\begin{cases} H_k - \mu I = Q_k R_k, \\ H_{k+1} = R_k Q_k + \mu I. \end{cases}$$

如果 A 的特征值排序为: $|\lambda_1 - \mu| \geq |\lambda_2 - \mu| \geq \cdots \geq |\lambda_n - \mu|$,

则 H_k 的第 j 个次对角元素的收敛快慢取决于 $\left| \frac{\lambda_{j+1}-\mu}{\lambda_j-\mu} \right|^k$.

定理: 设 $H \in R^{n \times n}$ 为不可约上 Hessenberg 阵, μ 为 $H = H_1$ 的一个特征值, 则对如下方法得到的 H_2 满足: $h_{nn}^{(2)} = \mu$, $h_{n,n-1}^{(2)} = 0$.

$$\begin{cases} H_1 - \mu I = QR, \\ H_2 = RQ + \mu I. \end{cases}$$

定理: 设 $H \in R^{n \times n}$ 为不可约上 Hessenberg 阵, μ 为 $H = H_1$ 的一个特征值, 则对如下方法得到的 H_2 满足: $h_{nn}^{(2)} = \mu$, $h_{n,n-1}^{(2)} = 0$.

$$\begin{cases} H_1 - \mu I = QR, \\ H_2 = RQ + \mu I. \end{cases}$$

带原点位移的 QR 算法:

设上 Hessenberg 矩阵 $H_1 = H$, 对 $k = 1, 2, \dots$, 取 $\mu_k = h_{nn}^{(k)}$,

$$\begin{cases} H_k - \mu_k I = Q_k R_k, \\ H_{k+1} = R_k Q_k + \mu_k I. \end{cases}$$

5.4 矩阵的奇异值分解

定义： 设 $A \in \mathbb{C}_r^{m \times n}$ ($r > 0$), $A^H A$ 的特征值为

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \cdots = \lambda_n = 0$$

则称 $\sigma_i = \sqrt{\lambda_i}$ ($i = 1, 2, \cdots, n$) 为 A 的奇异值.

定义： 设 $A, B \in C^{m \times n}$, 若存在 m 阶酉矩阵 U 和 n 阶酉矩阵 V , 使得

$$U^H A V = B$$

则称 A 与 B 酉等价。

定理5.13: 酉等价矩阵有相同的奇异值。

定理5.14: 设 $A \in \mathbb{C}_r^{m \times n}$ ($r > 0$), 则存在 m 阶酉矩阵 U 和 n 阶酉矩阵 V , 使得

$$U^H A V = \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix},$$

其中 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, 这里 σ_i 为 A 的非零奇异值。而

$$A = U \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix} V^H,$$

称之为 A 的奇异值分解。

证明： 存在 n 阶酉矩阵 V 使得

$$V^H A^H A V = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \begin{pmatrix} \Sigma^2 & 0 \\ 0 & 0 \end{pmatrix},$$

将 V 分块为

$$V = (V_1, V_2), \quad (V_1 \in \mathbb{C}^{n \times r}, V_2 \in \mathbb{C}^{n \times (n-r)}),$$

得 $V_1^H A^H A V_1 = \Sigma^2$, $V_2^H A^H A V_2 = 0$, 于是

$$\Sigma^{-1} V_1^H A^H A V_1 \Sigma^{-1} = I_r, \quad (A V_2)^H (A V_2) = 0,$$

从而 $A V_2 = 0$.

又记 $U_1 = AV_1\Sigma^{-1}$, 则 $U_1^H U_1 = I_r$, 即 U_1 的 r 个列是两两正交的单位向量, 取 $U_2 \in \mathbb{C}^{m \times (m-r)}$ 使 $U = (U_1, U_2)$ 为 m 阶酉矩阵, 即

$$U_2^H U_1 = 0, \quad U_2^H U_2 = I_{m-r},$$

则有

$$\begin{aligned} U^H AV &= \begin{pmatrix} U_1^H \\ U_2^H \end{pmatrix} A(V_1, V_2) = \begin{pmatrix} U_1^H AV_1 & U_1^H AV_2 \\ U_2^H AV_1 & U_2^H AV_2 \end{pmatrix}, \\ &= \begin{pmatrix} U_1^H(U_1\Sigma) & 0 \\ U_2^H(U_1\Sigma) & 0 \end{pmatrix} = \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix}. \end{aligned}$$

求 A 的奇异值分解步骤:

(1) 求酉矩阵 V 使 $V^H A^H A V = \begin{pmatrix} \Sigma^2 & 0 \\ 0 & 0 \end{pmatrix}$;

(2) 将 V 分块为

$$V = (V_1, V_2), \quad (V_1 \in \mathbb{C}^{n \times r}, V_2 \in \mathbb{C}^{n \times (n-r)}),$$

计算 $U_1 = A V_1 \Sigma^{-1}$;

(3) 取 U_2 使 $U = (U_1, U_2)$ 为 m 阶酉矩阵, 则

$$A = U \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix} V^H$$

为 A 的奇异值分解.

例： 求 $A = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$ 的奇异值分解.

解： $A^T A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$, 所以 $A^T A$ 的特征值为 $\lambda_1 = 3$, $\lambda_2 = 1$, $\lambda_3 = 0$,

对应的特征向量为 $\mathbf{p}_1 = (2, 1, 1)^T$, $\mathbf{p}_2 = (0, -1, 1)^T$, $\mathbf{p}_3 = (-1, 1, 1)^T$,
经过标准化后, 可得

$$V = (\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3) = \begin{pmatrix} \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{pmatrix},$$

使得 $V^H A^H A V = \text{diag}(3, 1, 0)$ 。

计算

$$U_1 = AV_1\Sigma^{-1} = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{2}{\sqrt{6}} & 0 \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix},$$

取 $U = U_1$ 是酉矩阵。

故 A 的奇异值分解为

$$A = U \begin{pmatrix} \Sigma & 0 \end{pmatrix} V^H = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ 0 & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \end{pmatrix}.$$