



数 理 统 计

开课院系：数学与统计学院概率与统计系

教师：成灵妍 副教授

邮箱：cly@njust.edu.cn

上节回顾

充分统计量

设总体 X 的分布族为 $\{p(x;\theta), \theta \in \Theta\}$, X_1, X_2, \dots, X_n 是 $F(x;\theta)$ 的样本, $T(X_1, X_2, \dots, X_n)$ 是一个统计量.

若在已知 T 的条件下, (X_1, X_2, \dots, X_n) 的条件分布与 θ 无关, 则称 T 为参数 θ 的充分统计量.

因子分解定理

T 是参数 θ 的充分统计量当且仅当 $p_\theta(x_1, x_2, \dots, x_n)$ 可以分解为

$$p_\theta(x_1, x_2, \dots, x_n) = g_\theta(T(x_1, x_2, \dots, x_n))h(x_1, x_2, \dots, x_n)$$

主观题 1分



习题4: 设 X_1, X_2 是来自 $N(0,1)$ 的样本, 试求常数 k , 使得

$$P\left(\frac{(X_1 + X_2)^2}{(X_1 - X_2)^2 + (X_1 + X_2)^2} > k\right) = 0.05.$$

作答

单选题 1分



习题5: 设总体 $X \sim N(\mu, \sigma^2)$, \bar{X} 为该总体的样本均值, 则 $P(\bar{X} < \mu) = ?$

☐ A $< 1/2$

☐ B $> 1/2$

☒ C $= 1/2$

☐ D $= 1/4$

提交

主观题 1分

设置

习题6: 设总体 X 服从正态分布 $N(0,1)$, X_1, X_2, \dots, X_8 是它的简单随机样本, 设

$$Y = (X_1 + X_2 + X_3 + X_4)^2 + (X_5 + X_6 + X_7 + X_8)^2,$$

试决定常数 c , 使得 cY 服从卡方分布.

正常使用主观题需2.0以上版本雨课堂

作答

第七章

参数估计



第七章 参数估计



例子:

某公司要采购一批产品, 每件产品不是合格品就是不合格品, 但是该产品总有一个不合格品率 p . 由此, 若从该批产品中随机抽取一件, 用 X 表示抽出产品的不合格品数, 不难看出 X 服从二点分布 $B(1, p)$, 但分布中的参数 p 确实不知道的. 显然, p 的大小决定了该产品的质量, 它直接影响采购行为的经济效益. 因此, 人们会对 p 提出一些问题, 比如:

- (1) p 的大小如何——点估计
- (2) p 大概落在什么范围内——区间估计

第七章 参数估计



§7.1 参数的点估计

★ 点估计的概念

定义: 设 θ 为总体 $\mathbf{X} \sim F(\mathbf{x}; \theta)$, $\theta \in \Theta$ 的待估计参数, 若取样本 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 的一个统计量

$$\hat{\theta} = \hat{\theta}(\mathbf{X}_1, \dots, \mathbf{X}_n)$$

来估计 θ , 则称 $\hat{\theta}$ 为 θ 的一个估计量. 称 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 为 θ 的估计值, 并仍记为 $\hat{\theta}$.



§7.1 参数的点估计

★ 点估计的概念

由于估计值 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 是 \mathbf{R} 上的一个点，故称这种估计为**点估计**。

注：上述定义中，若考虑多个未知参数时， θ 也可以看成一个向量，即 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ ，表示有 k 个未知参数，则 $\hat{\theta}_i = \hat{\theta}_i(X_1, X_2, \dots, X_n)$ 为 θ_i 的估计量。



§7.1 参数的点估计

★ 点估计的两种方法

1 矩估计法

2 最大似然估计法



§7.1 参数的点估计

★ 矩估计法——皮尔逊（1890）替换原理（矩法）

矩估计法是以样本矩作为相应的总体矩的估计。

样本原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ，总体原点矩 $a_k = E(X^k)$ 。

即当一个参数可以表达成某些总体矩的函数时，就以样本矩的同一函数作为那个参数的估计。

样本中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ ，总体中心矩 $b_k = E((X - EX)^k)$



§7.1 参数的点估计

★ 矩估计的依据原理

回忆：辛钦大数定律

若 $\{X_k\}_{k=1,2,\dots}$ 为独立同分布随机变量序列，

$EX_k = \mu$ 存在， $k=1, 2, \dots$ 则

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

§7.1 参数的点估计

★ 矩估计的依据原理

引理: $X_1, \dots, X_n \stackrel{iid}{\sim} X$,

$$A_m = \frac{1}{n} \sum_{i=1}^n X_i^m \xrightarrow{P} E(X^m), \quad m=1, 2, \dots$$

证明: 令 $Y_i = X_i^m, i=1, 2, \dots$, 则随机变量序列 $\{Y_i\}_{i=1, 2, \dots}$ 独立同分布, 且 $E(Y_i) = E(X_i^m), i=1, 2, \dots$
由辛钦大数定理知

$$A_m = \frac{1}{n} \sum_{i=1}^n X_i^m \xrightarrow{P} E(X^m), \quad m=1, 2, \dots$$

§7.1 参数的点估计

★ 矩估计的方法与技巧

设 $X_1, X_2, \dots, X_n \sim X, i.i.d.$, X 的分布函数为 $F(x; \theta_1, \theta_2, \dots, \theta_k)$, 含有 k 个未知参数. 设总体至少存在 k 阶原点矩, i. e. $E(X^k)$ 存在. 记 $a_l = E(X^l) = g_l(\theta_1, \theta_2, \dots, \theta_k), l=1, 2, \dots, k$.

若样本的 l 阶原点矩为 $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, l=1, 2, \dots, k$,

§7.1 参数的点估计

★ 矩估计的方法与技巧

则由如下 k 个方程解出 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$,

$$\begin{cases} a_1 = E(X) = g_1(\theta_1, \theta_2, \dots, \theta_k) \\ a_2 = E(X^2) = g_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \\ a_k = E(X^k) = g_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$

从中解出未知参数 $\theta_j, j=1, 2, \dots, k$,

$\theta_j = \theta_j(a_1, a_2, \dots, a_k)$, 再用 A_l 替换 a_l , 得到 θ 的估计

$$\hat{\theta}_j = \hat{\theta}_j(A_1, A_2, \dots, A_k) = \hat{\theta}_j(X_1, X_2, \dots, X_n), \\ j=1, 2, \dots, k.$$

§7.1 参数的点估计

★ 矩估计的方法与技巧

注意:

- (1) 有 k 个未知数就取 k 个方程从而解出全部未知参数;
- (2) 未知参数 $\theta_1, \dots, \theta_k$ 在方程组的右边
- (3) 解出未知参数后, 再用样本矩替换总体矩, 从而得到未知参数的估计。

按上述方法求出的 $\hat{\theta}_j, j=1, 2, \dots, k$,

称为未知参数 $\theta_j (j=1, 2, \dots, k)$ 的矩法估计。

第七章 参数估计

§7.1 参数的点估计

★ 矩估计的方法步骤总结（先解方程再替换）

1 求出总体前 k 阶原点矩, 注意是关于 $\theta_1, \theta_2, \dots, \theta_k$ 的函数:

$$a_l = E(X^l) = g_l(\theta_1, \theta_2, \dots, \theta_k), l = 1, 2, \dots, k;$$

2 从这 k 个方程中解出 $\theta_1, \theta_2, \dots, \theta_k$:

$$\theta_j = \theta_j(a_1, a_2, \dots, a_k), j = 1, 2, \dots, k;$$

3 用 A_l 替换 a_l , 得到 θ 的估计

$$\hat{\theta}_j = \hat{\theta}_j(A_1, A_2, \dots, A_k) = \hat{\theta}_j(X_1, X_2, \dots, X_n), \\ j = 1, 2, \dots, k.$$

第七章 参数估计

§7.1 参数的点估计

★ 矩估计的方法步骤总结（先替换再解方程）

1 求出总体前 k 阶原点矩, 注意是关于 $\theta_1, \theta_2, \dots, \theta_k$ 的函数:

$$a_l = E(X^l) = g_l(\theta_1, \theta_2, \dots, \theta_k), l = 1, 2, \dots, k;$$

2 用 A_l 替换 a_l , 得到 k 个方程

$$A_l = g_l(\theta_1, \theta_2, \dots, \theta_k), l = 1, 2, \dots, k;$$

3 解出 θ 的估计 $\hat{\theta}_j$

$$\hat{\theta}_j = \hat{\theta}_j(A_1, A_2, \dots, A_k) = \hat{\theta}_j(X_1, X_2, \dots, X_n), \\ j = 1, 2, \dots, k.$$

第七章 参数估计

§7.1 参数的点估计

★ 例1 设 $X_1, \dots, X_n \stackrel{iid}{\sim} U(a, b), a < b$, 试求 \hat{a}_M 和 \hat{b}_M .

$$\text{解: } E(X) = \frac{a+b}{2}, \quad D(X) = \frac{(b-a)^2}{12},$$

$$E(X^2) = D(X) + [E(X)]^2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4},$$

$$\text{用 } A_1 = \bar{X} \text{ 代替 } E(X), \quad A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \text{ 代替 } E(X^2)$$

$$\text{得方程 } \begin{cases} A_1 = \bar{X} = \frac{a+b}{2} \\ A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4} \end{cases}$$

解之

$$\hat{a}_M = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{b}_M = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

第七章 参数估计

§7.1 参数的点估计

★ 例2 设总体 X 的概率密度为 $f(x) = \frac{1}{2\sigma} e^{-\frac{|x|}{\sigma}}$

X_1, \dots, X_n 为样本, 求参数 σ^2 的矩估计。

$$\text{解: } E(X) = \int_{-\infty}^{+\infty} \frac{x}{2\sigma} e^{-\frac{|x|}{\sigma}} dx = 0$$

$$E(X^2) = \int_{-\infty}^{+\infty} \frac{x^2}{2\sigma} e^{-\frac{|x|}{\sigma}} dx = \int_0^{+\infty} \frac{x^2}{\sigma} e^{-\frac{x}{\sigma}} dx = 2\sigma^2$$

$$\text{令 } A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \text{ 替换上述方程中的 } EX^2$$

$$\text{解得 } \hat{\sigma}^2 = \frac{1}{2n} \sum_{i=1}^n X_i^2$$

§7.1 参数的点估计

★ **例3** 设总体 X 的均值 μ , 方差 σ^2 都存在, 且 $\sigma^2 > 0$, 但 μ, σ^2 未知, 又设 X_1, \dots, X_n 是一个样本; 求: μ, σ^2 的矩估计量。

解: 因为 $EX = \mu, EX^2 = \sigma^2 + \mu^2$

令 $A_1 = \bar{X}$ 替换 EX , 令 $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ 替换 EX^2 得

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = A_2 - \hat{\mu}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

§7.1 参数的点估计

★ **Remark:** 1. 矩估计法不需要知道总体的分布, 只需要知道总体矩就可以。

2. 二维总体 (X, Y) 的相关系数 $\rho = \frac{Cov(X, Y)}{\sqrt{D(X)D(Y)}}$

$$\text{的矩估计为 } r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

3. 频率是概率的矩估计:

因为在伯努利总体 $X \sim B(1, p)$ 中, $E(X) = p$,

而样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\mu_n}{n}$ 就是频率。

§7.1 参数的点估计

★ **思考:** 矩估计是不是唯一的?

作业 P377 1

(作业) 总体密度函数为 $p(x; \theta) = \frac{2}{\theta^2}(\theta - x), 0 < x < \theta, \theta > 0$,

X_1, X_2, \dots, X_n 样本, 求未知参数 θ 的矩估计。

(思考题) 甲乙两校对员彼此独立的对同一本书的样稿进行校对, 校完后, 甲发现 a 个错别字, 乙发现 b 个错别字, 其中共同发现的错别字有 c 个, 试用矩估计给出下列两个未知参数的估计。

(1) 该书样稿的总错别字个数;

(2) 未被发现的错字数。

提示: 频率替换概率

主观题 1分

设置

设总体 X 密度函数为

$$f(x; \theta, \mu) = \frac{1}{\theta} e^{-\frac{x-\mu}{\theta}}, x > \mu, \theta > 0,$$

其中 θ, μ 是未知参数,

X_1, X_2, \dots, X_n 是 X 的样本, 求 θ, μ 的矩估计。


正常使用主观题需2.0以上版本雨课堂

作答



§7.1 参数的点估计

★ 最大似然估计小故事



这是由故事主人公自己讲述的一个真实故事



§7.1 参数的点估计

★ 最大似然估计 (maximum likelihood estimation简写MLE)

例1: 设外形完全相同的两个箱子, 甲箱子中有99个白球, 一个黑球, 乙箱子中有99个黑球, 一个白球, 今随机抽取一箱并从中随机抽取一球, 得到一个白球, 问这个球是从哪个箱子取出的?

分析: 考虑事件 $A=\{\text{取出一球为白球}\}$, 那么对于甲箱子, $P(A)=0.99$, 而对于乙箱子, $P(A)=0.01$. 现在经过一次试验 A 发生了, 那么此白球最像是从甲箱子抽出来的。这里的最像就是“最大似然”得意思。



表彰榜



塔娜



梅卜玮



姚树仁



陈昌杰



上节回顾

点估计

矩估计

用样本矩替
代总体矩

大数定律

方法步骤!!! 一定要会

§7.1 参数的点估计

★ 最大似然估计 (maximum likelihood estimation简写MLE)

*例2: 一射手击中目标的概率可能是

$$p = \frac{1}{5}, \frac{8}{15}, \frac{4}{5}.$$

现让他打三发子弹, 在不同的命中目标的次数下, 我们应该如何取 p 的估计值 \hat{p} ?

解: 令 X 表示射手命中目标的次数, 则 $X \sim B(3, p)$, 即

$$P\{X = x\} = C_3^x p^x (1-p)^{3-x} = P(x; p), \quad x = 0, 1, 2, 3$$

计算结果列表如下:

§7.1 参数的点估计

例2(续)

命中次数 x	0	1	2	3
$P(x; \frac{1}{5})$	$\frac{1728}{3375}$	$\frac{1296}{3375}$	$\frac{324}{3375}$	$\frac{27}{3375}$
$P(x; \frac{8}{15})$	$\frac{343}{3375}$	$\frac{1176}{3375}$	$\frac{1344}{3375}$	$\frac{512}{3375}$
$P(x; \frac{4}{5})$	$\frac{27}{3375}$	$\frac{324}{3375}$	$\frac{1296}{3375}$	$\frac{1728}{3375}$

因为 $P(0; \frac{1}{5}) > P(0; \frac{8}{15}) > P(0; \frac{4}{5})$,

这表明, 若他打三发子弹均未命中目标时, 取

$$\hat{p} = \frac{1}{5} \text{ 最合理.}$$

§7.1 参数的点估计

例2(续)

命中次数 x	0	1	2	3
$P(x; \frac{1}{5})$	$\frac{1728}{3375}$	$\frac{1296}{3375}$	$\frac{324}{3375}$	$\frac{27}{3375}$
$P(x; \frac{8}{15})$	$\frac{343}{3375}$	$\frac{1176}{3375}$	$\frac{1344}{3375}$	$\frac{512}{3375}$
$P(x; \frac{4}{5})$	$\frac{27}{3375}$	$\frac{324}{3375}$	$\frac{1296}{3375}$	$\frac{1728}{3375}$

由上表可得下面的结论:

打三发命中次数 $x=1$ 时, 命中率 p 的合理估计 $\hat{p} = \frac{1}{5}$;

打三发命中次数 $x=2$ 时, 命中率 p 的合理估计 $\hat{p} = \frac{8}{15}$;

打三发命中次数 $x=3$ 时, 命中率 p 的合理估计 $\hat{p} = \frac{4}{5}$.

§7.1 参数的点估计

★ 最大似然估计 (maximum likelihood estimation简写MLE)

一般说, 事件 **A** 发生的概率与参数 $\theta \in \Theta$ 有关, θ 取值不同, 则 $P(\mathbf{A})$ 也不同。因而应记事件 **A** 发生的概率为 $P(\mathbf{A}; \theta)$ 。若 **A** 发生了, 则认为此时的 θ 值应是在 Θ 中使 $P(\mathbf{A}; \theta)$ 达到最大的那一个。这就是**最大似然估计思想**。

§7.1 参数的点估计

★ 最大似然估计 (maximum likelihood estimation简写MLE)

用样本观点解释

设 X_1, X_2, \dots, X_n 是总体 X 的简单随机样本, X 分布为 $P(x; \theta_1, \theta_2, \dots, \theta_k)$, 事件 $A = \{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$, $P(A; \theta_1, \theta_2, \dots, \theta_k)$ 即观测到样本值为 (x_1, x_2, \dots, x_n) 的概率, 我们需要求 $(\theta_1, \theta_2, \dots, \theta_k)$ 使得 $P(A; \theta_1, \theta_2, \dots, \theta_k)$ 最大.

§7.1 参数的点估计

★ 最大似然估计 (离散时)

$$\begin{aligned} P\{X = x; \theta\} &= p(x; \theta), \theta \in \Theta, \text{ 则} \\ P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta) \\ &= \prod_{i=1}^n P(X_i = x_i; \theta) = \prod_{i=1}^n p(x_i; \theta) \\ \arg \max_{\theta \in \Theta} \left\{ \prod_{i=1}^n p(x_i; \theta) \right\} &= \arg \max_{\theta \in \Theta} L(\theta) = \hat{\theta}_{MLE} \end{aligned}$$

§7.1 参数的点估计

★ 最大似然估计 (连续时)

由于连续随机变量在一点的取值概率为0, 因此我们考虑样本 (X_1, X_2, \dots, X_n) 落在 (x_1, x_2, \dots, x_n) 小邻域内的概率

$$P(x_1 \leq X_1 < x_1 + \Delta x_1, \dots, x_n \leq X_n < x_n + \Delta x_n; \theta)$$

$$= \prod_{i=1}^n P(x_i \leq X_i < x_i + \Delta x_i; \theta)$$

$$\approx \prod_{i=1}^n f(x_i; \theta) \Delta x_i$$

$$\arg \max_{\theta \in \Theta} \left\{ \prod_{i=1}^n f(x_i; \theta) \Delta x_i \right\} = \arg \max_{\theta \in \Theta} \left\{ \prod_{i=1}^n f(x_i; \theta) \right\}$$

$$= \arg \max_{\theta \in \Theta} L(\theta) = \hat{\theta}_{MLE}$$

§7.1 参数的点估计

★ 似然函数

$$\text{设 } X_1, \dots, X_n \stackrel{iid}{\sim} \begin{cases} f(x; \theta), (\text{连续}) \\ P\{X = x; \theta\} = p(x; \theta), (\text{离散}) \end{cases}, \theta \in \Theta, \text{ 则称}$$

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n f(x_i; \theta), & (\text{连续}) \\ \prod_{i=1}^n p(x_i; \theta), & (\text{离散}) \end{cases}$$

为该总体的**似然函数**。

似然函数是样本的联合密度函数或分布律。

§7.1 参数的点估计

★ 最大似然估计的定义

当选取 $\hat{\theta}$ 作为 θ 的估计时, 若有 $\hat{\theta}(x_1, \dots, x_n) \in \Theta$,

使得 $L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$

即 $\hat{\theta}$ 是使得 $L(\theta)$ 达到最大值的 θ 的取值,

称 $\hat{\theta}$ 为 θ 的最大似然估计值,

称 $\hat{\theta}(X_1, \dots, X_n)$ 为 θ 的极大似然估计量, 都记为 $\hat{\theta}_{MLE}$.

§7.1 参数的点估计

★ 求最大似然估计方法与技巧

问题的提法

$P\{X = x; \theta\} = p(x; \theta), \theta \in \Theta$, 则

设 X_1, X_2, \dots, X_n 为 X 的一个样本, 其观测值为

x_1, x_2, \dots, x_n , 求 $\hat{\theta}_{MLE}$. (离散时, $X \sim p(x; \theta)$; 连续时, $X \sim f(x; \theta)$.)

§7.1 参数的点估计

★ 求最大似然估计方法与技巧

(1) 写出似然函数:

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n p(x_i; \theta), & (\text{离散}) \\ \prod_{i=1}^n f(x_i; \theta), & (\text{连续}) \end{cases},$$

(2) 求 θ 使得 $L(\theta)$ 达到最大值.

§7.1 参数的点估计

★ 如何求最大似然函数的最大值

注: 通常, 最大似然函数是可微的

方法: 求导!

$$\frac{dL(\theta)}{d\theta} = 0$$



观察最大似然函数的形式, 当样本量比较大时, 计算量大且复杂

此时考虑函数 $\ln L(\theta)$, 由于 $\ln x$ 关于 x 单调增, 所以 $L(\theta)$ 与 $\ln L(\theta)$ 在相同的点处取最大值.

可对 $\ln L(\theta)$ 求导, 令 $\frac{d \ln L(\theta)}{d\theta} = 0$.

第七章 参数估计

§7.1 参数的点估计

★ 最大似然估计的通常方法步骤总结

1 写出似然函数: $L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n p(x_i; \theta), & (\text{离散}) \\ \prod_{i=1}^n f(x_i; \theta), & (\text{连续}) \end{cases}$

2 做对数似然函数: $\ln L(\theta) = \ln L(x_1, \dots, x_n; \theta) = \begin{cases} \sum_{i=1}^n \ln p(x_i; \theta) \\ \sum_{i=1}^n \ln f(x_i; \theta) \end{cases}$

3 求导 (列似然方程)

$$\frac{d \ln L(\theta)}{d \theta} = 0, \text{一般若有解, 其解就是 } \hat{\theta}_{MLE}.$$

第七章 参数估计

§7.1 参数的点估计

★ 最大似然估计的通常方法步骤总结

注:

(1) 当似然函数不可微, 或者似然方程无解或者解不唯一时, 则需根据具体情况求似然函数的最大值;

(2) 当似然函数相对简单时, 也可以直接对其求导求出取最大值的点。

第七章 参数估计

§7.1 参数的点估计

★ 例1 设 $X \sim f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$

$X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \lambda), \text{ 求 } \hat{\lambda}_{MLE}.$

解: $L(\lambda) = \prod_{i=1}^n f(x_i; \lambda) = \prod_{i=1}^n (\lambda e^{-\lambda x_i}) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$

$\ln L(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i \quad \text{令} \quad \frac{d \ln L(\lambda)}{d \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$

$$\therefore \hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}}$$

第七章 参数估计

§7.1 参数的点估计

★ 例2 设 $X_1, \dots, X_n \stackrel{iid}{\sim} B(m, p), 0 < p < 1$, 试求 \hat{p}_{MLE} .

解: $\because L(p) = \prod_{i=1}^n \binom{m}{x_i} p^{x_i} (1-p)^{m-x_i} = \left[\prod_{i=1}^n \binom{m}{x_i} \right] p^{\sum_{i=1}^n x_i} (1-p)^{n(m-\bar{x})}$

$\ln L = \ln \left[\prod_{i=1}^n \binom{m}{x_i} \right] + \sum_{i=1}^n x_i \ln p + n(m - \bar{x}) \ln(1-p)$

令 $\frac{d \ln L}{d p} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{n(m - \bar{x})}{1-p} = 0$

解得 $\hat{p}_{MLE} = \frac{1}{m} \bar{X}$

第七章 参数估计

§7.1 参数的点估计

★ 注:

(1) 若总体分布中含有多个未知参数,

$$X_1, \dots, X_n \stackrel{iid}{\sim} \begin{cases} p(x_1, \dots, x_n; \theta_1, \dots, \theta_k) \\ f(x_1, \dots, x_n; \theta_1, \dots, \theta_k) \end{cases}, (\theta_1, \dots, \theta_k) \in \Theta$$

则可解方程组

$$\frac{\partial L}{\partial \theta_j} = 0, \text{ 或 } \frac{\partial \ln L}{\partial \theta_j} = 0, j = 1, 2, \dots, k,$$

得出 θ_j 的 MLE $\hat{\theta}_j, j = 1, 2, \dots, k$.

第七章 参数估计

§7.1 参数的点估计

★ 注:

(2) 同样, 方程组有唯一解时, $\hat{\theta}_j$ 就是 θ_j 的 MLE.例3: 设 X_1, \dots, X_n 为取自 $N(\mu, \sigma^2)$ 总体的样, 求参数 μ, σ^2 的最大似然估计.

$$\text{解 } \because L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

第七章 参数估计

§7.1 参数的点估计

$$\star \text{ 例3(续) } \ln L = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0 \end{cases}$$

$$\text{解得: } \hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

第七章 参数估计

回顾 矩估计的例子

★ 例3 设总体 X 的均值 μ , 方差 σ^2 都存在, 且 $\sigma^2 > 0$, 但 μ, σ^2 未知, 又设 X_1, \dots, X_n 是一个样本; 求: μ, σ^2 的矩估计量.解: 因为 $EX = \mu, EX^2 = \sigma^2 + \mu^2$ 令 $A_1 = \bar{X}$ 替换 EX , 令 $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ 替换 EX^2 得

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = A_2 - \hat{\mu}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

第七章 参数估计

§7.1 参数的点估计

★ 注(3)

若 $\hat{\theta}$ 是未知参数 θ 的极大似然估计,

$g(\theta)$ 具有单值反函数, 则 $g(\theta)$ 的极大似然估计为 $g(\hat{\theta})$.

例4: 设 X_1, \dots, X_n 为取自参数为 λ 的指数分布总体的样本, $a > 0$ 为一给定实数。求 $p = P\{X < a\}$ 的最大似然估计。

$$\text{解 } \because p = P\{X < a\} = \int_0^a \lambda e^{-\lambda x} dx = 1 - e^{-\lambda a}$$

关于 λ 严单, \therefore 若 $\hat{\lambda}$ 是 λ 的最大似然估计, 则 $\hat{p} = 1 - e^{-\hat{\lambda}a}$

$$\text{其中 } \hat{\lambda} = \frac{1}{\bar{X}}.$$

第七章 参数估计

§7.1 参数的点估计

★ **例5** 设 X_1, \dots, X_n 为取自 $U[a, b]$ 的样本, $a < b$ 均未知, 求参数 a, b 的最大似然估计。

解: 若按通常的做法, 得

$$L(a, b) = \begin{cases} \prod_{i=1}^n \frac{1}{b-a} = \frac{1}{(b-a)^n} & a \leq x_i \leq b, i=1, 2, \dots, n \\ 0 & \text{else} \end{cases}$$

只考虑 $a \leq x_i \leq b, i=1, 2, \dots, n$ 时,

$$\ln L(a, b) = -n \ln(b-a)$$

$$\begin{cases} \frac{\partial \ln L}{\partial a} = \frac{n}{b-a} \neq 0 \\ \frac{\partial \ln L}{\partial b} = -\frac{n}{b-a} \neq 0 \end{cases}$$

第七章 参数估计

§7.1 参数的点估计

用最大似然估计思想求

★ 例5(续)

$$L(a, b) = \begin{cases} \prod_{i=1}^n \frac{1}{b-a} = \frac{1}{(b-a)^n} & a \leq x_i \leq b, i=1, 2, \dots, n \\ 0 & \text{else} \end{cases}$$

$$= \begin{cases} \frac{1}{(b-a)^n} & a \leq \min\{x_1, \dots, x_n\} \leq \max\{x_1, \dots, x_n\} \leq b \\ 0 & \text{else} \end{cases}$$

对满足条件 $a \leq x_{(1)} \leq x_{(n)} \leq b$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

$$\text{因此取} \begin{cases} \hat{a} = X_{(1)} \\ \hat{b} = X_{(n)} \end{cases}$$

第七章 参数估计

§7.1 参数的点估计

★ **例6** 在一次试验中事件 A_1, A_2, \dots, A_r 发生的概率分别为 p_1, p_2, \dots, p_r ($p_i > 0, i=1, 2, \dots, r$), 且 $p_1 + p_2 + \dots + p_r = 1$. 设在 n 次独立试验中, 事件 A_1, A_2, \dots, A_r 分别发生 n_1, n_2, \dots, n_r 次, $n_1 + n_2 + \dots + n_r = n$, 试求参数 p_1, p_2, \dots, p_r 的最大似然估计。

解: 由于常数系数不影响取最大值的 θ , 可取似然函数为

$$L(p_1, p_2, \dots, p_r) = p_1^{n_1} p_2^{n_2} \cdots p_r^{n_r}.$$

$$\ln L(p_1, p_2, \dots, p_r) = n_1 \ln p_1 + n_2 \ln p_2 + \cdots + n_r \ln p_r.$$

如何求似然函数的最大值? ——拉格朗日数乘法

第七章 参数估计

§7.1 参数的点估计

★ 例6 回忆拉格朗日数乘法

求 $f(x, y)$ 在给定条件 $g(x, y) = 0$ 时的极值:

步骤

1. 令 $F(x, y, \lambda) = f(x, y) + \lambda g(x, y)$

2. 求导

$$\frac{\partial F(x, y, \lambda)}{\partial x} = 0$$

$$\frac{\partial F(x, y, \lambda)}{\partial y} = 0$$

$$\frac{\partial F(x, y, \lambda)}{\partial \lambda} = g(x, y) = 0$$

3. 解出 (x, y) .

第七章 参数估计

§7.1 参数的点估计

★ 例6 回忆拉格朗日数乘法

取 $g(p_1, p_2, \dots, p_r) = p_1 + p_2 + \dots + p_r - 1$, 则

$$f(p_1, p_2, \dots, p_r, \lambda) = n_1 \ln p_1 + n_2 \ln p_2 + \dots + n_r \ln p_r - \lambda g(p_1, p_2, \dots, p_r)$$

求导得:

$$\frac{n_i}{p_i} - \lambda_i = 0 \Rightarrow p_i = \frac{n_i}{\lambda}$$

$$\text{又 } p_1 + p_2 + \dots + p_r = 1,$$

$$\text{所以 } \lambda = n_1 + n_2 + \dots + n_r = n,$$

$$\hat{p}_i = \frac{n_i}{n}.$$

主观题 1分

设置

设总体 X 服从几何分布 $P(X = x) = (1 - p)^{x-1} p$,
 $x = 1, 2, \dots$, 其中 p 为未知参数, $0 < p < 1$.

设 X_1, X_2, \dots, X_n 为 X 的一个样本,
 求参数 p 的矩估计和最大似然估计.

正常使用主观题需2.0以上版本雨课堂

作答

主观题 10分

设置

设 X 的分布律为

X	0	1	2	3
p	θ^2	$2\theta(1-\theta)$	θ^2	$1-2\theta$

其中 $0 < \theta < 0.5$, 现观测到样本观测值为
 3, 1, 3, 0, 3, 1, 2, 3. 求 θ 的极大似然估计值.

作答

§7.1 参数的点估计

★ §7.1.2 估计量的优良性

1 无偏性

2 有效性

3 相合性 (一致性)

§7.1 参数的点估计

★ §7.1.2 估计量的优良性

1 无偏性

设 $\hat{\theta}$ 是参数 θ 的估计量, 如果 $\forall \theta \in \Theta$,
 $E_{\theta}(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是 θ 的无偏估计.

§7.1 参数的点估计

★ §7.1.2 估计量的优良性

注:

(1) 若 $\hat{\theta}$ 是 θ 的无偏估计量, 则
 $g(\hat{\theta}) = a\hat{\theta} + b$ 是 $g(\theta) = a\theta + b$ 的无偏估计量。

(2) 对一般函数 $g(\theta)$,
 $g(\hat{\theta})$ 一般不是 $g(\theta)$ 的无偏估计量。

§7.1 参数的点估计

★ 反例 $g(\theta) = \theta^2$

若 $\hat{\theta}$ 是 θ 的无偏估计量, 且 $D(\hat{\theta}) > 0$,
 $E(\hat{\theta}^2) = D(\hat{\theta}) + (E(\hat{\theta}))^2 > \theta^2$.

§7.1 参数的点估计

★ 例1

\bar{X} 是总体均值 μ 的无偏估计吗？

S^2 是总体方差 σ^2 的无偏估计吗？

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n EX_i = \mu$$

$$ES^2 = E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \sigma^2 \quad (\text{已证结论})$$

样本 k 阶原点矩是总体 k 阶原点矩的无偏估计吗？

§7.1 参数的点估计

★ 例1

注：

若总体 k 阶矩存在时，则样本原点矩是总体原点矩的无偏估计，但是样本中心矩则不一定，考虑二阶中心矩

$$EV^2 = E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{n-1}{n} \sigma^2 \neq \sigma^2,$$

$$\text{但 } \lim_{n \rightarrow \infty} EV^2 = \sigma^2,$$

所以它是**渐近无偏**的，即当样本量较大时，二阶样本中心矩可以近似看作是总体方差的无偏估计。

表彰榜



陈静波



白煜涵

上节回顾

思想：观测到的事件就是发生的概率最大的

最大似然估计

基本方法和步骤：

1. 写出似然函数
2. 写出对数似然函数（若似然函数易求最大值点可省去）
3. 列似然方程（求导），求出达到最大值的点
注：若求估计量就写关于样本的函数，若求估计值就把样本观测值带入求出结果

求最大值点的常用方法：

1. 求导
2. 判断函数单调性
3. 拉格朗日数乘法
4. 具体情况具体分析 $O(\cap \cap)O$

第七章 参数估计

§7.1 参数的点估计

★ 渐近无偏估计

设 $\hat{\theta}$ 是参数 θ 的估计量, 如果 $\forall \theta \in \Theta$,

$E_{\theta}(\hat{\theta}) \xrightarrow{n \rightarrow +\infty} \theta$, 则称 $\hat{\theta}$ 是 θ 的渐近无偏估计.

第七章 参数估计

§7.1 参数的点估计

★ 例2 设 $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$, 试讨论 θ 的矩估计 $\hat{\theta}_M$ 与

最大似然估计 $\hat{\theta}_{MLE}$ 的无偏性.

解 已知 $\hat{\theta}_M = 2\bar{X}$, $\hat{\theta}_{MLE} = X_{(n)}$

$\therefore E\hat{\theta}_M = E(2\bar{X}) = 2EX = 2\left(\frac{\theta}{2}\right) = \theta$, $\therefore \hat{\theta}_M$ 是 θ 的无偏估计.

$$F_{X_{(n)}}(x) = (F_X(x))^n = \begin{cases} 0 & x < 0 \\ x^n / \theta^n & 0 \leq x < \theta \\ 1 & x \geq \theta \end{cases}$$

极大值的分布

第七章 参数估计

§7.1 参数的点估计

★ 例2(续)

$$\therefore X_{(n)} \sim f_n(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 < x < \theta \\ 0, & \text{其它} \end{cases}$$

$$E\hat{\theta}_{MLE} = EX_{(n)} = \int_0^{\theta} xn \frac{x^{n-1}}{\theta^n} dx = \frac{n}{n+1} \theta \neq \theta$$

$\therefore \hat{\theta}_{MLE}$ 不是 θ 的无偏估计

第七章 参数估计

§7.1 参数的点估计

★ §7.1.2 估计量的优良性

2 有效性

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是参数 θ 的两个无偏估计,

如果对 $\forall \theta \in \Theta$, $D_{\theta}(\hat{\theta}_1) \leq D_{\theta}(\hat{\theta}_2)$,

且至少对某个 $\theta \in \Theta$ 上式中的不等号成立,

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

单选题 1分

设置

例2(补) 考虑 $\hat{\theta}_{MLE}$ 修正 $\hat{\theta} = \frac{n+1}{n} X_{(n)}$, 证明它为 θ 的无偏估计, 并比较 $\hat{\theta}$ 与 $\hat{\theta}_M$ 的有效性.

- ☐ A 矩估计更有效
- ☒ B 修正之后更有效
- ☐ C 一样有效
- ☐ D 不知道

提交

解: $\hat{\theta}_M = 2\bar{X}$ 与 $\hat{\theta} = \frac{n+1}{n} X_{(n)}$ 都是 θ 的无偏估计

$X_{(n)} = \max(X_1, X_2, \dots, X_n)$ 的概率密度函数为 $f_n(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 < x < \theta, \\ 0, & \text{其它,} \end{cases}$

$$D(2\bar{X}) = 4D(\bar{X}) = \frac{4}{n} D(X) = \frac{4}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n}$$

$$D(X_{(n)}) = \int_0^\theta x^2 \frac{n}{\theta^n} x^{n-1} dx - \frac{n^2}{(n+1)^2} \theta^2 = \frac{n}{(n+1)^2(n+2)} \theta^2$$

$$D\left(\frac{n+1}{n} X_{(n)}\right) = \frac{(n+1)^2}{n^2} \cdot \frac{n}{(n+1)^2(n+2)} \theta^2 = \frac{1}{n(n+2)} \theta^2$$

由于 $D\left(\frac{n+1}{n} X_{(n)}\right) \leq D(2\bar{X})$ 且当 $n > 1$ 时, 不等号成立, 故

$\frac{n+1}{n} X_{(n)}$ 比 $2\bar{X}$ 有效.

● 第七章 参数估计



§7.1 参数的点估计

★ §7.1.2 估计量的优良性

3 相合性 (一致性)

设 $\hat{\theta}_n$ 为样本容量为 n 时未知参数 θ 的估计量, 如果

$$\lim_{n \rightarrow +\infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0, \text{ 对一切 } \varepsilon \text{ 成立,}$$

则称 $\hat{\theta}_n$ 为 θ 的相合估计或一致估计.

● 第七章 参数估计



§7.1 参数的点估计

★ §7.1.2 估计量的优良性

3 相合性 (一致性)

样本 k 阶原点矩是总体 k 阶原点矩的相合估计吗?

§7.1 参数的点估计

★ §7.1.2 估计量的优良性

3 相合性（一致性）

定理：若 $\hat{\theta}_n$ 是 θ 的相合估计， $g(\theta)$ 是 θ 的连续函数，则 $g(\hat{\theta}_n)$ 是 $g(\theta)$ 的相合估计。

注：该定理可以推广到 θ 是向量的情形，即多个参数情形。见茆诗松书 p77 页定理 2.1.2

§7.1 参数的点估计

★ 例3 设总体 $X \sim N(\mu, \sigma^2)$ ，其中 μ 已知，而 $\sigma^2 > 0$ 为未知参数， X_1, \dots, X_n 是从该总体中抽取的一个样本。证明 σ^2 的最大似然估计是无偏估计

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

由于 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$

$$E(\hat{\sigma}^2) = E\left(\frac{\sigma^2}{n} \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}\right) = \frac{\sigma^2}{n} \times n = \sigma^2$$

主观题 1分

设置

★ 例3(续) 比较 S^2 与 $\hat{\sigma}^2$ 的有效性
判断 S^2 与 $\hat{\sigma}^2$ 的是否是 σ^2 的相合估计？

正常使用主观题需2.0以上版本雨课堂

作答

§7.1 参数的点估计

★ 渐近正态性

相合性：定性的性质

收敛的速度 ← 渐近正态性



§7.1 参数的点估计

★ 渐近正态性

定义:

称 $\hat{\theta}_n$ 是 θ 的渐近正态估计或 $\hat{\theta}_n$ 具有渐近正态性, 如果存在趋于0的非负常数序列 $\sigma_n(\theta)$, 使得

$\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布.

这时也称 $\hat{\theta}_n$ 服从渐近正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$.



§7.1 参数的点估计

★ 渐近正态性

注:

- (1) $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐近方差
- (2) $\sigma_n(\theta)$ 表示着估计量 $\hat{\theta}_n$ 依概率收敛到 θ 的速度
- (3) $\sigma_n(\theta)$ 不唯一
- (4) 渐近正态性 \Rightarrow 相合性



§7.1 参数的点估计

★ 渐近正态性

例1: 若总体的均值为 μ , 方差为 σ^2 , 证明样本均值 \bar{X} 是 μ 的渐近正态估计.



§7.1 参数的点估计

★ 渐近正态性

例2: 若总体 $X \sim N(\mu, \sigma^2)$, 证明样本方差 S^2 是 σ^2 的渐近正态估计.

表彰榜



丁子缘

上节回顾

无偏性 $E \hat{\theta} = \theta$

有效性

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是参数 θ 的两个无偏估计,
如果对 $\forall \theta \in \Theta$, $D_{\theta}(\hat{\theta}_1) \leq D_{\theta}(\hat{\theta}_2)$,
且至少对某个 $\theta \in \Theta$ 上式中的不等号成立,
则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

相合性 (一致性)

设 $\hat{\theta}_n$ 为样本容量为 n 时未知参数 θ 的估计量, 如果
 $\lim_{n \rightarrow +\infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0$, 对一切 ε 成立,
则称 $\hat{\theta}_n$ 为 θ 的相合估计或一致估计.

上节回顾

渐近正态性

称 $\hat{\theta}_n$ 是 θ 的渐近正态估计:

$\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布

$\sigma_n(\theta)$: 趋于0的非负常数序列

$\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$.

§7.1.2 一致最小方差无偏估计 (UMVUE)

判断估计量的好坏

大样本场合 \longrightarrow 相合性

小样本场合 \longrightarrow 如何判断?



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 均方误差

判断一个点估计的好坏指标，我们最自然的想法考虑的是估计量与真实参数之间的距离，即 $|\hat{\theta} - \theta|$ 。通常我们最常用的函数是距离的平方，又由于估计量的随机性，所以我们考虑 $E(\hat{\theta} - \theta)^2$ ，这个函数即为**均方误差**，记为 $MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2$ 。



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 均方误差

注：
(1)均方误差是评价点估计的最一般的标准。
(2)均方误差与方差的关系：

$$MSE(\hat{\theta}) = D(\hat{\theta}) + B^2,$$

其中 $B = E(\hat{\theta} - \theta) = E(\hat{\theta}) - \theta$ 称为偏差。



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差无偏估计

定义：若 $\hat{\theta}_0$ 是参数 θ 的一个无偏估计量，而 $\hat{\theta}$ 是参数 θ 的任意一个无偏估计量，即

$$E_{\theta}(\hat{\theta}_0) = E_{\theta}(\hat{\theta}) = \theta,$$

如果有

$$D_{\theta}(\hat{\theta}_0) \leq D_{\theta}(\hat{\theta}), \forall \theta \in \Theta$$

成立，则称 $\hat{\theta}_0$ 是 θ 的一致最小方差无偏估计，记为 UMVUE (Uniformly Minimum Variance Unbiased Estimator)。



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差无偏估计判定准则

定理：设 X_1, X_2, \dots, X_n 为来自某总体的一个样本， $\hat{\theta}(X_1, X_2, \dots, X_n)$ 是参数 θ 的一个无偏估计， $D_{\theta}(\hat{\theta}(X_1, X_2, \dots, X_n)) < +\infty$ ，则 $\hat{\theta}$ 是 θ 的 UMVUE \Leftrightarrow 对任意满足 $E_{\theta}(T(X_1, X_2, \dots, X_n)) = 0$ 且 $D_{\theta}(T(X_1, X_2, \dots, X_n)) < +\infty$ 的 $T(X_1, X_2, \dots, X_n)$ ，都有 $Cov_{\theta}(\hat{\theta}, T) = 0, \forall \theta \in \Theta$ 。



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差无偏估计判定方法

注：上述定理表明，UMVUE与任意一个均值为0，方差有限的估计量都不相关.



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差无偏估计判定方法

推论：对于参数 θ 而言，最多存在一个UMVUE.
(概率意义下)



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ **例** 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ, σ^2 未知. 试证 μ, σ^2 的一致最小方差无偏估计量分别为 \bar{X}, S^2 .
(S^2 是 σ^2 的UMVUE(作业)).

证明：若 $\hat{\theta}_1, \hat{\theta}_2$ 分别是 θ_1, θ_2 的UMVUE，则对任意的非零常数 a, b , $a\hat{\theta}_1 + b\hat{\theta}_2$ 是 $a\theta_1 + b\theta_2$ 的UMVUE.

作答

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差线性无偏估计

定义: 设 $\hat{\theta}$ 是参数 θ 的估计量, 若满足

$$(1) \hat{\theta}(X_1, X_2, \dots, X_n) = \sum_{i=1}^n C_i X_i, \text{ 其中 } C_i \text{ 为常数};$$

$$(2) E_{\theta}(\hat{\theta}) = \theta;$$

(3) 对满足上述(1)(2)的估计量 $\hat{\theta}'$, 都有

$$D_{\theta}(\hat{\theta}) \leq D_{\theta}(\hat{\theta}'), \forall \theta \in \Theta,$$

则称 $\hat{\theta}$ 是样本 X_1, X_2, \dots, X_n 线性组合类当中 θ 的一致最小方差线性无偏估计.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差线性无偏估计

例 设 X_1, X_2, \dots, X_n 是为总体 X 的一个样本, 记 μ 为总体均值, $a_i (i=1, 2, \dots, n)$ 为常数, 且

$$\sum_{i=1}^n a_i = 1.$$

(1) 证明 $\sum_{i=1}^n a_i X_i$ 是 μ 的无偏估计量.

(2) 证明在 μ 的所有形如 $\sum_{i=1}^n a_i X_i$ 的线性无偏估计中, 以 \bar{X} 最有效.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 一致最小方差线性无偏估计

定理: 设 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 是参数 θ 的 m 个相互独立的线性无偏估计量, 且有相同的方差

$$D_{\theta}(\hat{\theta}_i) = \sigma^2 < +\infty, j = 1, 2, \dots, m,$$

则统计量 $\bar{\theta} = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$ 是 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 线性组合类中

θ 的一致最小方差线性无偏估计量, 且 $D_{\theta}(\bar{\theta}) = \frac{\sigma^2}{m}$.

表彰榜



张源钧



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 充分性原则

定理:

设总体的分布为 $p(x; \theta)$, $\theta \in \Theta$, X_1, X_2, \dots, X_n 是其样本,

$T(X_1, X_2, \dots, X_n)$ 是 θ 的充分统计量,

设 $\varphi(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的一个无偏估计, 则

$$\hat{g}(T) = E(\varphi(X_1, X_2, \dots, X_n) | T)$$

也是 $g(\theta)$ 的无偏估计, 并且

$$D_\theta(\hat{g}(T)) \leq D_\theta(\varphi(X_1, X_2, \dots, X_n)), \forall \theta \in \Theta,$$

且等号成立的充要条件是

$$P(\varphi(X_1, X_2, \dots, X_n) = \hat{g}(T)) = 1.$$



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ Cramer——Rao不等式

定义 (费希尔信息量 Fisher information) :

设总体概率函数为 $f(x; \theta)$, $\theta \in \Theta$ 满足下列条件

(1) 参数空间 Θ 是直线上的一个开区间;

(2) 支撑 $S = \{x: f(x; \theta) > 0\}$ 与 θ 无关;

(3) 导数 $\frac{\partial}{\partial \theta} f(x; \theta)$ 对 $\theta \in \Theta$ 都存在;

(4) 对 $f(x; \theta)$, 积分和微分运算可以交换顺序;

(5) 期望 $E\left[\frac{\partial}{\partial \theta} \ln f(X; \theta)\right]^2$ 存在,

则称 $I(\theta) = E\left[\frac{\partial}{\partial \theta} \ln f(X; \theta)\right]^2$ 为总体分布的费希尔信息量.



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ Cramer——Rao不等式

定理 (C-R不等式) :

设 X_1, X_2, \dots, X_n 是为总体 X 的一个样本, $X \sim f(x; \theta)$,

$f(x; \theta)$ 满足上述定义中的条件, 设

$g(\theta)$ 是 Θ 的可微函数,

$\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量, 且对 Θ 中的一切 θ ,

$$g(\theta) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \hat{g}(X_1, X_2, \dots, X_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \dots dx_n$$

的微分可在积分号下进行, 即

$$g'(\theta) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \hat{g}(X_1, X_2, \dots, X_n) \left[\frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i; \theta) \right] dx_1 \dots dx_n,$$

则有 $D_\theta(\hat{g}(X_1, X_2, \dots, X_n)) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$, 称为 C-R 不等式.



§7.1.2 一致最小方差无偏估计 (UMVUE)

★ Cramer——Rao不等式

注:

(1) C-R 不等式表明在样本容量 n 给定时, 待估参数的无偏估计量的方差不可能无限小, 它有一个下界:

$$\frac{[g'(\theta)]^2}{nI(\theta)} \quad \text{称为 C-R 下界.}$$

(2) 如果有一个待估参数的无偏估计量达到了 C-R 下界, 那么该估计量就是 UMVUE.

第七章 参数估计

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 例 证明Fisher信息量的另一个计算公式

$$I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right].$$

pf: $E \left(\frac{\partial}{\partial \theta} \ln f(x; \theta) \right) = 0$

$$\begin{aligned} 0 &= \frac{\partial}{\partial \theta} E \left(\frac{\partial}{\partial \theta} \ln f(x; \theta) \right) \\ &= \frac{\partial}{\partial \theta} \int \frac{\partial}{\partial \theta} \ln f(x; \theta) f(x; \theta) dx \end{aligned}$$

积分求导交换.

$$\begin{aligned} &\int \frac{\partial^2 \ln f(x; \theta)}{(\partial \theta)^2} \cdot f(x; \theta) dx \\ &+ \int \frac{\partial \ln f(x; \theta)}{\partial \theta} \cdot \frac{\partial f(x; \theta)}{\partial \theta} dx \\ &= E \left(\frac{\partial^2 \ln f(X; \theta)}{(\partial \theta)^2} \right) \\ &+ \int \frac{\partial \ln f(x; \theta)}{\partial \theta} \cdot \frac{\partial \ln f(x; \theta)}{\partial \theta} \cdot f(x; \theta) dx \\ &= E \left(\frac{\partial^2 \ln f(X; \theta)}{(\partial \theta)^2} \right) + E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] \\ &\quad \text{" } I(\theta) \end{aligned}$$

第七章 参数估计

上节回顾

C-R不等式:

$$D_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

$\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量

$I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(x; \theta) \right]^2$ 为总体分布的费希尔信息量

第七章 参数估计

上节回顾

Fisher信息量的计算公式:

$$I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right].$$

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 例 设总体 $X \sim N(\mu, \sigma_0^2)$, σ_0^2 已知, X_1, X_2, \dots, X_n 为 X 的一个样本:

- (1) 求均值 μ 的矩估计, 并证明其无偏性;
- (2) 证明该估计量是均值 μ 的 UMVUE.

(1) 解:

因为 $E(X) = \mu$, 用 \bar{X} 替换 $E(X)$, 得 μ 的矩估计量为 \bar{X} ,

又因为 $E(\bar{X}) = \mu$, 所以 \bar{X} 是 μ 的无偏估计量.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 例(续) (2) 证明:

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma_0} e^{-\frac{(x-\mu)^2}{2\sigma_0^2}},$$

$$\ln f(x; \mu) = -\ln(\sqrt{2\pi}\sigma_0) - \frac{(x-\mu)^2}{2\sigma_0^2},$$

$$\frac{\partial \ln f(x; \mu)}{\partial \mu} = \frac{x - \mu}{\sigma_0^2},$$

$$I(\mu) = E\left[\left(\frac{X - \mu}{\sigma_0^2}\right)^2\right] = \frac{E[(X - \mu)^2]}{\sigma_0^4} = \frac{1}{\sigma_0^2},$$

$$\text{所以 C-R 下界为 } \frac{(\mu')^2}{nI(\mu)} = \frac{\sigma_0^2}{n},$$

$$\text{又 } D(\bar{X}) = \frac{\sigma_0^2}{n}, \text{ 所以 } \bar{X} \text{ 是 } \mu \text{ 的 UMVUE.}$$

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 例 设总体 $X \sim B(1, p)$, X_1, X_2, \dots, X_n 为 X 的一个样本, 证明 \bar{X} 是 p 的 UMVUE.

证明:

$E(\bar{X}) = E(X) = p$, 所以 \bar{X} 是 p 的无偏估计量,

$$D(\bar{X}) = \frac{D(X)}{n} = \frac{p(1-p)}{n}.$$

$$\text{下证 C-R 下界为 } \frac{p(1-p)}{n}.$$

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 例(续) 下证 C-R 下界为 $\frac{p(1-p)}{n}$.

$$p(x; p) = p^x (1-p)^{1-x}, x=0 \text{ 或 } 1,$$

$$\ln p(x; p) = x \ln p + (1-x) \ln(1-p),$$

$$\frac{\partial \ln p(x; p)}{\partial p} = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x-p}{p(1-p)},$$

$$I(p) = E\left[\left(\frac{X-p}{p(1-p)}\right)^2\right] = \frac{E[(X-p)^2]}{p^2(1-p)^2} = \frac{1}{p(1-p)},$$

$$\text{所以 C-R 下界为 } \frac{1}{nI(p)} = \frac{p(1-p)}{n} = D(\bar{X}),$$

所以 \bar{X} 是 p 的 UMVUE.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 总结：用C-R不等式证明UMVUE的方法步骤

设总体 $X \sim f(x; \theta)$, X_1, X_2, \dots, X_n 为 X 的一个样本,
证明 $\hat{\theta}$ 是 θ 的 UMVUE.

1 证明 $\hat{\theta}$ 是 θ 的无偏估计量, 即验证 $E(\hat{\theta}) = \theta$;

2 计算 $D(\hat{\theta})$;

3 计算 C-R 下界:

$$(1) \text{ 计算 Fisher 信息量 } I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right].$$

$$(2) \text{ C-R 下界为 } \frac{1}{nI(\theta)}$$

4 验证 C-R 下界与 $D(\hat{\theta})$ 是否相等.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 总结：用C-R不等式证明UMVUE的方法步骤

设总体 $X \sim f(x; \theta)$, X_1, X_2, \dots, X_n 为 X 的一个样本,
证明 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的 UMVUE.

1 证明 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量, 即验证 $E(\hat{g}) = g(\theta)$;

2 计算 $D(\hat{g}(X_1, X_2, \dots, X_n))$;

3 计算 C-R 下界:

$$(1) \text{ 计算 Fisher 信息量 } I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right].$$

$$(2) \text{ C-R 下界为 } \frac{[g'(\theta)]^2}{nI(\theta)}$$

4 验证 C-R 下界与 $D(\hat{g}(X_1, X_2, \dots, X_n))$ 是否相等.

§7.1.2 一致最小方差无偏估计 (UMVUE)

★ 思考

1. 如果没有达到 C-R 下界, 则 UMVUE 一定不存在吗?

有效估计:

若定理中等号成立, 即 $D_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) = \frac{[g'(\theta)]^2}{nI(\theta)}$,

则称 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的有效估计.

C-R 定理表明有效估计一定是 UMVUE, 反之不一定.

单选题 1分

设置

关于 UMVUE 下面说法错误的是

- A UMVUE 是无偏的
- B UMVUE 与零均值且方差存在的统计量都不相关
- C 至多存在一个 UMVUE (概率意义下)
- D 在样本量给定时, UMVUE 的方差可以无限小

提交

第七章 参数估计

§7.1 参数的点估计

★ 渐近正态性

条件：只考虑 θ 为一维情况

设总体 X 的密度函数为 $f(x; \theta)$, $\theta \in \Theta$, Θ 为非退化区间, 假定

(1) 对任意的 x , 偏导数

$$\frac{\partial f(x; \theta)}{\partial \theta}, \frac{\partial^2 f(x; \theta)}{\partial \theta^2}, \frac{\partial^3 f(x; \theta)}{\partial \theta^3} \text{ 对 } \forall \theta \in \Theta \text{ 都存在}$$

(2) 对 $\forall \theta \in \Theta$ 有

$$\left| \frac{\partial f(x; \theta)}{\partial \theta} \right| \leq F_1(x), \left| \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \right| \leq F_2(x), \left| \frac{\partial^3 \ln f(x; \theta)}{\partial \theta^3} \right| \leq H(x) \text{ 成立,}$$

其中

$$\int_{-\infty}^{+\infty} F_i(x) dx < +\infty, i = 1, 2. \quad \int_{-\infty}^{+\infty} H(x) f(x; \theta) dx < +\infty.$$

(3) 对 $\forall \theta \in \Theta, 0 < I(\theta) < +\infty$

第七章 参数估计

§7.1 参数的点估计

★ 渐近正态性

定理:

设 X_1, X_2, \dots, X_n 是满足上述条件总体的简单随机样本,

且设对数似然方程有唯一的解 $\hat{\theta}$, 则 $\hat{\theta}$ 是 θ 的相合渐近正态估计 (consistent Asymptotic Normal) (CAN估计) 且

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} Y \sim N(0, \frac{1}{I(\theta)})$$

$$\text{即 } \hat{\theta} \sim AN(\theta, \frac{1}{nI(\theta)}).$$

主观题 10分

设置

计算正态总体 $N(\mu, \sigma^2)$ 中 σ^2 的fisher信息量以及C-R下界, μ 已知.

作答

第七章 参数估计

§7.2 区间估计

★ 区间估计

前面介绍了估计总体未知参数 θ 的两种方法, 这两种方法都是要估计出 θ 的一个值. 从几何角度来看表示一个点, 所以这两种估计方法有称为点估计.

但有的时候, 我们还希望估计出包含未知参数 θ 的一个范围, 并且还希望知道这个范围包含 θ 的可靠程度, 这就是区间估计.

$$\theta \begin{cases} \text{点估计} \\ \text{区间估计} \end{cases} \begin{cases} \text{矩法估计} \\ \text{最大似然估计} \end{cases}$$



§7.2 区间估计

★ 定义(置信区间)

设总体 X 的分布函数为 $F(x; \theta)$, θ 为未知参数, $\theta \in \Theta$, 对于给定值 $\alpha (0 < \alpha < 1)$, 若有两个统计量

$\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 使得

$$P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha$$

对一切 $\theta \in \Theta$ 成立, 则称随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 是参数 θ 的置信度为 $1 - \alpha$ 的置信区间, $\hat{\theta}_1, \hat{\theta}_2$ 分别称为置信下限和置信上限.



§7.2 区间估计

★ 注:

(1) 参数 θ 虽然未知, 但是却是常数, 而 $\hat{\theta}_1, \hat{\theta}_2$ 是随机变量, 所以置信区间是一个随机区间.

(2) 置信区间的意思是 $(\hat{\theta}_1, \hat{\theta}_2)$ 以 $1 - \alpha$ 的概率包含参数 θ .

一般我们说 θ 的区间估计, 就是在给定置信度 $1 - \alpha$ 的情况下, 给出其置信区间.



§7.2 区间估计

★ 定义(单侧置信区间)

设总体 X 的分布函数为 $F(x; \theta)$, θ 为未知参数, $\theta \in \Theta$, 对于给定值 $\alpha (0 < \alpha < 1)$, 若存在统计量

$\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 使得

$$P\{\theta > \hat{\theta}_1\} = 1 - \alpha \text{ 对一切 } \theta \in \Theta \text{ 成立,}$$

则称随机区间 $(\hat{\theta}_1, +\infty)$ 是参数 θ 的置信度为 $1 - \alpha$ 的单侧置信区间, $\hat{\theta}_1$ 称为 $1 - \alpha$ 的单侧置信下限.



§7.2 区间估计

★ 定义(续)(单侧置信区间)

又若存在统计量

$\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 使得

$$P\{\theta < \hat{\theta}_2\} = 1 - \alpha \text{ 对一切 } \theta \in \Theta \text{ 成立,}$$

则称随机区间 $(-\infty, \hat{\theta}_2)$ 是参数 θ 的置信度为 $1 - \alpha$ 的单侧置信区间, $\hat{\theta}_2$ 称为 $1 - \alpha$ 的单侧置信上限.

§7.2 区间估计

★ 注

- 1 **估计精度**: 置信区间的长度就是区间估计的估计精度, 区间长度越短, 精度越高.
- 2 **置信度**: 置信度的大小反映了这个区间估计的可靠程度, 即随机区间包含参数的概率大小
- 3 **精度与置信度的关系**: 在样本容量一定的情况下, 精度和置信度是此消彼长的关系.

§7.2 区间估计

★ 枢轴量法

枢轴量法是构造未知参数置信区间的最常用的方法.

设 $G(X_1, X_2, \dots, X_n, \theta)$ 是关于样本 X_1, X_2, \dots, X_n 和未知参数 θ 的函数, 不包含其他未知参数, $G(X_1, X_2, \dots, X_n, \theta)$ 分布已知且不依赖于 θ . 一般称具有这种性质的 G 为枢轴量.

§7.2 区间估计

★ 枢轴量法的具体步骤

- (i) 设法构造一个枢轴量 $G(X_1, X_2, \dots, X_n, \theta)$;
- (ii) 对于给定的置信度 $1 - \alpha$, 利用 $G(X_1, X_2, \dots, X_n, \theta)$ 的已知分布, 确定两个常数 a, b , 使得 $P\{a < G(X_1, X_2, \dots, X_n, \theta) < b\} = 1 - \alpha$.
- (iii) 利用不等式运算, 将 $a < G(X_1, X_2, \dots, X_n, \theta) < b$ 进行等价变换, 若能得到 $\hat{\theta}_1 < \theta < \hat{\theta}_2$ 的形式, 则 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的 $1 - \alpha$ 的置信区间.

§7.2 区间估计

★ 注:

- (1) 构造枢轴量一般从 θ 的点估计 $\hat{\theta}$ 出发, 构造函数 $G(\hat{\theta}, \theta)$, 此处的 $\hat{\theta}$ 常用最大似然估计.
- (2) 满足 (iii) 中条件的 a, b 有很多, 选择的目的是希望置信区间的平均长度 $E_\theta(\hat{\theta}_2 - \hat{\theta}_1)$ 尽可能短.

§7.2 区间估计

★ 注：在 $G(X_1, X_2, \dots, X_n, \theta)$ 为单峰分布时，常用如下两种方法确定 a, b ：

(1) 当 $G(X_1, X_2, \dots, X_n, \theta)$ 的分布对称时，如正态分布，t 分布，由对称性可取 b ，使得

$$P\{-b < G(X_1, X_2, \dots, X_n, \theta) < b\} = 1 - \alpha,$$

这时 $a = -b$, b 为 $G(X_1, X_2, \dots, X_n, \theta)$ 的分布的 $\frac{\alpha}{2}$ 上侧分位数.

§7.2 区间估计

★ 注：

(2) 当 $G(X_1, X_2, \dots, X_n, \theta)$ 的分布不对称时，如 χ^2 分布，F 分布，可取 a, b 使得

$$P\{G(X_1, X_2, \dots, X_n, \theta) \leq a\} = \frac{\alpha}{2},$$

$$P\{G(X_1, X_2, \dots, X_n, \theta) \geq b\} = \frac{\alpha}{2}$$

这时 a 为 $G(X_1, X_2, \dots, X_n, \theta)$ 的分布的 $\frac{\alpha}{2}$ 分位数，

b 为 $G(X_1, X_2, \dots, X_n, \theta)$ 的分布的 $\frac{\alpha}{2}$ 上侧分位数.

§7.2 区间估计

★ 单个正态总体参数的置信区间

1、设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ，给定 α ，求 μ 的置信区间.


(1)、 σ^2 已知

$$\because Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

对给定的 α ，有

$$P\left\{-z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} < z_{\alpha/2}\right\} = 1 - \alpha$$

其中 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$



§7.2 区间估计

★ 单个正态总体参数的置信区间

$$\text{等价变形得 } P\left\{\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right\} = 1 - \alpha$$

所以， μ 的置信度为 $1 - \alpha$ 的置信区间为

$$\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = \left(\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

单选题 1分

设置

例1: 设 $X \sim N(\mu, 0.09)$, 测得 X 的4个观测值为12.6, 13.4, 12.8, 13.2, 求 μ 的95%置信区间.

x	5	6
1.6	0.9505	0.9515
1.9	0.9744	0.9750

- ☒ A (12.71, 13.29)
- ☐ B (12.75, 13.25)
- ☐ C (12, 14)
- ☐ D (12.65, 13.35)

提交

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

例1: 设 $X \sim N(\mu, 0.09)$, 测得 X 的4个观测值为12.6, 13.4, 12.8, 13.2, 求 μ 的95%置信区间.

解: $\alpha=0.05$, 查表得 $z_{\alpha/2}=z_{0.025}=1.96$
所以 μ 的95%置信区间为

$$(\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}) = (13 \pm 1.96 \times 0.3 / \sqrt{4}) = (12.71, 13.29)$$

第六章 抽样分布

§6.2 正态总体的抽样分布

回顾

★ 单个正态总体场合

设 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 为它的简单随机样本, 则有

1 $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1);$

2 $T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t(n-1);$

3 在 μ 已知时, $\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n);$

4 在 μ 未知时, $\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1).$

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

(2)、 σ^2 未知

选取枢轴量 $T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t(n-1);$

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

(2)、 σ^2 未知


对给定的 α , 有

$$P\{-t_{\alpha/2}(n-1) < \frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{\alpha/2}(n-1)\} = 1 - \alpha$$

$$\text{得 } P\{\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}\} = 1 - \alpha$$

所以, μ 的置信度为 $1-\alpha$ 的置信区间

$$(\bar{x} - t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}}, \bar{x} + t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}}) = (\bar{x} \pm t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}})$$



第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

2、设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 给定置信度 $1-\alpha$, 求 σ^2 (或 σ) 的置信区间。

(1) μ 已知

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n);$$

$$P\left\{\chi_{1-\alpha/2}^2(n) < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} < \chi_{\alpha/2}^2(n)\right\} = 1 - \alpha$$

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

$$\text{得 } P\left\{\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)} < \sigma^2 < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}\right\} = 1 - \alpha$$

$$\text{得 } P\left\{\sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}} < \sigma < \sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}}\right\} = 1 - \alpha$$

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

所以, σ^2 与 σ 的置信度为 $1-\alpha$ 的置信区间分别为

$$\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}\right),$$

$$\left(\sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}}, \sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}}\right).$$

主观题 1分

设置

2、设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ，给定置信度 $1-\alpha$ ，求 σ^2 (或 σ)的置信区间。 $(\mu$ 未知时)

正常使用主观题需2.0以上版本雨课堂

作答

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

2、设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ，给定置信度 $1-\alpha$ ，求 σ^2 (或 σ)的置信区间。

(2) μ 未知

$$\because \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$P\{\chi_{1-\alpha/2}^2(n-1) < \frac{(n-1)S^2}{\sigma^2} < \chi_{\alpha/2}^2(n-1)\} = 1-\alpha$$

第七章 参数估计

§7.2 区间估计

★ 单个正态总体参数的置信区间

$$\text{得 } P\left\{\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} < \sigma^2 < \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}\right\} = 1-\alpha$$

$$P\left\{\frac{\sqrt{n-1}S}{\sqrt{\chi_{\alpha/2}^2(n-1)}} < \sigma < \frac{\sqrt{n-1}S}{\sqrt{\chi_{1-\alpha/2}^2(n-1)}}\right\} = 1-\alpha$$

所以， σ^2 与 σ 的置信度为 $1-\alpha$ 的置信区间分别为

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}\right) \left(\frac{\sqrt{n-1}S}{\sqrt{\chi_{\alpha/2}^2(n-1)}}, \frac{\sqrt{n-1}S}{\sqrt{\chi_{1-\alpha/2}^2(n-1)}}\right)$$

表彰榜



池浩闻

上节回顾

★ 总结：用C-R不等式证明UMVUE的方法步骤

设总体 $X \sim f(x; \theta)$, X_1, X_2, \dots, X_n 为 X 的一个样本,
证明 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的UMVUE.

1 证明 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量, 即验证 $E(\hat{g}) = g(\theta)$;

2 计算 $D(\hat{g}(X_1, X_2, \dots, X_n))$;

3 计算C-R下界:

(1) 计算Fisher信息量 $I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right]$.

(2) C-R下界为 $\frac{[g'(\theta)]^2}{nI(\theta)}$

4 验证C-R下界与 $D(\hat{g}(X_1, X_2, \dots, X_n))$ 是否相等.

上节回顾

区间估计 置信区间: 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$

枢轴量法: (i) 构造一个枢轴量 G ;

(ii) 对于给定的置信度 $1-\alpha$, 确定两个常数 a, b , 使得

$P\{a < G(X_1, X_2, \dots, X_n, \theta) < b\} = 1-\alpha$;

(iii) 对 $a < G(X_1, X_2, \dots, X_n, \theta) < b$ 进行等价变换, 若可以解出

$\hat{\theta}_1 < \theta < \hat{\theta}_2$ 的形式, 则 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的 $1-\alpha$ 的置信区间.

单个正态总体区间估计: 置信度 $1-\alpha$

§7.2 区间估计

★ 两个正态总体参数的置信区间

设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且相互独立,

$X_1, X_2, \dots, X_{n_1}, Y_1, Y_2, \dots, Y_{n_2}$ 为抽自这两个总体的样本, 记

$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{j=1}^{n_2} Y_j,$

$S_1^2 = \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2}{n_1 - 1}, S_2^2 = \frac{\sum_{j=1}^{n_2} (Y_j - \bar{Y})^2}{n_2 - 1}$, 则

$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$ 称为混合样本方差.

待估参数		枢轴量	随机变量的分布	置信区间的上、下限
μ	σ^2 已知	$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$	$N(0, 1)$	$\bar{X} \pm z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$
	σ^2 未知	$\frac{\bar{X} - \mu}{S / \sqrt{n}}$	$t(n-1)$	$\bar{X} \pm t_{\frac{\alpha}{2}}(n-1) \cdot \frac{S}{\sqrt{n}}$
σ^2	μ 已知	$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$	$\chi^2(n)$	$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\frac{\alpha}{2}}^2(n)} \quad \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\frac{\alpha}{2}}^2(n)}$
	μ 未知	$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	$\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)} \quad \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}$

回顾

§6.2 正态总体的抽样分布

★ 两个正态总体场合

1 在 σ_1, σ_2 已知时, $\bar{X} \pm \bar{Y} \sim N(\mu_1 \pm \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$, 且有

$$\frac{\bar{X} \pm \bar{Y} - (\mu_1 \pm \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1);$$

回顾

§6.2 正态总体的抽样分布

★ 两个正态总体场合

2 虽然 σ_1, σ_2 未知, 但是当 $\sigma_1^2 = \sigma_2^2$ 时, 则

$$\begin{aligned} T &= \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \\ &= \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2), \end{aligned}$$

其中 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$ 称为混合样本方差;

回顾

§6.2 正态总体的抽样分布

★ 两个正态总体场合

3 若 μ_1, μ_2 已知, 则

$$F = \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2 / n_1 \sigma_1^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2 / n_2 \sigma_2^2} \sim F(n_1, n_2);$$

回顾

§6.2 正态总体的抽样分布

★ 两个正态总体场合

4 若 μ_1, μ_2 未知, 则

$$F = \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2 / (n_1 - 1) \sigma_1^2}{\sum_{i=1}^{n_2} (Y_i - \bar{Y})^2 / (n_2 - 1) \sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$



§7.2 区间估计

★ 两个正态总体参数的置信区间

1、给定 α , 求 $\mu_1 - \mu_2$ 的区间估计.

(1) 在 σ_1, σ_2 已知时, 选取枢轴量

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1);$$



§7.2 区间估计

★ 两个正态总体参数的置信区间

1、给定 α , 求 $\mu_1 - \mu_2$ 的区间估计.

(2) 虽然 σ_1, σ_2 未知, 但是当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时, 选取枢轴量

$$\begin{aligned} T &= \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \\ &= \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2), \end{aligned}$$



§7.2 区间估计

★ 两个正态总体参数的置信区间

2、给定 α , 求 $\frac{\sigma_1^2}{\sigma_2^2}$ 的区间估计.

(1) 若 μ_1, μ_2 已知, 则选取枢轴量

$$F = \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2 / n_1 \sigma_1^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2 / n_2 \sigma_2^2} \sim F(n_1, n_2);$$



§7.2 区间估计

★ 两个正态总体参数的置信区间

2、给定 α , 求 $\frac{\sigma_1^2}{\sigma_2^2}$ 的区间估计.

(2) 若 μ_1, μ_2 未知, 则

$$F = \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2 / (n_1 - 1) \sigma_1^2}{\sum_{i=1}^{n_2} (Y_i - \bar{Y})^2 / (n_2 - 1) \sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$



§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

对一般总体 X ,若其均值为 μ ,方差为 σ^2 ,只要样本容量 n 足够大,根据中心极限定理,可以认为

\bar{X} 近似服从正态分布,

即 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ 近似服从标准正态分布.



§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

1. 比例数(或概率)的近似置信区间估计

我们可以把比例看成是一个服从伯努利分布总体 X 的参数

$X = \begin{cases} 1, & \text{表示抽到具有某种属性A的个体,} \\ 0, & \text{表示抽到不具有某种属性A的个体,} \end{cases}$

则 $X \sim B(1, p), E(X) = p, D(X) = p(1 - p).$



§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

1. 比例数(或概率)的近似置信区间估计

设 X_1, X_2, \dots, X_n 是 X 的一个样本,则 \bar{X} 即是在 n 次观察中

A出现的频率 $\frac{\mu_n}{n}$,其中 $\mu_n = X_1 + X_2 + \dots + X_n$,

\bar{X} 作为 p 的估计,显然有

$E(\bar{X}) = p, D(\bar{X}) = \frac{p(1-p)}{n}$,当 n 足够大时,近似的有

$\frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \sim N(0, 1).$



§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

1. 比例数(或概率)的近似置信区间估计

选取枢轴量 $\frac{\bar{X} - p}{\sqrt{p(1-p)/n}},$

$$P\left\{-z_{\alpha/2} < \frac{\bar{X} - p}{\sqrt{p(1-p)/n}} < z_{\alpha/2}\right\} = 1 - \alpha.$$

$$\text{求} \left| \frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \right| < z_{\alpha/2} \Rightarrow (\bar{X} - p)^2 < z_{\alpha/2}^2 p(1-p)/n,$$

$$\Rightarrow (1 + z_{\alpha/2}^2/n)p^2 - (2\bar{X} + z_{\alpha/2}^2/n)p + \bar{X}^2 < 0,$$

§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

1. 比例数(或概率)的近似置信区间估计

求解 p 的二次方程得

$$\hat{p} = \frac{n}{n + z_{\alpha/2}^2} \left[\bar{X} + z_{\alpha/2}^2 / 2n \pm z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{z_{\alpha/2}^2}{4n^2}} \right],$$

当 n 足够大时, 略去 $z_{\alpha/2}^2 / n$, 得 p 得置信度为

$1-\alpha$ 得置信区间为

$$\left(\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right).$$

§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

2. 泊松分布中参数得近似置信区间:

设总体 X 服从参数为 λ 的泊松分布 $P(\lambda)$,

X_1, X_2, \dots, X_n 是 X 的一个样本, 则 \bar{X} 是 λ 的点估计.

由 $E(\bar{X}) = \lambda, D(\bar{X}) = \frac{\lambda}{n}$, 当 n 足够大时, 近似的有

$$\frac{\bar{X} - \lambda}{\sqrt{\lambda/n}} \sim N(0, 1).$$

§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

2. 泊松分布中参数得近似置信区间:

选取枢轴量 $\frac{\bar{X} - \lambda}{\sqrt{\lambda/n}},$

$$P \left\{ -z_{\alpha/2} < \frac{\bar{X} - \lambda}{\sqrt{\lambda/n}} < z_{\alpha/2} \right\} = 1 - \alpha.$$

$$\text{求 } \left| \frac{\bar{X} - \lambda}{\sqrt{\lambda/n}} \right| < z_{\alpha/2} \Rightarrow (\bar{X} - \lambda)^2 < z_{\alpha/2}^2 \lambda / n$$

$$\Rightarrow \lambda^2 - (2\bar{X} + z_{\alpha/2}^2 / n) \lambda + \bar{X}^2 < 0$$

§7.2 区间估计

★ 非正态总体均值的区间估计（大样本场合）

2. 泊松分布中参数得近似置信区间:

求解 λ 的二次方程得

$$\hat{\lambda} = \left[\bar{X} + z_{\alpha/2}^2 / 2n \pm z_{\alpha/2} \sqrt{\frac{\bar{X}}{n} + \frac{z_{\alpha/2}^2}{4n^2}} \right],$$

当 n 足够大时, 略去 $z_{\alpha/2}^2 / n$, 得 λ 得置信度为

$1-\alpha$ 得置信区间为

$$\left(\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}}{n}} \right).$$

主观题 1分

设置

例：在某综艺节目收视率的调查中抽取1000户家庭，其中有401户收看，试求该收视率 p 的置信度为95%的置信区间。

正常使用主观题需2.0以上版本雨课堂

作答

主观题 10分

设置

复习题1：

已知某种零件尺寸服从方差 1.21的正态分布，对一批这类零件检查 6 件，得尺寸数据（单位：mm）32.56 29.66 31.64 30.00 31.37 31.03

问： n 等于多少才能使由样本 X_1, X_2, \dots, X_n 构成的参数的 95%置信区间的长度小于 1？

作答

主观题 10分

设置

复习题2：

设总体 X 服从 $f(x; \theta) = \frac{2\theta}{x^3} e^{-\theta/x^2}, x > 0$,

$f(x; \theta) = 0$,其他, 参数 $\theta > 0$ 未知,

X_1, X_2, \dots, X_n 为它的样本, 求 $\frac{1}{\theta}$ 的MLE,

并考察其是否是 $\frac{1}{\theta}$ 的UMVUE, 若是请给出证明, 若不是请说明理由.

作答

解：

似然函数为 $L(\theta) = \prod_{i=1}^n \frac{2\theta}{x_i^3} e^{-\frac{\theta}{x_i^2}}, x_i > 0, i = 1, 2, \dots, n.$

$\ln L(\theta) = \sum_{i=1}^n (\ln 2\theta - 3 \ln x_i) - \sum_{i=1}^n \frac{\theta}{x_i^2},$

$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^n \frac{1}{x_i^2} = 0 \Rightarrow \theta = \frac{n}{\sum_{i=1}^n \frac{1}{x_i^2}},$ 所以 $\hat{\theta}_{MLE} = \frac{n}{\sum_{i=1}^n \frac{1}{X_i^2}}.$

由不变性知: $\frac{1}{\hat{\theta}_{MLE}} = \frac{1}{n} \sum_{i=1}^n \frac{1}{X_i^2}$

$$\begin{aligned}
E\left(\frac{\hat{1}}{\theta_{MLE}}\right) &= E\left(\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i^2}\right) = E\left(\frac{1}{X^2}\right) = \int_0^{+\infty} \frac{1}{x^2} \frac{2\theta}{x^3} e^{-\frac{\theta}{x^2}} dx \\
&= \frac{1}{x^2} e^{-\frac{\theta}{x^2}} \Big|_0^{+\infty} - \int_0^{+\infty} e^{-\frac{\theta}{x^2}} d\frac{1}{x^2} = \frac{1}{\theta}, \text{ 所以 } \frac{\hat{1}}{\theta_{MLE}} \text{ 是 } \frac{1}{\theta} \text{ 的无偏估计.} \\
D\left(\frac{\hat{1}}{\theta_{MLE}}\right) &= D\left(\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i^2}\right) = \frac{1}{n} \left(E\left(\frac{1}{X^4}\right) - \frac{1}{\theta^2} \right), \\
E\left(\frac{1}{X^4}\right) &= \int_0^{+\infty} \frac{1}{x^4} \frac{2\theta}{x^3} e^{-\frac{\theta}{x^2}} dx = \frac{1}{x^4} e^{-\frac{\theta}{x^2}} \Big|_0^{+\infty} - \int_0^{+\infty} e^{-\frac{\theta}{x^2}} d\frac{1}{x^4} \\
&= \frac{2}{\theta} \int_0^{+\infty} \frac{1}{x^2} \frac{2\theta}{x^3} e^{-\frac{\theta}{x^2}} dx = \frac{2}{\theta^2}, \\
\text{所以 } D\left(\frac{\hat{1}}{\theta_{MLE}}\right) &= \frac{1}{n\theta^2}
\end{aligned}$$

$$\begin{aligned}
\ln f(x; \theta) &= \ln 2 + \ln \theta - 3 \ln x - \frac{\theta}{x^2} \\
\frac{\partial \ln f(x; \theta)}{\partial \theta} &= \frac{1}{\theta} - \frac{1}{x^2}, \quad \frac{\partial^2 \ln f(x; \theta)}{(\partial \theta)^2} = -\frac{1}{\theta^2}, \\
I(\theta) &= -E\left(\frac{\partial^2 \ln f(X; \theta)}{(\partial \theta)^2}\right) = \frac{1}{\theta^2}, \\
\text{因此C-R下界为 } \frac{((1/\theta))^2}{nI(\theta)} &= \frac{1}{n\theta^2} = D\left(\frac{\hat{1}}{\theta_{MLE}}\right), \\
\text{所以 } \frac{\hat{1}}{\theta_{MLE}} &\text{ 是 } \frac{1}{\theta} \text{ 的UMVUE.}
\end{aligned}$$